はじめに

データ管理は、今注目を浴びている破壊的なテーマです。あらゆるところでデータフィケーション（さまざまなものやことをデータ化すること、https://oreil.ly/xtutZ）が行われています。スマートフォンや、テレビ、電子書籍リーダー、産業用機械、自動運転車、ロボットなど、このような変革が私たちの身の回りで起きています。そして、私たちの生活を急激なスピードで変化させています。

生成されるデータの量が急増するだけでなく、その複雑さも増しています。クラウド化、APIとエコシステム、マイクロサービス、オープンデータ、SaaS（Software-as-a-Service）など、ソフトウェアデリバリーモデルの破壊的なトレンドが登場し、データ管理に多大な影響を及ぼしています。それと同時に、非常にたくさんの新しいアプリケーションによってビジネスのあり方が大きく変化しています。これらのトレンドは、データランドスケープを細分化してしまっています。結果として、ポイントツーポイントのインタフェースが増え、データの品質やオーナーシップに関する議論が続き、プライバシーや安全性、セキュリティに関して倫理面や法律面のジレンマも多く見られるようになりました。アジリティ、長期的な安定性、明確なデータガバナンスは、新しいビジネスを迅速に開発したいという要求と衝突します。私たちは、この変化しつづけるデータ管理の未来について、明確なビジョンを持つ必要があります。

本書におけるデータ管理に関する考え方は、筆者がチーフデータアーキテクトとして、大企業のデータアーキテクチャ計画を主導した際の経験に基づいています。この役割を通じて、優れたデータ戦略を策定することが、大きな組織にとっては非常に重要であることがわかりました。その会社を辞めた後、Microsoft Netherlands社で最高データ責任者（CDO）として働きはじめました。この心躍る新しいポジションで、50社を越える大企業のお客様とともに、理想的なデータソリューションについて議論し、試行錯誤してきました。以下に、すべての企業に共通する重要な点をいくつか紹介します。

- データ戦略を漠然と策定したため、データ戦略にビジネス上の目標がなかったり、目標と結びついていなかったりすることがよくあります。データ管理に関しては、技術動向やエンジニアリングの議論に終始しがちです。重要なのは、ビジネスにどう繋げていくかです。ビジネス上のユースケースという形で、具体的な価値を持つような、優れた戦略や、よく練られたデータ管理や分析計画が必要なのです。つまり、データをどう活用するか、どうビジネス価値へ転換していくかに焦点を当てなければなりません。
- データメッシュやデータファブリックのような新しい概念を企業が理解するのは困難です。実践的なガイダンスや、現場での経験が不足しているためです。さらに、データメッシュは非中央集権型のアプローチを全面的に採用しており、これはアーキテクチャやテクノロジーだけでなく、組織やプロセスも変革していく必要があります。つまり、ITだけを変革するのではなく、ビジネスを変革することでもあるのです。
- 最新のテクノロジートレンドを企業が理解するのは困難です。テクノロジートレンドを理解することも、適切な選択をすることもできません。
- 企業は最初の一歩を踏み出すこと自体に苦労しています。大きな目標を持っていても、それを行動に移すことができません。実行計画やアーキテクチャがあまりに抽象的で、具体性に欠けるため、経営陣によるトップダウンの取り組みにならないのが現状です。

このようなさまざまな企業での経験を踏まえて、この『大規模データ管理 第2版』を執筆しました。この本が第1版と比較して読む価値があるのかどうか、疑問に思われているかもしれません。この点について詳しく紹介することにしましょう。

なぜ本書を執筆したのか、そして、なぜ今執筆したのか

第1版は、ABN AMRO社でチーフデータアーキテクトとして働いていたときの経験をもとに執筆しました[†1]。その際、筆者のチームでは、より速いペースで変化するニーズに応じて、作業や責任を変化させていくという、連合型という方法を実践しました。中央集権と非中央集権の間のバランスを取るために、管理体制を整えました。このような変革は、中央データチームがサポートする形で始まり、事業部門が目標を達成するためのプラットフォーム開発に取り組みました。プラットフォームが事業部門のユースケースに対応できるように、セルフサービス機能を導入し、アナリストをドメインに割り当てました。ドメイン駆動設計も試しましたが、最終的にはアーキテクチャ全体を管理するビジ

ネスアーキテクチャへと移行しました。これらの経験については、初版を執筆する際に活用しました。

[†1] 本書で記載されている内容や意見は、必ずしもABN AMRO社やMicrosoft社の公式な見解を反映したものではありません。

初版の原稿を完成させた頃に、**データメッシュ**という言葉が生まれました。このデータメッシュは、大量のデータを利用可能にする社会技術的なアプローチを表す言葉です。この概念を説明する記事を、Zhamak Dehghani氏がMartin FowlerのWebサイト（https://oreil.ly/Metdq）に掲載してくれたことで、ABN AMRO社で何年も前から使っていた概念を表す名前が見つかりました。この言葉は業界用語となり、企業が規模を拡大する際の課題を解決するものとして、大規模な組織でこの概念が急速に受け入れられています。

では、なぜ第2版を書いたのでしょうか。まず、データメッシュの概念がその理由です。データ管理とソフトウェアアーキテクチャの関係を密接にし、ビジネスがデータのオーナーシップを持つという考え方は素晴らしいものです。ただ、これだけ大騒ぎになっているのですから、少し違った視点からの考察も必要ではないかと確信しています。

エンタープライズアーキテクトとしての筆者の以前の役割では、何百ものアプリケーションチーム、何千ものサービス、そして多くの大規模なレガシーアプリケーションを管理しなければなりませんでした。そのような状況では、複雑さに対処するアプローチも異なります。データメッシュアーキテクチャでは、**アーティスト**、**曲**、**プレイリスト**がデータドメインの例としてよく使われます。データを細かいドメインに分解するこの手法は、マイクロサービスを設計するときには適しているかもしれませんが、大規模なデータランドスケープの（再）構築には必ずしも適していません。大規模に対応するには別の視点が必要です。また、データプロダクトに関しては、よりきめ細やかな実践的な視点が必要です。データを包括的かつエンドツーエンドで管理しなければならないのには、それなりの理由があります。企業には、再利用性と一貫性に対する課題があります。法規制によって、組織報告、会計、財務報告、監査、リスク管理についても同じ次元で準拠しなければなりません。賛否両論あると思いますが、データプロダクトをコンテナ（データやメタデータ、コード、インフラストラクチャーをマイクロサービスのような小さなアーキテクチャにまとめてパ

ッケージ化したもの）として管理することはお勧めできません。このような管理方法は、今日のビッグデータプラットフォームの仕組みを考慮していません。最後に、データメッシュの議論はまだ完全ではない、という点も指摘しておきます。データメッシュは、分析目的に使用されるデータのみに焦点を当てています。運用データには焦点を当てていません。また、マスターデータ管理についての考慮が不足しています[†2]。コンシューマ側は高度なデータファブリックでサポートされる必要があります。そして、データプロダクトを構築するためのデータモデリングに関するガイダンスもあまり提供されていません。

[†2] 「マスター／スレーブ」という用語は明らかに不適切であり、多くの組織は「ソース／レプリカ」や「プライマリー／サブオーディネート」等の用語を使うようになっています。本書ではできるだけインクルーシブになるよう努めていますが、業界としてまだ別の言葉が用意されていないため、本書では「マスターデータ管理」という言葉を使っています。

第2版を出版するもう一つの理由として、初版に対する実用性への懸念です。さまざまな読者から、初版は抽象的すぎるという感想をいただきました。批判的なレビュアーの中には、筆者の現場経験を疑問視するコメントを残した方もいました。この第2版では、このような懸念に応えるべく、多くの実例と具体的な解決策を示しています。また、設計と実装方法に関する筆者のブログ記事も適宜紹介しています。ただし、**本書には、非常に複雑なトピックが多数記述されています。また、このトピックはコンテキストに大きく左右されるものです。**一冊の本ですべての事例を紹介することは不可能ですので、ある程度割り切った記述になっています。

ベストプラクティスに関する筆者の考えや、現場からの気づきを読者と分かち合えることをうれしく思っています。本書が読者のヒントになれば幸いです。ABN AMRO社で働いたときの経験を振り返ると、他社から学ぶべき教訓がたくさんありました。良い手法もたくさん見てきました。優れたデータアーキテクチャを構築する際に、正しいとか間違っているとかはありません。トレードオフを正しく判断し、自社の状況に最適なものを見つけることが重要なのです。

初版を読まれた方は、この第2版が大幅に改訂され、改善されていることにお気づきになるでしょう。章の構成自体はほぼ同じですが、すべての章を改訂し

ており、また内容も充実させています。図表も全面的に更新し、新しい内容を追加し、より実践的な内容となっています。それぞれの章には、多くのヒントや基礎知識、参考になる記事の紹介を含めています。

読者について

本書は、大企業での利用を想定していますが、小規模な組織でも十分に役立ちます。本書の読者層として、以下のような方々を対象としています。

経営者やアーキテクト
最高データ責任者（CDO）、最高技術責任者（CTO）、チーフアーキテクト、リードデータアーキテクト

分析チーム
データサイエンティスト、データエンジニア、データアナリスト、データ分析部門長

開発チーム
データエンジニア、ビジネスインテリジェンスエンジニア、データモデラー、データデザイナー、そのほかデータの専門家

コンプライアンスおよびガバナンスチーム
最高情報セキュリティ責任者（CISO）、データ保護責任者（DPO）、情報セキュリティアナリスト、規制コンプライアンス責任者、データスチュワード、ビジネスアナリスト

本書の読み方、使い方

最初に断っておきますが、本書は多くの複雑なトピックを扱っています、それらは互いに関連していたり、ほかのテーマへとつながっていたりします。そのため、さまざまなテクノロジー、ビジネスメソッド、フレームワーク、アーキテクチャパターンを行ったり来たりすることになります。時には、これまでさまざまなアーキテクチャを実装してきた筆者自身の運用経験も織り交ぜながら、異なるレベルの抽象度で話を展開していきます。この抽象度の変化を理解しやすくするために、本書では、ヘリコプターをたとえとして用います。

まず、データ管理、データ戦略、データアーキテクチャを高い視点から抽象的に眺め、全体を俯瞰することから始めます。そして、ヘリコプターの高度を下げて、データドメインとランディングゾーンについて掘り下げます。次に、アプリケーションがどのように管理され、データがどのように作成されるかを見るためにソースシステム側に向かい、データ管理の多くの領域を旋回し探索します。その後、データを利用するコンシューマ側に飛び、そこで何が行われて

いるかを学びます。そして、実践を通じ、これまで学んだことを統合しまとめます。

以下の表は、各章でどのテーマが重点的に取り上げられているのかをまとめたものです。本書を読みすすめる上で参考にしてください。

表1　各章の主なトピック

	1章	2章	3章	4章	5章	6章	7章	8章	9章	10章	11章	12章
データ管理	●											
データ戦略	●	●	●									●
データアーキテクチャ		●	●				●					●
データ統合				●	●	●	●					
データモデリング				●			●		●			
データガバナンス								●				

データセキュリティ			●			
データ品質		●				
メタデータ管理				●		
MDM			●			
ビジネスインテリジェンス						●
アドバンストアナリティクス						●
エンタープライズ					●	●

```
ア ー
キ テ
ク チ
ャ
```

1章では、データ管理について紹介します。データ管理とはなにか、データ管理はどのように変化しているのか、デジタルトランスフォーメーションにどのような影響を与えるのか、その動向を説明します。また、近年のこの分野の状況を分析し、データ戦略を策定するためのガイダンスを示します。2章では、大規模データ管理について詳しく説明します。大規模なデータランドスケープをデータドメインを使って管理するための方法論として、ドメイン駆動設計とビジネスアーキテクチャを紹介します。3章では、データアーキテクチャを構造化し、データドメインと連携させる方法として、トポロジーとデータランディングゾーンを取り上げます。

4章以降は、データ流通について詳しく説明します。4章では、データプロダクトや、CQRS（Command Query Responsibility Segregation、コマンドクエリ責務分離）、原則に着目し、ソリューション設計の例を紹介します。5章ではAPI管理について、6章ではイベントと通知の管理について説明します。7章は、すべてを統合したまとめです。アーキテクチャについてのガイダンスや経験を補足します。

次に、データ管理について、より高度な部分を掘り下げていきます。8章では、変化の激しい時代にあっても、長期的に持続可能で実用的な方法でデータガバナンスとセキュリティを実現する方法について検討します。9章では、メタデータの使い方、重要性、民主化がもたらす効果を考察します。10章では、分散している多様なデータ資産において、マスターデータ管理（MDM）を用いてデータの一貫性を維持するためのガイダンスを提供します。11章では、データを価値に変えるプロセスについて取り上げます。12章では、メタデータを活用した事例と、データ管理とエンタープライズアーキテクチャの将来像について述べます。

本書の表記法

本書では以下の表記法を使います。

太字（サンプル）
強調や新出用語に使います。

`等幅（sample）`
プログラムリストに使います。また本文の段落中でも、変数名や関数名、データベース、データ型、環境変数、文、キーワードなど、プログラムの要素を示すためにも使います。

ヒントや提案を表します。

一般的なメモを表します。

警告または注意を表します。

オライリー学習プラットフォーム

オライリーはフォーチュン100のうち60社以上から信頼されています。オライリー学習プラットフォームには、6万冊以上の書籍と3万時間以上の動画が用意されています。さらに、業界エキスパートによるライブイベント、インタラクティブなシナリオとサンドボックスを使った実践的な学習、公式認定試験対策資料など、多様なコンテンツを提供しています。

https://www.oreilly.co.jp/online-learning/

また以下のページでは、オライリー学習プラットフォームに関するよくある質問とその回答を紹介しています。

https://www.oreilly.co.jp/online-learning/learning-platform-faq.html

お問い合わせ

本書に関する意見、質問等はオライリー・ジャパンまでお寄せください。連絡先は次の通りです。

株式会社オライリー・ジャパン

電子メール：japan@oreilly.co.jp

本書のWebページには、正誤表やコード例などの追加情報が掲載されています。次のURLを参照してください。

https://oreil.ly/data-mgmt-at-scale-2e（*原書*）

https://www.oreilly.co.jp/books/9784814400713（*和書*）

本書に関する技術的な質問や意見は、次の宛先に電子メール（英文）を送ってください。

bookquestions@oreilly.com

オライリーに関するその他の情報については、次のオライリーのWebサイトを参照してください。

https://www.oreilly.co.jp

https://www.oreilly.com（*英語*）

謝辞

本書を書くことを許してくれたJessica Strengholt-Geitenbeek氏に感謝します。筆者が本書を著している間、彼女は子供の面倒を見たり、部屋を片付けて

くれたりするなど、筆者がこの仕事に専念できるように支えてくれました。彼女は、筆者の最愛の人です。

また、ABN AMRO社、とりわけSanthosh Pillai氏の信頼と、同社での仕事を通じて筆者を導いてくれたことに感謝を表します。本書のアイデアの多くは、彼の頭の中で生まれたものです。彼との数多くの議論がなければ、本書をまとめることはできなかったでしょう。次に、この第2版の執筆にあたって、サポートしてくれたMicrosoft社に感謝の意を表したいと思います。このほか、多くの方々から本書へのサポートとフィードバックをいただきました。Tim Ward氏（CluedIn社CEO）、Batuhan Tuter氏、Nasim Merhshid氏、Rob Worrall氏、Frank Leisten氏、そのほかさまざまな形で貢献してくれたすべての人たちに感謝します。

最後になりましたが、サポートと信頼を寄せてくれたオライリーの素晴らしいスタッフの皆さんに感謝します。Shiraさん、筆者の面倒を見てくれてありがとうございます。楽しい会話と建設的なフィードバックにも感謝しています。また、Katieさんの絶え間ないサポートと誠実さに感謝します。素晴らしい編集者であるRachel Head氏、校閲と編集に尽力してくれてありがとう。内容の誤りを見つけてくれたり、筆者の文章がうまくつながるように校正してくれたりしてくれて、本当に素晴らしい仕事でした。