3章
ドメインとテクノロジーアーキテクチャのマッピング

データドメインとは何か、どのように理解すればよいかがわかったと思います。次はそれらをどのようにグループ化し管理するか、テクノロジーアーキテクチャにどのように落とし込むかについて説明しましょう。機能ドメインとアーキテクチャを分解し、この2つの間の整合性をとることが非常に重要になります。なぜなら、アーキテクチャと、ガバナンス標準を導入しコントロールを確立しデータプロダクトを管理していく方法は密接に関連しているからです。

筆者の経験では、組織によって、ドメインアーキテクチャの分割方法や管理方法にかなりの相違があります。組織は、大規模なアーキテクチャを設計するときにトレードオフを行います。なぜなら、その組織固有の要件と戦略に合うように設計しなければならないからです。このようなトレードオフは、オーナーシップ、組織の規模や複雑さ、セキュリティ、変化のスピード、テクノロジー、コスト管理、カルチャー的・政治的特性など、多くの面にわたります。1章で述べたように、高い自律性を求める組織もあれば、品質とコントロールを重視する組織もあります。比較的単純な構造の組織もあれば、きわめて大規模で複雑な組織もあります。これらすべての要件のバランスをとるのは容易ではないため、要件の大部分に適合するような一般的なアーキテクチャ設計を選び、それをベースとして構築していくのが一般的です。後述するように、最初から正しいアーキテクチャ基盤を選択すれば、後々の問題を避けることができます。

この章は2つのパートに分かれています。前半は**ドメインのトポロジー**について説明します。トポロジーとは、ドメインをグループ化し、関連付けし、配置する方法のことです。いくつかの一般的なアーキテクチャ設計を取り上げ、組織がある設計を選ぶのはなぜか、組織を動かしているものは何かについて考察します。

この章の後半では、**ランディングゾーントポロジー**について説明します。ランディングゾーントポロジーとは、ドメインが解決空間と整合がとれるようにする方法です。また、クラウドの構成、標準サービス、ストレージを整理するための手法などを見ていきます。この節の最後には、2章でも紹介した架空のオーシャニック航空を使って、実践的な例を説明します。どちらの節でも、たくさんの顧客と仕事をしてきた筆者自身の経験を交えながら、考慮すべきトレードオフについて議論します。

3.1　ドメイントポロジー：問題空間の管理

前章では、非中央集権的なデータオーナーシップという概念は、責任をさまざまなドメインに分散・連合させるものであることを説明しました。テクノロジースタックについて考え、データチームが作業を開始する前に、まず全体像を俯瞰し、問題領域（より具体的にはビジネスチャンス）を特定する必要があることを説明しました。ビジネスケイパビリティについても触れ、ビジネスケイパビリティマップを作成することが出発点として重要であると述べました。また、データオーナーシップのためのさまざまな設計原則やガイドラインも紹介しました。

しかし、ドメイン同士をつなぎ合わせるとき、問題空間と解決空間はどのように連携しなければならないでしょうか。ある特性をもとにドメインをグループ化すべきでしょうか。もしそうなら、どの特性を、なぜ、どのようにグループ化すべきでしょうか。すべてのドメインにデータプロダクトのネットワークに接続できるだけの自律性を与えるべきでしょうか、それとも中央の管理者が介在すべきでしょうか。ドメインをまたがるようなデータへの対応はどうすべきでしょうか。例えば、ドメインがほかのドメインと重なっても良いのでしょうか。その場合、データの流れはどうなるのでしょうか。モデルはハブアンドスポーク型かピアツーピア型かどちらでしょうか。この節では、さまざまなドメインのトポロジーを見ていくことで、これらの疑問に答えていきます[†1]。

[†1] これらのドメイントポロジーはネットワークトポロジーに似ています。ネットワーク内におけるドメインの物理的・論理的関係や、リンクとドメインの配置、またはそれらのハイブリッドな関係を記述します。

ここで説明するすべてのトポロジーにおいて、データオーナーシップとドメインの境界の原則は変わりません。それぞれのドメインは自身のデータに責任を持ち、データをプロダクトとして管理し、2章で説明した共通ドライブウェイパターンを使用します。これから説明するトポロジーは、ガバナンスと柔軟性、依存と独立、管理と自律性のバランスを考えるためのものです。

3.1.1　完全連合型ドメイントポロジー

最初に紹介するドメイントポロジーは、筆者が**完全連合型（fully federated）**ドメイントポロジーと呼んでいるものです。このトポロジーがどのようにデータドメインをまとめるかを説明するために、データメッシュを例に説明しましょう。データメッシュは、大規模なデータ管理のための非中央集権的なアプローチです。4つの原則、すなわち、ドメイン主導のデータオーナーシップ、プロダクトとしてのデータ、セルフサービスのデータプラットフォーム、そして連合型計算ガバナンスに基づいています。最も基本的な形では、データメッシュは中央オーケストレーターを使わず、連合型を重視したきめ細かいアーキテクチャ設計になります。図3-1は、データメッシュ内での、ドメインの構成例を示したものです。このトポロジーでは、きめ細かく分離することとデータの再利用性の向上を目的としています。

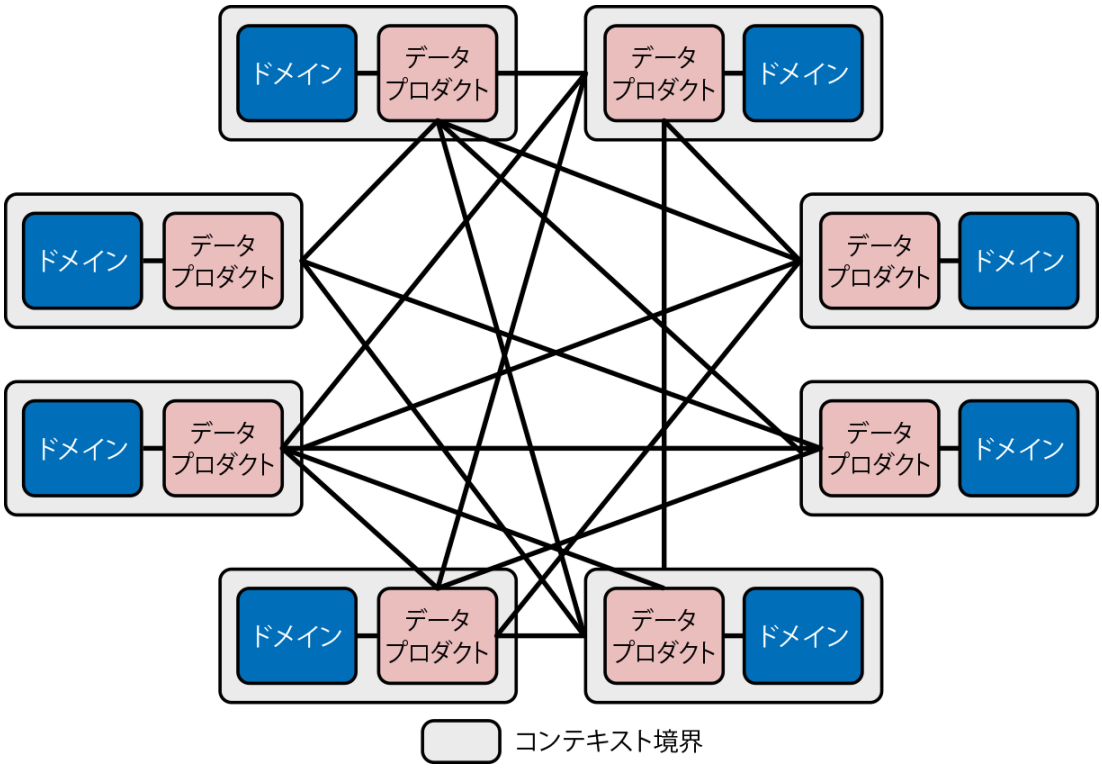

図3-1　データメッシュは、きめ細かい完全型連合ドメイントポロジーの一例

ご覧のように、自律権の境界はそれぞれのドメインときれいに整合しています。それぞれのドメインは、自身のデータに対してエンドツーエンドですべての責任を負います。それぞれのドメインは独立して運営され、データをプロダクトとして提供し、ほかのドメインに対してデータ共有の責務を負います。マイクロサービスアーキテクチャを採用している組織と同じように、きめ細かく分割されています。

図3-1でわかるようにドメイン間は直接結ばれています。データメッシュにおけるデータ流通はピアツーピアで行われます。つまり、中央の管理機関に頼らずに、直接データ流通が行われます。このように、ドメインは柔軟に対応することが可能となり、調整やデータ流通を中央のチームに依存することはありません。ガバナンスは計算（自動化）によって行われます。コンプライアンスはプラットフォームによって施行されます。

データメッシュでは、データプロダクトはきめ細かくなります。ドメイン間でデータを提供したり取得したりするために、小さなデータプロダクトアーキテクチャを数多くインスタンス化します。これらのアーキテクチャでは、データとメタデータ、インフラストラクチャー、コードが組み合わされ、ひとまとまりで配備されます。どのように機能するかの概念図を図3-2に示します。

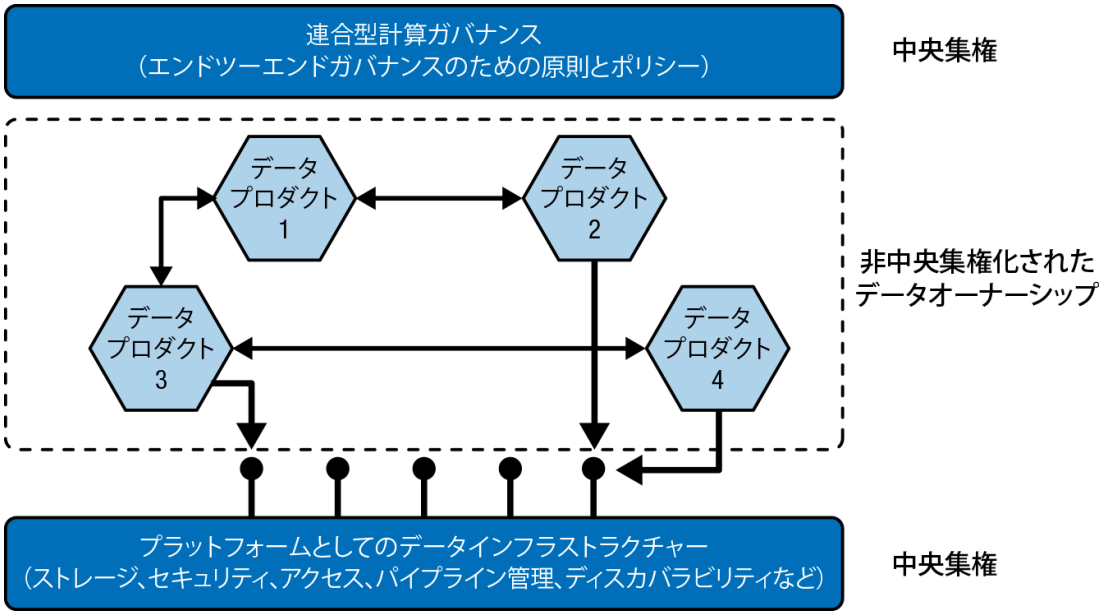

図3-2　データメッシュの論理アーキテクチャ：中央集権的な連合型計算ガバナンスとセルフサービスプラットフォーム機能、非中央集権化されたデータオーナーシップ

データメッシュトポロジーでは、ドメインをより細かく特定の分野に特化させることができます。データメッシュトポロジーでのインタラクションは多対多

であるため、組織が柔軟になり、依存関係も少なくなります。また、高度なデータプロダクトが作成できるため、データの再利用が容易になり、各データプロダクトはアーキテクチャ量子（https://oreil.ly/L1Ynv）となります。

きめ細かく完全連合型の設計は理論的には完璧に見えますが、導入について組織がより深く検討した場合、しばしば懸念が生じ、潜んでいた課題が浮かび上がってきます。これから、データメッシュのようなアーキテクチャを導入できない理由を見てみましょう。

3.1.1.1　部屋の中の象

まず、データメッシュでは、データの相互運用性、メタデータ、ガバナンス、セキュリティ標準などを、あらゆるドメインが準拠しなければなりません。この標準化のプロセスが自発的に行われることはありません。組織は、事前構想、概念化、議論、ドキュメント化から実装、コントロールに至るまで、さまざまな段階を経て、そのアーキテクチャと仕事の方法を移行させる必要があります。このアーキテクチャでは、ドメインがアプリケーションとデータをほぼ全面的に統括するため、すべてのドメインチームを共通の作業方法に準拠させるのは至難の業となります。ドメインには相反する利害関係があります。データを要求するだけのドメインもあれば、データを消費しないドメインもあり、データを消費しないドメインにとってはデータプロダクトを構築することはコストがかさむだけのものです。利害の対立に加え、ドメインはテクノロジーや仕事の進め方に関しても互いに異なる選択をする可能性があります。一部の人は、エンタープライズアーキテクチャに何ら関与することなく、ドメインを全面的に自律させることを推進するかもしれません。要するに、すべてのドメインを整合させるには、政治的な壁を壊す必要があるということです。より多くのコミュニティからの賛同と支援が必要不可欠です。

次に、組織は同じ機能が複数存在したり、ネットワークが大量に使用されたりすることを懸念します。きめ細かい多くのデータプロダクトを使うようなアーキテクチャでは、インフラストラクチャーのリソースを膨大に使用することになります。そのため、アーキテクチャの管理コストが大きくなり、複雑なものとなってしまうかもしれません。例えば、何千ものアプリケーションやプラットフォームが、オンプレミスやさまざまなクラウドで運用されているような大規模組織を想像してみてください。ピアツーピアで通信するドメイン間のネットワーク接続を簡単かつ安全に管理するにはどうすればよいでしょうか。ピアツーピアの通信は、アプリケーションの数が増えると指数関数的に増大します。これは、ネットワークの監視とセキュリティを中央チームが管理している

企業にとっては、特に深刻な問題となります。このような場合、ドメインとネットワークセキュリティチームの間で常に議論を巻き起こすことでしょう。

さらに、データプロダクトアーキテクチャの粒度が細かいことも問題となります。データをさまざまな場所から取得しなければならない場合、性能が低下します。データがサイロ化されている場合、データ検索、データ品質の検証、過去データの照合が困難になります。また、データ処理が散在していると、問題の切り分けが難しくなります。このような問題は、多くのドメインが、ほかの多くのドメインのデータに依存している場合に、特に顕著にあらわれます。例えば、金融機関は企業全体で一貫したレポーティングを行わなければなりません。法規制により、会計、財務、グループ報告、監査、リスク管理は同じデータを使用することが義務付けられています。この整合性の問題に対する典型的な解決策は、多くのデータをまとめてしまうことです。これは、データメッシュとは対照的な手法です。

これに加え、企業は適切な人材を獲得・雇用しつづけることが難しくなっています。データ管理を非中央集権化し、データメッシュトポロジーをサポートするプラットフォームを構築することは、データプロダクトアーキテクチャの自動作成、ポリシー施行、インテリジェントルーティング、非中央集権化オーケストレーション、カタログ作成、配信など、複雑でリスクを伴う作業です。データメッシュを実装するには、DataOps、自動化、セキュリティ、プラットフォーム設計などの知識を持つ、高度なスキルを持ったソフトウェアエンジニアが大量に必要です。データメッシュを成功させるには大規模な導入が必要なため、データメッシュを開始するにはかなり多くのエンジニアが必要になります。すべての組織がこのような大規模な投資を積極的に行うわけはなく、ましてや適切な人材を集めることができるわけでもありません。

きめ細かく完全に連合型ドメイントポロジーは素晴らしい選択肢ですが、実現は困難です。このトポロジーは、クラウドネイティブで、主にマイクロサービスを使用し、比較的少数のアプリケーションを使用してマルチクラウド戦略を推進し、歴史が浅く高いスキルを持つソフトウェアエンジニアを多く抱える組織で目にします。このトポロジーの採用は、社内にすでに高度な自律性がある場合にのみ検討すべきなのかもしれません。

3.1.2　統制ドメイントポロジー

データメッシュアーキテクチャが組織に高く評価されているのは、作成・管理・配布するデータについて、データ生産者が完全に責任を持つようにしてい

るからです。データメッシュアーキテクチャは、データ管理の責任を連合型にします。データ生産者は自データの専門家であるため、このような位置づけは理にかなっています。システムがどのように設計され、どのようなデータがシステム内で管理されているかを熟知しているからです。また、エンドユーザーやビジネスアナリストと緊密に連携することも多いため、データコンシューマにとって良質なデータとはどういうものかについても熟知しています。さらに、連合型にすることでスケーラビリティが実現できます。複数のチームが独立してデータパイプラインを開発し、並行してデータを提供することができるからです。多くの大企業がタスクと責任を連合型で管理することに興味を持っているのは不思議なことではありません。

インフラストラクチャー管理のオーバーヘッドを減らすには、前述のトポロジーを修正して、中央に流通レイヤーを追加します。このように変更すると、**統制ドメイントポロジー**は厳密にはデータメッシュアーキテクチャを実装したものではなくなります。それでも、多くのデータメッシュの原則を踏襲しています。それぞれのドメインは明確な境界の中で運用され、独自のアプリケーションとデータプロダクトを自律的に所有します。ただ、それらのデータプロダクトは図3-3に示すように、中央で管理・共有される論理エンティティを介して流通するようにしなければなりません。

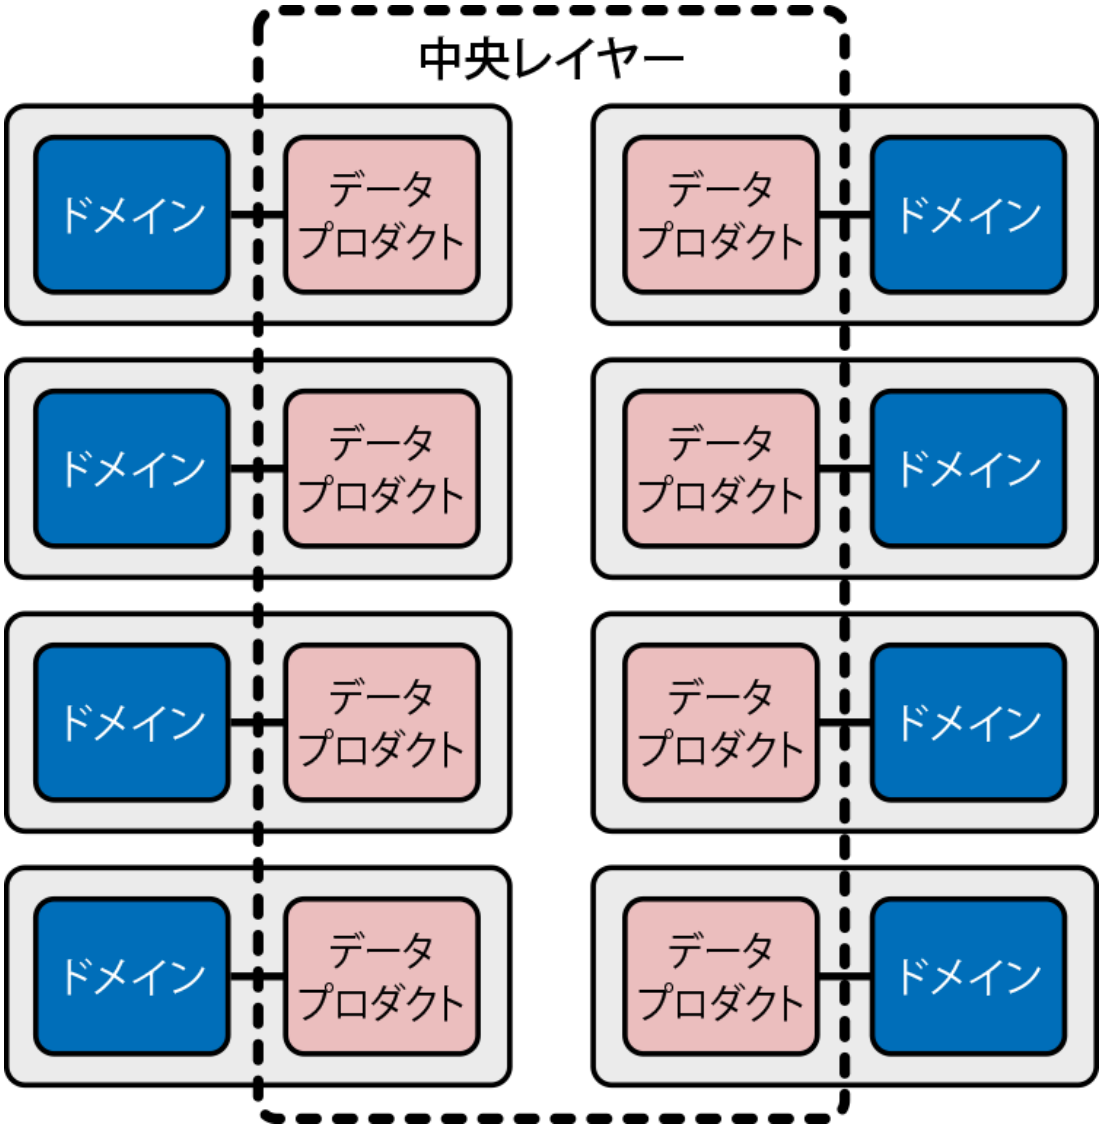

図3-3　統制ドメイントポロジー

このトポロジーは、ハブアンドスポークモデルに似ています[†2]。中央に共有データプロダクトアーキテクチャを追加することで、データ流通を効率的に管理します。中央集権化された論理的な場所にデータをいったん配信し、その後さまざまなデータコンシューマが何度もデータを消費できるようにします。

[†2] ハブアンドスポークは有名なアーキテクチャパターンです。データ転送とサーバー間通信が、中央集権化されたハブを介して行われます。

ドメインは常にすべてのデータを公開し、共有すべきなのでしょうか。それは場合によります。筆者が推奨する方法は、データプロダクトを需要駆動型で構築することです。また、一般的なベストプラクティスとして、再利用されることを考慮して、できるだけ多くのデータコンシューマに提供可能な方法でデータプロダクトを構築するのがよいでしょう。ただし、すべてのデータを常に利用できるようにすることを求める組織もありました。このような組織では、データ駆動型経営を計画していたため、市場投入までの時間を短くする必要があります。

図3-4のような中央集権型のデータ流通の方が、開発の初期段階、例えば自動化が行われていない段階では、情報の伝達に関して適切な対応ができるかもしれません。データ流通のために、単一のプラットフォームしか使用していないのであれば、データ流通や消費を簡単にブロックしたり、メタデータの配信を強制したり、特定の作業方法を要求したりすることができます。このほか中央集権型の流通には、接続の中心となる部分があるため、大量のネットワークトラフィックを避けられるという利点もあります。すべてのドメインがピアツーピア接続を使用してデータを流通する場合、入出力の接続ポイントが爆発的に増えてしまいます。中央集権型の論理エンティティへ／から流通することで、この問題が解決されます。

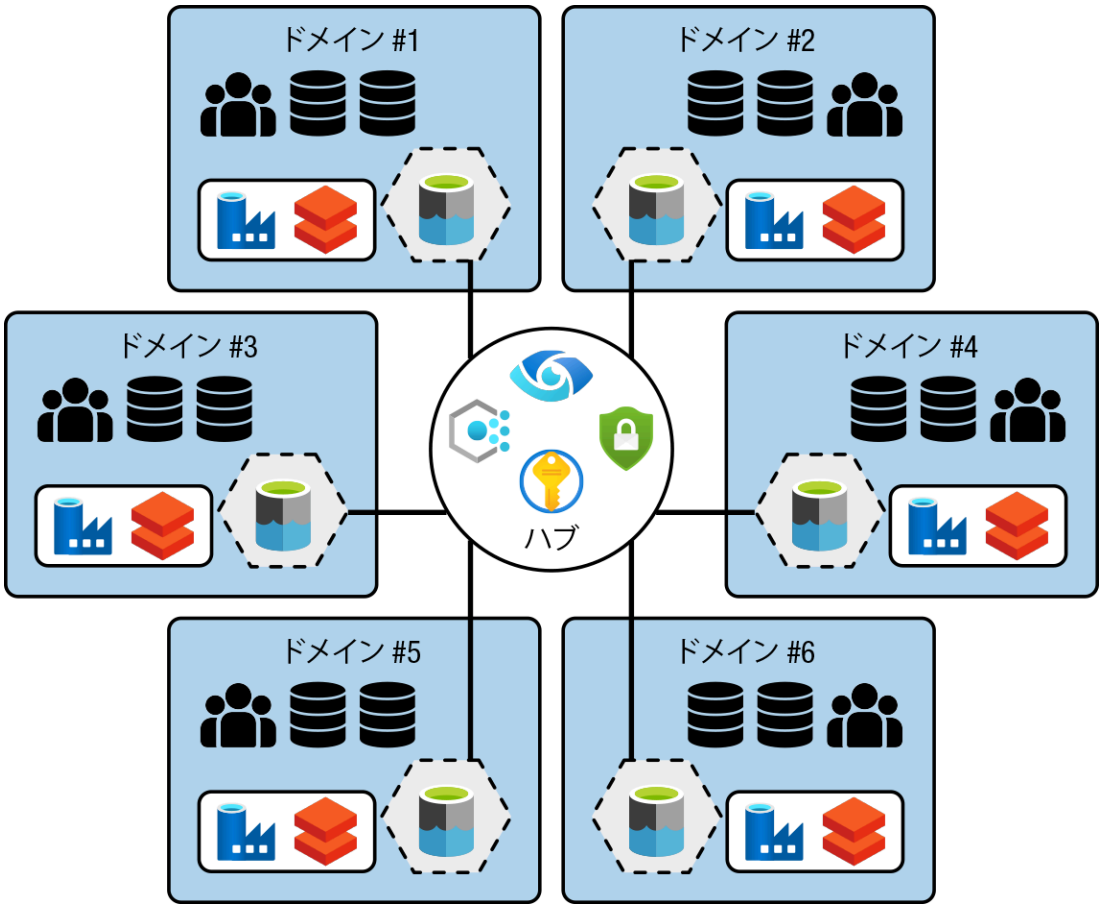

図3-4　ドメインが自身のアプリケーション、データ、データプロダクトに対して、どのようにオーナーシップを持つかを示す概要設計。データプロダクトは中央の論理エンティティを経由してルーティングされる

中央集権型の流通を使うことで、アーキテクチャのコスト効率を向上させることもできます。中央集権型の流通レイヤーを共有計算サービスでサポートする例もあります。例えば、個々のデータプロダクトのアーキテクチャからApache Sparkの処理部分を取り出し、その処理を複数のドメインで共有することで、データをコスト効率良く処理することができます。データ流通用の中央レイヤーを持つことで、データウェアハウスの一般的なワークロードである、**時系列データの管理**と**不揮発性**という要件への対応も簡単になります[†3]。

[†3] これらの概念は、Bill Inmon氏が著書“Building the Data Warehouse”（Wiley）で提示したものです。時系列データとは、時間の経過とともにデータを履歴化するということです。これによりタイムトラベルが可能になり、古いデータセットを見ることができるようになります。不揮発性とは、一度処理されたデータは変化しないということです。つまり、過去データ

は決して変更されません。履歴化（historization）については、4章で詳しく説明します。

このトポロジーでは、ドメインが中央集権型の論理エンティティを経由してデータを流通し、ルーティングしなければならないため、ドメインがそれに従う必要があります。中央集権化が強まるとともに、この点は重要となるので注意してください。中央集権化が強まると、ドメイン間の結合が強まります。中央の流通レイヤーがボトルネックとなってしまい、中央の機能に不具合があれば、ドメインがビジネス価値を提供できなくなってしまいます。異なるクラウド間でデータをシームレスに移動させるような中央集権型データ流通サービスを構築することは、一部のクラウドネイティブサービスのロックインや制限を考慮すると簡単ではありません。このため、このトポロジーをマルチクラウド環境に導入することは難しくなります。

このような状況ではあるものの、統制ドメイントポロジーを導入することで、中央集権型データ管理から連合型データ管理へ移行することに変わりはありません。実装するのは複雑かもしれませんが、それにもかかわらず、多くの組織がスケーラビリティを高めるために統制ドメイントポロジーを選択しています。これは、筆者が仕事をしたほとんどの金融機関や政府機関、そのほか、チームの自主性よりもコントロールや品質、コンプライアンスを重視する大企業に見られる傾向でした。

3.1.3　部分連合型ドメイントポロジー

すべての組織が、高度なスキルを持つソフトウェアエンジニアを多数抱えているわけではありません。また、保守やデータ抽出が困難なレガシーアプリケーションを使用しなければならない組織もあります。このような組織では、**図3-5**に示すようなトポロジーを使用して、「何らかの」連合型を実現することがよくあります。

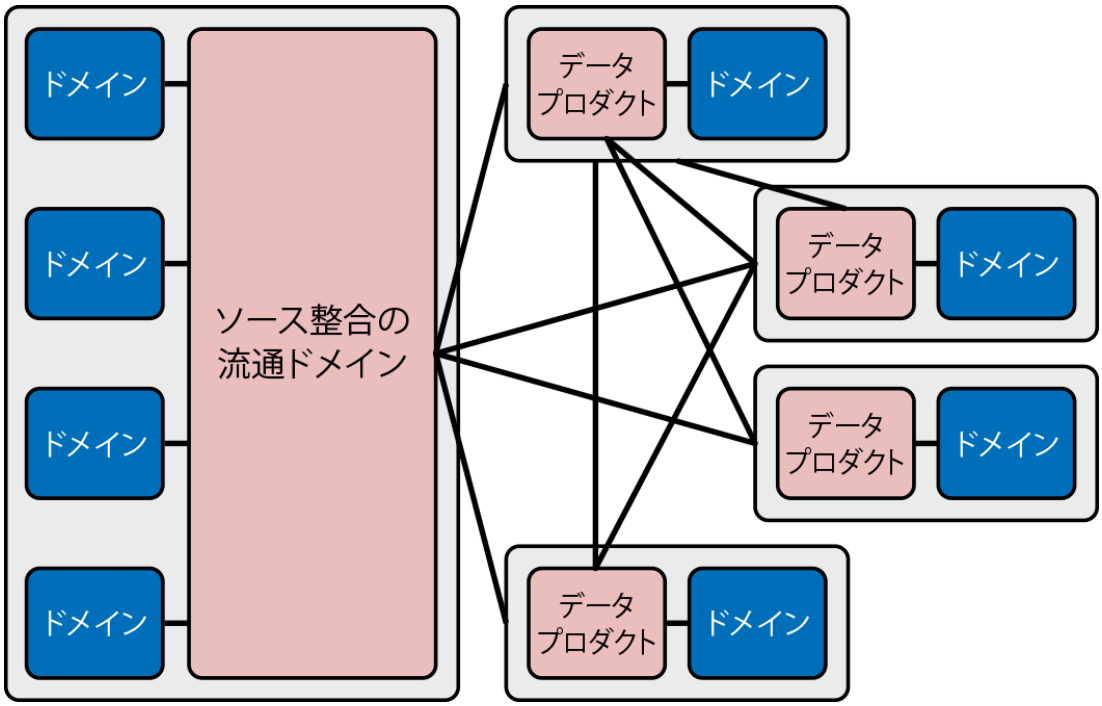

図3-5　部分連合型ドメイントポロジー：消費側では連合型、ソースシステム側では多少の中央集権化

このトポロジーとこれまでのトポロジーとの違いはどこでしょうか。連合型の要素が少なく、中央集権化が進んでいます。データプロダクト管理の考え方はあります。データは、中央集権型で共有されたデータプロダクトアーキテクチャで管理されます。ドメインチームに必要なスキルやリソースがない場合、中央のエンジニアリングチームがデータのオーナーシップを持つこともあります。このような状況では、**仮想的な**連携が行われます。プロジェクトチームのメンバーは、ドメインの代わりに、問題の解決やデータの導入をサポートします。

このアーキテクチャの消費側では、より高度な自律性とメッシュスタイルのデータ流通が行わるのが一般的です。さまざまなドメインチームがユースケースに取り組み、変換されたデータや分析アプリケーションのオーナーシップを持ちます。その成果物や新たに作成されたデータは、ピアツーピアで流通されるか、中央のデータプラットフォームに戻されます。

このトポロジーで注意してほしい点は、ソースシステム整合ドメインを管理するオーバーヘッドが増えてしまうことです。中央チームによって導入される可能性が高いためです。このアーキテクチャを使用する組織は、さまざまな運用モデル、セルフサービス機能の欠如、複雑なガイダンスと原則に起因する問題に悩まされることでしょう。また、消費ドメインが提供ドメインにもなることが多いため、データ流通のルールに一貫性がなくなる場合もあります。

3.1.4　バリューチェーン整合ドメイントポロジー

サプライチェーンマネジメント、製品開発、輸送をコアコンピタンスとする組織は、バリューチェーンに細心の注意を払っています。こうした組織を特徴づけているのは、それぞれのドメインが提供する付加価値です。ドメインは、通常、ビジネスの1つの領域として（したがって、エンドツーエンドで）、バリューストリームに整合して機能します。このため、一般的に、ドメインは本質的に密に相互接続され、運用されます。また、運用から分析へ、分析から運用へと、データを行ったり来たりさせながら処理します。このトポロジーの例を図3-6に示します。

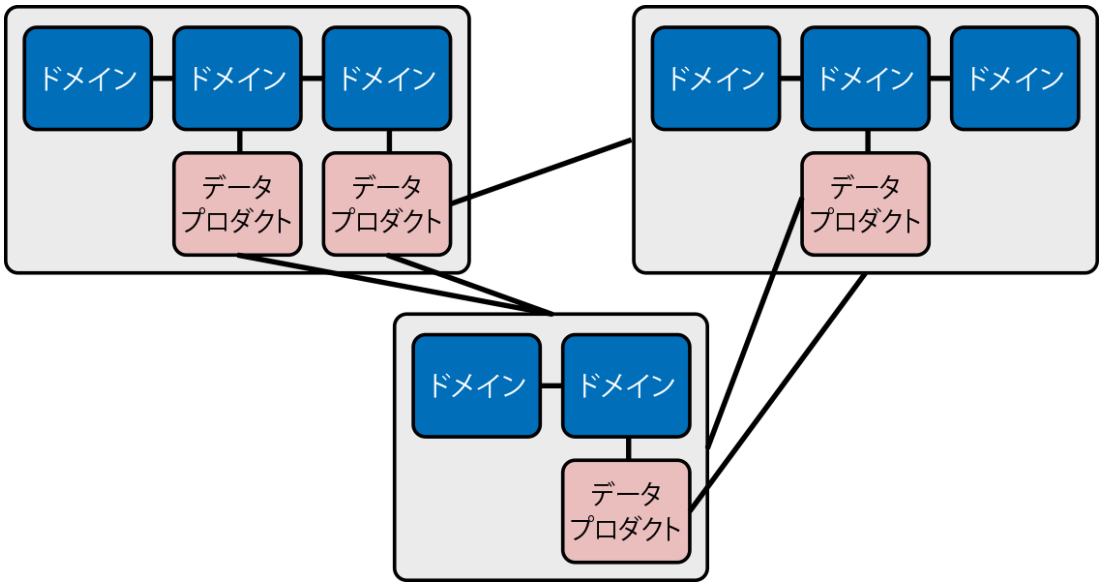

図3-6　バリューチェーン整合ドメイントポロジー：事業活動のチェーンを軸にした密なドメイン連携

ここでいうバリューチェーンとは、共通の付加価値を実現するために密に連携する小さなドメインのグループです。バリューチェーンそのものは、より高いレベルの自律性を必要とする、より大きなドメインと見なすことができます。このような大きなドメインの中では、さまざまなパターンが見られます。具体的には、バリューチェーン内部のデータ流通と、バリューチェーン間のデータ流通があります。バリューチェーンの境界内では、中央で定めた標準にあまり遵守しなかったり、一部だけ遵守していたりしても問題ありません。一方で、データがバリューチェーンの境界を越える場合は標準を遵守しなければなりません。

バリューチェーン整合ドメイントポロジーを適用する場合、さまざまな種類のガバナンスモデルを組み合わせることができます。あるドメインでは厳格に従

わせ、ほかのドメインではゆるやかなコントロールを許容する、といった具合です。また、このトポロジーを導入する場合、境界が必ずしも明確でないため、アーキテクトによる強力なガイダンスが必要になる点も注意が必要です（例えば、ビジネスケイパビリティがさまざまなバリューストリーム間で共有される場合など）。さらに、このトポロジーを採用する場合、バリューチェーンの境界を越えたデータのみがデータプロダクトに入るため、それほどデータ駆動型とは呼べなくなります。

3.1.5　粗視化ドメイントポロジー

組織によっては、合併や買収を経て、組織の規模を拡大してきたところもあります。このような組織は、時には数百、数千のアプリケーションやシステムからなる複雑な構造を持っています。このような複雑な構造の中には、さまざまなレベルのガバナンス、連携、分業が存在します。自律的に運営される部分もあります。また、グループとして統合される部分もあります。

このような組織のシステムは、一般的に大規模です。個々のドメインは数十から数百のアプリケーションを抱えているかもしれません。この**粗視化**トポロジーを抽象的に示したのが図3-7です。

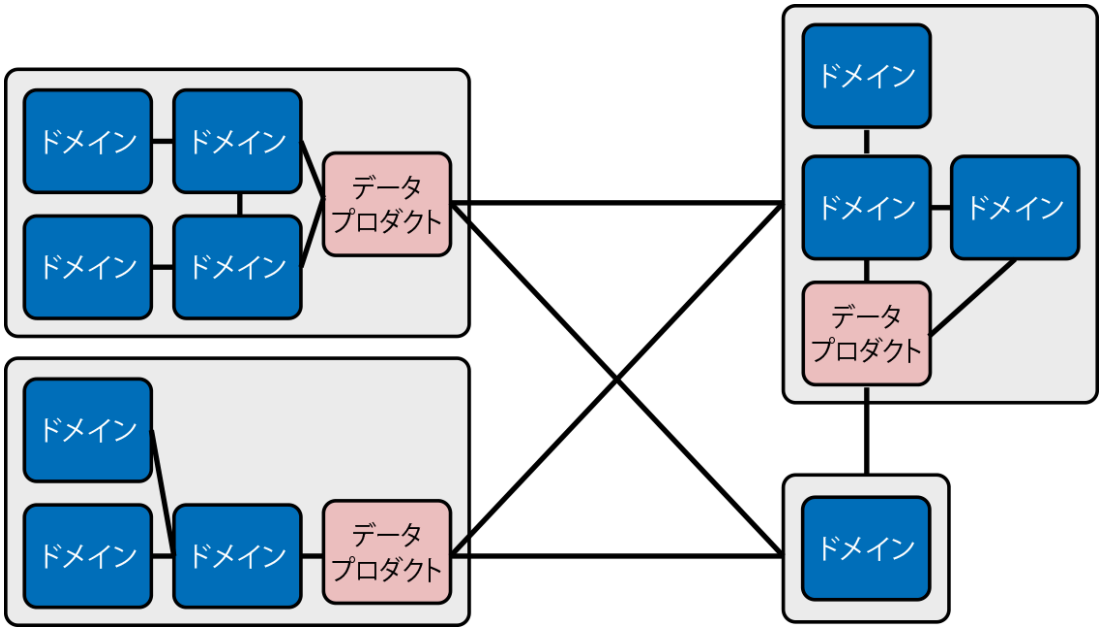

図3-7　粗視化ドメイントポロジー：ドメインは、例えば、事業部門、地域、ビジネスケイパビリティなどの周りに粗く配置されている

粗視化ドメイントポロジーの難しい点は、境界が必ずしも明確ではないことです。ドメインはほかのドメインと重なったり、より大きなドメインの中に存在したりします。さらに、アプリケーションとデータは常にビジネス目標と整合

しているとは限りません。多くの場合、ドメイン境界は、組織や地域の視点に基づいて決められています。このようなグループ分けがされていると、誰がデータを管理し、それを正しく管理するためにどのようなガバナンスルールを適用すべきかについて、政治的な対立を生み出すかもしれません。

また、アプリケーションとデータを粗視化アプローチで管理する場合、機能の重複が生じるという課題もあります。粗視化された各ドメインは、データの導入、変換、流通に独自のデータプラットフォームを使用している場合が多いでしょう。このように多くのプラットフォームを実装するアプローチは、重複を招きます。例えば、データ品質管理やマスターデータ管理は企業全体で必要とされるはずです。連合型プラットフォームのアプローチだと、さまざまなデータプラットフォーム上にデータ品質とMDMを多数実装することになるかもしれません。すべてのプラットフォームでこれらのサービスを一貫して実装するには、強力なコラボレーションとガイダンスが必要です。組織が大きくなればなるほど、この作業は難しくなります。

このマルチプラットフォームのアプローチは往々にして多くの問題を引き起こします。例えば、データプラットフォームとドメインをどのように調整すれば良いのでしょうか。同じデータプラットフォームに接続されているドメインは、直接データを共有しても良いのでしょうか。同じデータが異なるプラットフォームで必要とされる場合、データ要件が重なっている場合はどのように対処すれば良いのでしょうか。ドメインやプラットフォームインスタンス間でデータを効率的に流通させるにはどうすれば良いのでしょうか。このような問題に適切に対処するには、プラットフォームサービスを実装する前に、2章で説明したビジネスケイパビリティモデリングを使用して、組織を適切にドメインに分割することが重要です。その後、アプリケーションとデータのオーナーシップを確立し、データプロダクトの作成と流通に関する強力なガイダンスを策定します。

ドメイン指向データウェアハウス

一部の組織は、標準データモデル（**スーパーモデル**）を用いて、大規模ドメイン内のすべてのパーティを1つの言語で接続し、大規模で粗視化されたデータウェアハウスを実装することによりドメイン指向の実現を目指します。このアプローチでは、データウェアハウスやデータレイクは生データを取得・保持し、それを直接、調和されたドメインモデルに変換します。調和後、元のドメインは運用アプリケーションなどの消費ドメインに直接データを提供します。

このように、データウェアハウスが多くのドメインのストレージとして機能する場合、いくつか注意すべき点があります。

- あるユースケースのために特定のロジックを実装する一方で、ほかのドメインに汎用的なデータを直接提供することは非常に困難です。これらは対照的な関心事であり、1つの設計にまとめることは簡単ではありません。例えば、あるコンシューマのためにはデータを抽象化する一方で、ほかのユースケース固有の複雑な処理を追加しなければならないかもしれません。このようなことを同じデータモデルに実装した場合、最終的には作業がしにくい設計になってしまいます。
- 生データのみを保持し、それを直接調和させるということは、運用レポーティングや分析を容易には行えなくなるということを意味します。データは、密に結合され作業するには複雑すぎる受信時の生データか、運用ユースケースにとって無意味に調和されたデータのどちらかになるからです。
- すべてのユースケースが同じ基盤に結合されるため、変更に伴うリスクは大幅に増加します。単一のソースからのデータにしか興味のないコンシューマでも、ほかのシステムと結合しており、その影響を受ける可能性があります。データはまず調和レイヤーで結合され、それから提供されるからです。

さまざまなビジネス上の関心事を持つ複数ドメインのために、大規模なドメインデータウェアハウスのようなデータベースモデルを共有することは、最終的には深刻な問題につながることになるので絶対に避けなければなりません。

組織が粗視化ドメイントポロジーを検討している場合、よりきめ細かく非中央集権的なモデルへの移行を計画すべきです。粗視化アプローチでは高度な自律性を伴うため、より強力なガバナンスポリシーとセルフサービスデータプラットフォーム機能が必要となります。例えば、データプロダクトを登録し、検索可能にするには、ドメインが選択したテクノロジーや相互運用性に応じた具体的なガイダンスが必要になるでしょう。ガイダンスがなければ、ドメイン間でさまざまなアプローチが乱立してしまい、情報の可視性が損なわれ、コストが増大してしまいます。

ここで説明した粗視化ドメイントポロジーは、データメッシュの実装からはかけ離れています。通常、ドメイン境界は設定されません。これは、システム間の結合を増やし、より大きなサイロを生み出す危険性があります。また、境界が粗視化されており、データプロダクトが中間システムや、サイロ、ポイント

ツーポイントのインタフェースを経由して流通するため、データオーナーシップが曖昧になり、データの出所を特定することが難しくなります。このようなリスクを避けるためには、明確な境界線を設定し、テクノロジーサービス、メタデータ、相互運用性の標準を強力に策定する必要があります。また、一意のデータのみを利用し、一意のドメインコンテキストを使い、元のソースから直接データを取り込むなどの原則を守ってください。

3.1.6　粗視化・部分統制ドメイントポロジー

大規模で複雑な組織の中には、前述したような粗視化境界の間に、中央集権型のデータ流通レイヤーを構築することで、複雑さ、ピアツーピアのデータ流通、相互運用性における問題を解決しようとしている場合もあります。このようなトポロジーの概要図を図3-8に示します。

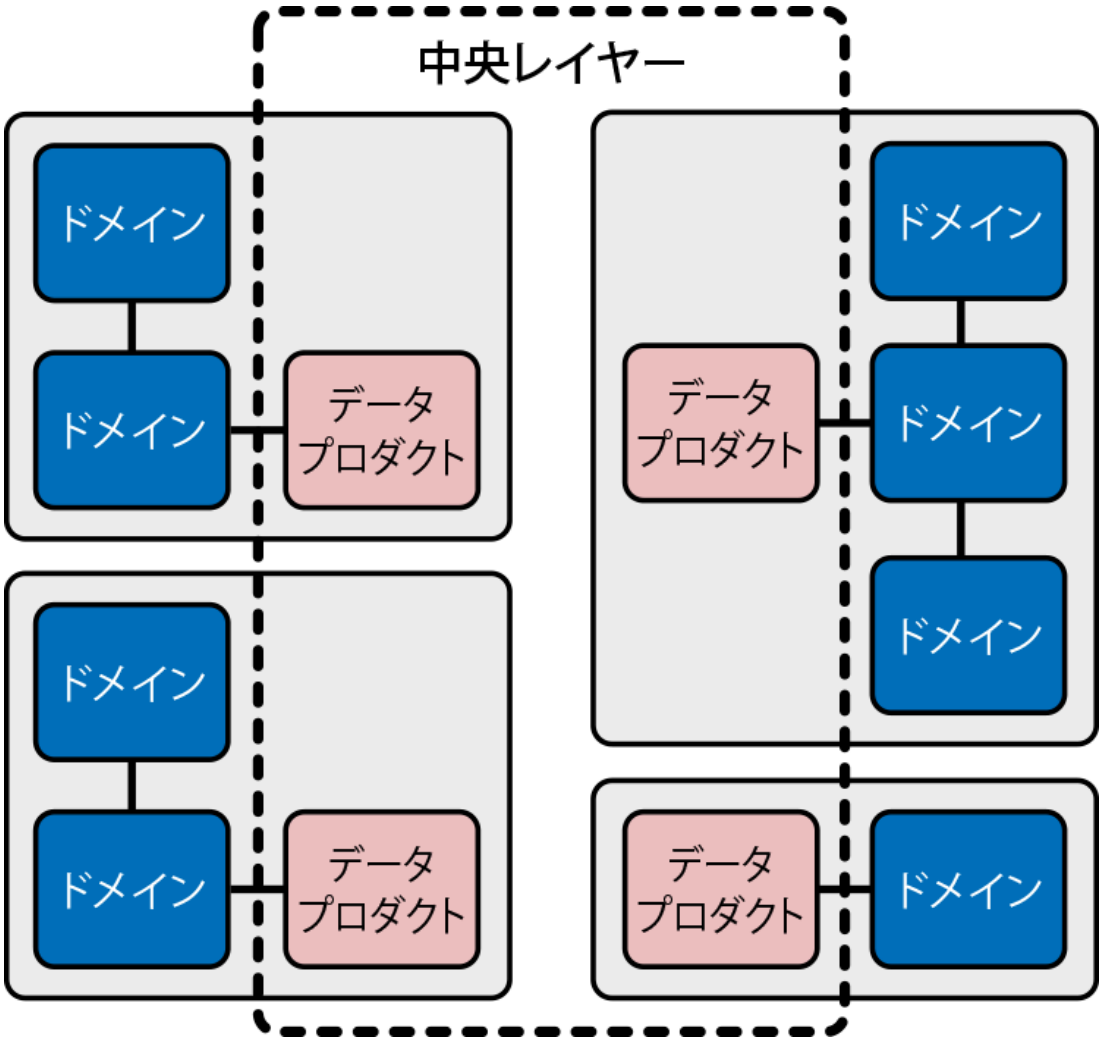

図3-8　粗視化・部分統制ドメイントポロジー：粗視化された配置にする一方で、境界を越えるデータ流通を統制する

このトポロジーでは、チームや組織が、データを発行・消費する際に、データ流通プラットフォームやマーケットプレースを利用するようにします。このトポロジーでは、統制ドメイントポロジーの特徴をいくつか取り入れていますが、より大きな境界の中で、より緩やかにコントロールします。

粗視化トポロジーでは、データプラットフォームチームに高いレベルの成熟度を必要とします。すべてのコンポーネントはセルフサービスである必要があり、中央集権型の流通レイヤーと各ドメインのプラットフォームを適切に統合しなければなりません。メタデータ管理、ガバナンス標準、ポリシーは非常に重要です。中央のアーキテクチャとガバナンスチームに強い権限がなければ、これらのアーキテクチャは失敗するおそれがあります。

3.1.7　中央集権型ドメイントポロジー

非中央集権化に難色を示す組織もあります。あらゆる組織が、データプロダクト作成用のエンジニアリングツールをすべてのチームに提供できるわけではありません。すべての組織に数百人ものデータエンジニアがいるわけではありません。組織のすべてのチームが、複雑なデータモデリング技術や、変更データキャプチャ、Kubernetes、Pythonのノートブックに精通しているわけではありません。 企業は、その規模や、ビジネス上のニーズ、既存のアーキテクチャによって、異なるアプローチが必要となります。

筆者が関わってきた多くの組織では、ハブアンドスポークネットワークトポロジーアーキテクチャを導入し、データプラットフォームなどすべての共通インフラストラクチャーをプラットフォームチームが中央集権型で管理していました。汎用的なデータサービスについては、中央チームがほかのチームと密に連携してデータの導入や消費を実現していました。データプロダクトの考え方は、チームがデータオーナーシップを管理することにより実現されます。これには、トラブルシューティング、データ品質の問題の解決、インジェストの問題へのサポートも含まれます。しかし、複雑なエンジニアリングに関しては成熟曲線が存在するため、中央チームがデータの導入、パイプラインの設定、トレーニング、ベストプラクティスに関してチームを指導することも少なくありません。ほかのチームに必要なスキルがない場合、中央チームがデータオーナーシップを持つ場合もあります。

一般的に、同じような成熟度曲線がデータを消費する側にも存在します。多くの場合、チームはデータの設定や、インジェスト、変換に関して共通のリソースプールを利用することで、知識やヘルプを得ています。得られた知見をもと

に、データパイプラインやデータインジェスト用フレームワークなどのサービスを改善し、より柔軟に構成できるようにします。効率性の悪さに対処し、時間の観点からセルフサービスで実現することと、新しいデータの導入を助けることとを調整しつづけます。

ケイパビリティが重複してしまう問題に対処するため、企業は多くの場合、個々のチームによって管理されるコンポーネントを多数配備するよりも、単一の中央集権型の（ドメイン指向）データプラットフォームを選択します。これはまた、例えばデータレイクハウスアーキテクチャと重なる部分も少なくありません[†4]。このような場合、中央の共有データプラットフォームが存在し、このプラットフォームでデータのインジェストや、保存、変換、出力を単一の論理データレイクで処理します。データの整理と、ソースシステムやドメインとの整合は、中央プラットフォーム内で行われます。図3-9に、単一のプラットフォームインスタンスと、ドメイン整合されたデータオーナーシップを持つようなアーキテクチャの参照モデルを示します。

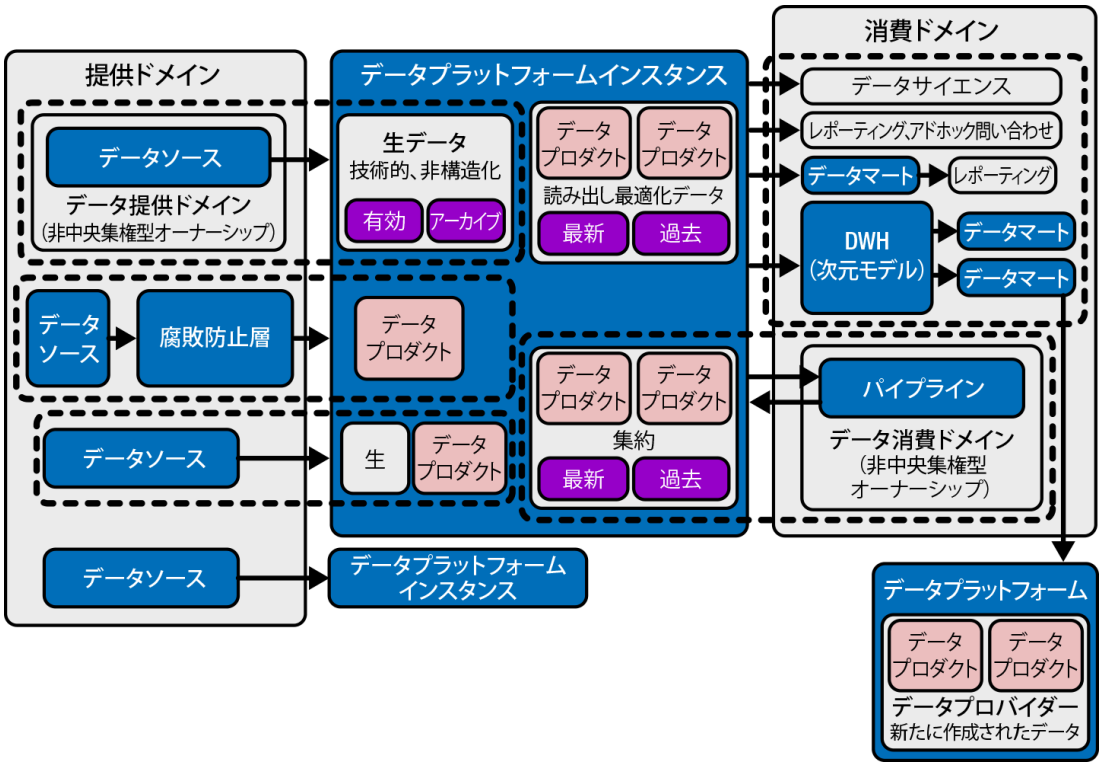

図3-9　中央集権型ドメイントポロジーを使用して、ドメインが共有プラットフォームインスタンス上でどのように連携するかを示す参照モデル

[†4] データレイクハウス（https://oreil.ly/I1dqO）は、データレイクの柔軟性やコスト効率、規模と、データウェアハウスのデータ管理およびACIDトラン

ザクションを組み合わせたアーキテクチャ設計であり、すべてのデータに対してビジネスインテリジェンス（BI）と機械学習（ML）を行えます。

この設計では、ドメイン間でデータを流通させるために、1つの論理ストレージレイヤーがあります。図3-9では**データプラットフォームインスタンス**と名付けられたこのレイヤーは、すべてのチーム間を分離するポイントとして機能します。通常、提供ドメイン側では、ストレージアカウント、バケット、コンテナ、フォルダを使用して、プラットフォーム内でデータを物理的に分離することでセグメント化と隔離を実現します。データを導入する際、データは生データや、キュレーション済みデータなどいくつかの段階を経てレイヤー化され処理されるのが一般的です。最終結果（よくデータプロダクトと呼ばれるもの）は、ソースシステムにあるデータをリッチ化し、クレンジングしたものです。多くの場合、組織はセルフサービスを利用可能にし、メタデータ駆動型インジェストのような技術を活用することで、このプロセスを推進します。

消費ドメイン側では、コンシューマのニーズに応じてさまざまな消費パターンを見ることになるでしょう。あるユースケース（例えばデータサイエンスやレポーティング）ではデータを直接消費し、別のユースケースでは新たに作成されたデータマートやデータウェアハウスにデータをプッシュします。セマンティックレイヤーとデータ仮想化は、データを仮想的または論理的なデータグループにまとめるためによく利用されます。これらの新たに作成されたデータセットはしばしばデータプロダクトとも呼ばれ、さまざまなデータコンシューマのユースケースに対応したものとなります。提供側と同じように、消費側でもセルフサービスモデルをよく見かけます。組織はカタログを使ってエンドユーザーがデータを簡単に要求できるようにし、データを消費し再発行するためのツールを提供します。

企業全体のデータモデルや企業全体のデータ調和を使用することにおいては、中央集権型ドメイントポロジーは、ほかのトポロジーとは対照的です。企業全体のデータモデリングについては、その複雑さと開発に必要な時間の長さから否定的なイメージがありますが、データの再利用性と標準化に関する問題に対処するために、企業全体にデータモデリングを適用している組織は少なくありません。このような場合、新たにモデル化されたデータセットは、ソースシステム整合やデータコンシューマ整合とは別に、個別に管理されるゾーンに配置されます。このゾーンのデータは通常、中央チームが所有します。このエンタープライズデータは高度に統制され、適切にドキュメント化されます。どの程度のエンタープライズ標準が存在するかは、組織によってさまざまです。ほと

んどの組織は、一部のデータ（例えば、最も重要で最も頻繁に使用される次元のみ）をモデル化する一方、すべてのデータをモデル化しようとする組織もあります。これらの「エンタープライズデータプロダクト」の消費原則もまた異なります。チームが常にこれらのデータプロダクトを消費するように義務付けている組織もあれば、ドメインが消費するデータを選択できる、より柔軟なアプローチを取っている組織もあります。エンタープライズレベルでの一貫性に取り組む際の問題点については、10章で扱います。

このトポロジーでは中央集権化のレベルが高いため、小規模な組織では、あるドメインから別のドメインへデータを移動することなく、大規模な履歴データセットを参照したり、データのコヒーレンス（データが論理的に接続され、相互に一貫している度合い）、MDMの効率性、異なるチーム間で計算リソースを共有することによるコスト削減などの問題に対処したりすることができます。同時に、データメッシュアーキテクチャのベストプラクティスも継承しています。例えば、データプロダクトの考え方、ドメイン指向かつドメイン整合性のあるデータオーナーシップ、セルフサービス機能、データガバナンスなどのことです。

3.1.8　正しいトポロジーの選択

中央集権化と非中央集権化のバランスをうまくとることは、多くの組織にとってジレンマが残るところです。データの中央集権管理から非中央集権管理へのシフトは、組織にとってデータ管理の意味を完全に定義しなおすことになります。データ管理を全領域にわたって中央集権的に行う代わりに、中央チームは強力なデータガバナンスを確立する責任を負います。この章で説明したドメイントポロジーを使えば、どのレベルの中央集権化や非中央集権化を採用できるか、どのように境界線を設定できるか、アーキテクチャ内のドメインがどのように相互作用し、接続されるかを理解できることでしょう。

これらのドメイントポロジーのうち1つしか実装できないわけではありません。組織は、どのようなトレードオフが必要かによって、さまざまなトポロジーを組み合わせたり、混在させたりできます。例えば、**図3-10**では、比較的柔軟なガバナンスモデルと、より厳格で中央集権的なモデルが組み合わされています。いくつかのドメインは完全な連合型で運用され、ほかのドメインはハブアンドスポーク型や中央集権型モデルで構成されています。

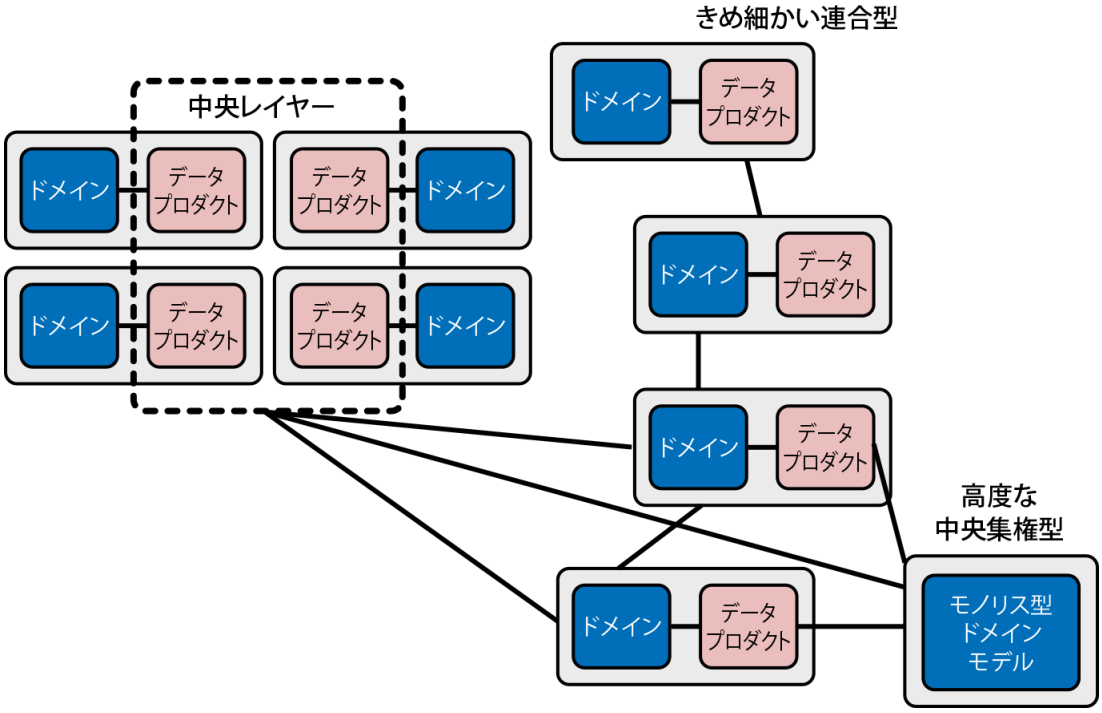

図3-10　さまざまなドメイントポロジーを1つの組織内で組み合わせる

また、最初に選択したトポロジーがそのまま最終的なトポロジーになるというのも誤解です。ドメインがグループ化され相互接続されることにおいて、完全なバランスは存在しません。例えば宇宙について考えてみましょう。最初は衝突、融合、崩壊がありました。その後、宇宙はより調和がとれた状態になり、重力によってかたまりが生じました。その結果、変化の少ない穏やかな状態になっています。大規模なアーキテクチャの設計もこれと似ています。このようにさまざまな段階を経ることになるので、最初に完璧な設計をしようとしてはなりません。それよりも、「小さく始めて早く失敗し、早く成功するために早く失敗してください」。

結論をまとめると、ドメイントポロジーを選択する場合には、可能な限りきめ細かく境界を設定するようにしてください。データ駆動型になるということは、データを積極的に（再）利用できるようにするということだからです。ドメイン境界を粗くしすぎると、多くのアプリケーション間で望ましくない結合を作ることになり、データの再利用性が損なわれます。データがビジネスケイパビリティや機能上の関心事の境界を越える場合は、分離するようにしてください。このベストプラクティスは、ドメインの内部アーキテクチャであれば、密結合しても問題がないという意味でもあります。ただし、境界を越える場合、ドメインは分離し、ほかのドメインとデータを共有するには、読み出し最適化されたデータを流通しなければなりません。

ドメイントポロジーの構造を定義するとき、その基礎となるテクノロジーアーキテクチャも設計し、実装しなければなりません。ここまでのところでは、解決空間について触れていませんが、これらのトポロジーをテクノロジーアーキテクチャとして実装したときにどのようになるか考えてみましょう。隔離やモジュール性を適用できるのでしょうか。例えば、ドメインを論理的にグループ化することは可能なのでしょうか。もし可能なら、プラットフォームインフラストラクチャーを共有するのに適したものは何でしょうか。

おすすめは、クラウドを活用したフレームワークを利用することです。このようなフレームワークは、規範となるガイダンス、ベストプラクティス、ドキュメント、オープンソースのブループリントを提供してくれます。ビジネスとテクノロジーの目標を整合させてくれるので、正しい道を選択しやすくなります。次の節では、このようなフレームワークがどのように機能し、ドメイントポロジーのテクノロジー実装がどのようなものになるのかを見ていきます。

3.2　ランディングゾーントポロジー：解決空間の管理

クラウドインフラストラクチャー上に大規模なアーキテクチャを構築する場合、クラウド導入フレームワークを使用し、ランディングゾーンを使用する方法がおすすめです。簡単に言えば、**ランディングゾーン**とは、セキュリティポリシー、コンプライアンスガイドライン、ベストプラクティスに準拠して事前に設定されたプロジェクト、インフラストラクチャー、環境を自動的に作成する、標準的な一連のビルディングブロックのことです。これらのビルディングブロックには通常、セキュリティ、ガバナンス、自動化、ネットワーク、ストレージ、計算能力、監査とロギング、データ管理のためのサービスが含まれます。ランディングゾーンにはさまざまな形式があり、設定によって調整することができます。組織によっては、できるだけ多くのシナリオを実現するために、ランディングゾーンを汎用的なものにする場合もあります。また、ランディングゾーンを特定用途に特化する組織もあります。例えば、データ関連のシナリオに最適化されたランディングゾーンを用意するなどです。

ランディングゾーンは、ドメイン用にあらかじめ設定された環境を提供し、コードを使ってプロビジョニングされます。オープンソースのブループリントとベストプラクティスは、すべての主要なクラウドプロバイダーが提供しており、以下のようなものがあります。

- アマゾンのAWSクラウド導入フレームワーク（https://oreil.ly/FIeR4）

- Azure向けのMicrosoftクラウド導入フレームワーク（https://oreil.ly/MuL4F）
- Google Cloud導入フレームワーク（https://oreil.ly/1Hj6J）

> データランディングゾーンのブループリントにおけるベストプラクティスは、オープンな中央リポジトリでこれらをホストすることです。運用をオープンにすることで、ドメインチームの貢献と参加を得ることができます。同時に、中央チームが監督責任を負い、すべての実装における標準化を徹底します。

ランディングゾーンは、大規模アーキテクチャの実装を容易にします。ランディングゾーンを利用することで、チームに提供するサービスを標準化できるからです。ランディングゾーンは、配備の容易さや、一貫した命名規則、ポリシーの適用、拡張性、セキュリティ、バックアップとディザスタリカバリ、法規制への準拠を提供してくれます。また、新たなワークロードがアーキテクチャに追加される際にも、あらかじめ適切なインフラストラクチャーが用意されていることを担保します。

一般的に、クラウド導入フレームワークは2つのビルディングブロックで構成されており、これらはすべての配備において基本的な選択肢となります。

データ管理ランディングゾーン
これはアーキテクチャの基盤となるものです。セキュリティコンポーネント、ファイアウォール、監視ソリューション、エンドツーエンドのデータ管理サービスなど、ワークロードを監視・管理するためのすべての機能が含まれます。データカタログ、データリネージ、APIカタログ、MDMサービス、中央メタデータリポジトリなどが含まれます。原則として、このランディングゾーンは常にドメインとは独立したものになります。

データランディングゾーン（または、単にランディングゾーン）
これらは、ドメインのワークロードまたはユースケースをホストするアカウントやサブスクリプションです。ドメインが特定のアプリケーションを開発できるように、主要な機能が含まれています。データ関連のユースケースの場合、ランディングゾーンは、統合、レポーティング、機械学習、デ

ータベース、ストレージソリューション、ランタイム、分析処理用の計算プール、オーケストレーションなどのサービスを提供します。

クラウド導入フレームワークでは、実装するデータアーキテクチャの種類について必ずしも明示されているわけではありません。さまざまなクラウドプロバイダーのドキュメントやベストプラクティスを参照すれば、これらのフレームワークは、（エンタープライズ）データウェアハウス、データレイク、データレイクハウス、データファブリック、データメッシュなど、一般的なデータ管理や分析ソリューションに使用できることがわかるでしょう。つまり、前述のドメイントポロジーのいずれにも使用できます。それでは、これらのフレームワークがどのようにアーキテクチャ設計をサポートするのかを見ていきましょう。さまざまな配備オプションを検討し、それぞれの設計における注意点を説明します。この節の最後では、オーシャニック航空のアーキテクチャ配備を、ブループリントがどのようにサポートできるかを紹介し、さらに具体的にしていきます。

ランディングゾーンにはさまざまな種類があります。ランディングゾーンが**ランディングゾーン**または**アプリケーションランディングゾーン**と呼ばれる場合は、より汎用的で、幅広いアプリケーションやワークロードに使用されることが多いです。ランディングゾーンが**データランディングゾーン**と呼ばれる場合は、データと分析処理に特化しています。**コントロールゾーン**、**管理ゾーン**、**プラットフォームゾーン**の場合は、中央集権型サービスや共有サービスの管理用です。

3.2.1　単一データランディングゾーン

データアーキテクチャを構築する際の最も単純な配備設計では、図3-11に示すように、1つの（データ）管理ランディングゾーンと1つのデータランディングゾーンを使用します。このような最小限の構成は、強力なコントロールと標準化が必要な場合、新規導入の初期段階である場合、シンプルであることが望ま

しい場合に適しています。すべてのデータ管理関連サービスは管理ランディングゾーン内に中央集権化されます。同じようにすべてのデータ関連ドメインが中央集権化されます。ドメインは同じ単一のデータランディングゾーンに存在します。ここで、ランディングゾーンは、単一のサブスクリプションやアカウントを意味しており、標準的なサービスセットが含まれます。

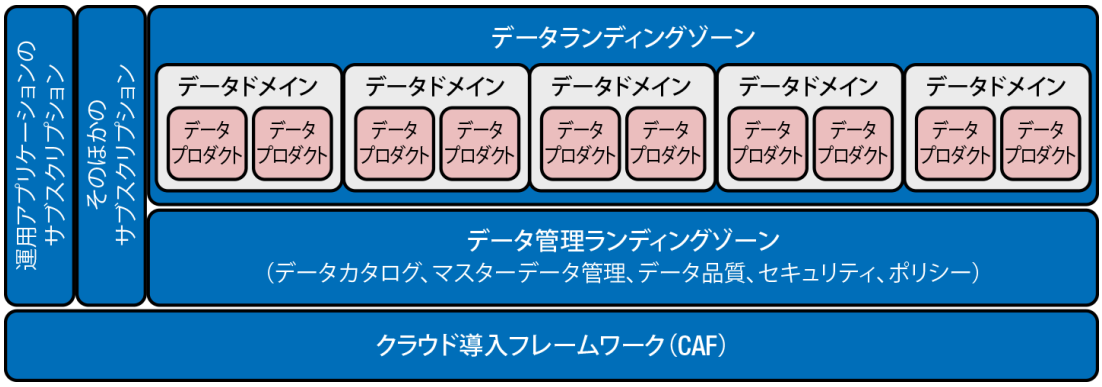

図3-11　最小推奨構成は、1つのデータ管理ランディングゾーンと1つのデータランディングゾーンで構成される

このような設計の基本となるのは、一般的には、以下のような目的を実現するためです。

- ドメインがデータをエンドツーエンドで管理するための基盤を確立することが目的です。これにはリネージ、データ品質、セキュリティ、データのカタログ化と共有などの、強力かつ一貫したガバナンスが含まれます。
- 提供ドメインは、それぞれ、ほかのドメインから独立した独自のデータとテクノロジーサービスを使って、複数のデータプロダクトを所有・運用します。同じように、消費ドメインは、それぞれ分析とレポーティングのために独自のツール群を運用します。
- データドメインは、プロバイダー、コンシューマ、あるいはその両方の役割を果たします。どのような役割を果たすかによって、マッピングされるサービスは増減します。
- データレイクハウスのアプローチは、チームがデータプロダクトを構築する際のベストプラクティスと考えられています。データプロバイダードメインは、自らが管理、所有、運用する一連のパイプラインを通じて、それぞれのデータレイクサービスにデータをインジェストします。

このアーキテクチャは、解決空間ではどのようになるのでしょうか。2章のオーシャニック航空の例に戻って説明しましょう。**図3-12**を見れば、社内のさまざまなドメインがどのように連携し、データを利用しているかが理解できるで

しょう。設計のそれぞれの領域は、一連の標準サービスを提供する再利用可能なブループリントです。

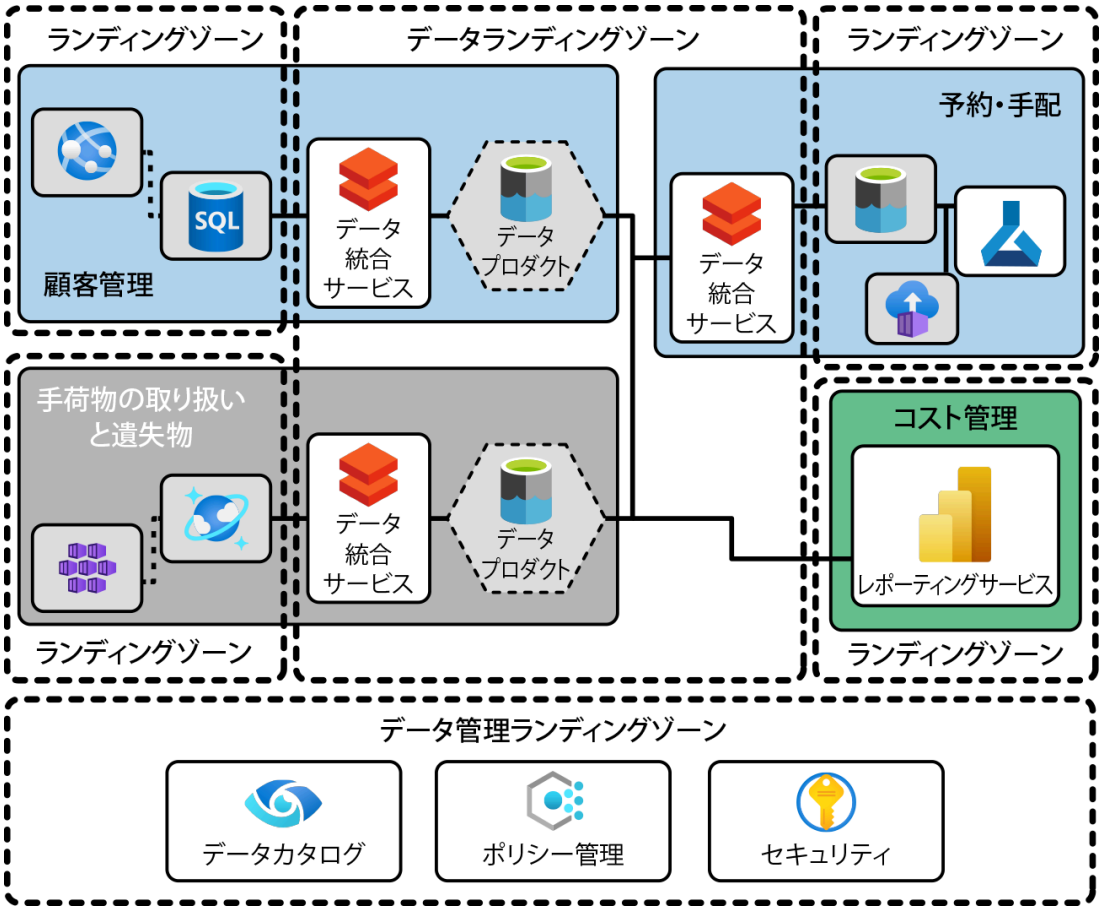

図3-12　オーシャニック航空内のさまざまなドメインがどのように運用されるか

左側と右側には、通常のランディングゾーンを通じてプロビジョニングされる運用アプリケーションが並んでいます。それぞれのドメインは、自律性、必要となる柔軟性、地理的位置、セキュリティ要件などの理由から、専用のランディングゾーンを持っています。

中央には、単一のデータランディングゾーンによって提供されるデータ関連サービスが並んでいます。このゾーンから提供されるサービスは、データプロバイダーまたはデータコンシューマのどちらか一方に整合していますが、すべてのドメインにとって汎用的なものです。データ提供サービスは、ドメインがデータをインジェストし、保存し、変換し、提供することをサポートします。データ消費サービスは、ドメインが分析アプリケーションを構築し、データ駆動型の意思決定のための分析処理をサポートします。

一番下にはデータ管理ランディングゾーンがあります。このゾーンは、データをエンドツーエンドで管理するために、データカタログなどの中央集権的な

（ドメインに無関係な）サービスをすべて管理します。

> 組織によっては、「自社のアーキテクチャを1つのランディングゾーンにまとめることはできないのでしょうか」という疑問が湧いていることでしょう。確かに、すべてのデータ管理とデータ関連サービスを1つの巨大なランディングゾーンにまとめることは技術的には可能です。しかし、そのようにすると将来の拡張性が失われてしまいます。したがって、ベストプラクティスとしては、常に（最低でも）1つのデータ管理ゾーンと、もう1つ別のデータランディングゾーンから始めることです。

図3-12では、レポーティングサービスをデータランディングゾーンではなく、一般的なランディングゾーンに配置することにしました。これは設計上の判断です。4章と11章で再度取り上げます。また、ドメイン境界の一部が、通常のランディングゾーンと（共有）データランディングゾーンにまたがっています。これも設計上の判断です。

別の構成として、ドメインごとに、アプリケーションサービスとデータサービスの両方を備えた汎用ランディングゾーンを用意することもできます。このような設計は、すべてのサービスをそれぞれのドメインに整合させ、ドメインの自律性を高めるのに適しています。しかし、ランディングゾーンとブループリントを標準化するのが難しいというデメリットがあります。なぜなら、ビジネスドメインとそのアプリケーションは、これまで学んできたように、常に一意であり異なるからです。

実用的な例はひとまず置いておいて、トポロジーの議論を始めた時点に話を戻しましょう。単一のランディングゾーンをプロビジョニングする場合、ランディングゾーン内でサービスをどのように構成するのがベストか迷うかもしれません。一連のサービスを配備する際の一般的なベストプラクティスは、例えばタグやリソースグループを使用して、それらを論理的にグループ化することです。それぞれのドメインチームは、このリソースグループを使用して、データソリューションをエンドツーエンドで管理します。サービスをこのようにグル

ープ化してマッピングする理由は、すべてのサービスがプロビジョニング、更新、破棄という共通のライフサイクルを持つからです。さらに、グループ化されたサービスは、すべて同じドメインに属するため、同じセキュリティコントロールを継承します。

サービスとドメインを整合させるには、別の方法もあります。サービスを排他的にドメインにマッピングするのではなく、ドメイン間でサービスを共有することもできます。サービスを共有するのは、主にセキュリティ、プロセスの単純化、コスト削減のためです。例えば、データ処理に高性能なデータベースと変換フレームワークを使用している状況を想像してください。すべてのドメインに多数の（高価な）サービスをプロビジョニングする代わりに、ドメイン間で同じ一連のサービスを共有するようにします。場合によっては、これはコスト削減につながるでしょう。また、作業方法が統一され、コントロールや管理がしやすくなるかもしれません。

サービスを共有する場合、一般的に、隔離やセキュリティは、一段下のレベル（サービスの内部）で行われることを理解しておいてください。サービスを共有するかどうかを決める際に筆者がお勧めする方法は、サービスをカテゴリー別に分類し、それぞれのカテゴリーや種類ごとに運用モデルを決定する方法です。多くの場合、コスト効率や、実装コスト、柔軟性、セキュリティ、管理オーバーヘッドなどの間でトレードオフを行う必要があります。

3.2.1.1　データプロダクトの構成

同じようなトレードオフをデータプロダクトについても考慮しなければなりません。ストレージアカウントや、データレイクサービス、データベースは、データプロダクトの保存と管理によく使われます。これらのサービスを使用する場合、それぞれのドメインは1つのインスタンスにマッピングされ、それぞれのインスタンスは単一ドメインの一連のデータプロダクトをホストします。**図3-13**に、この設計の例を示します。

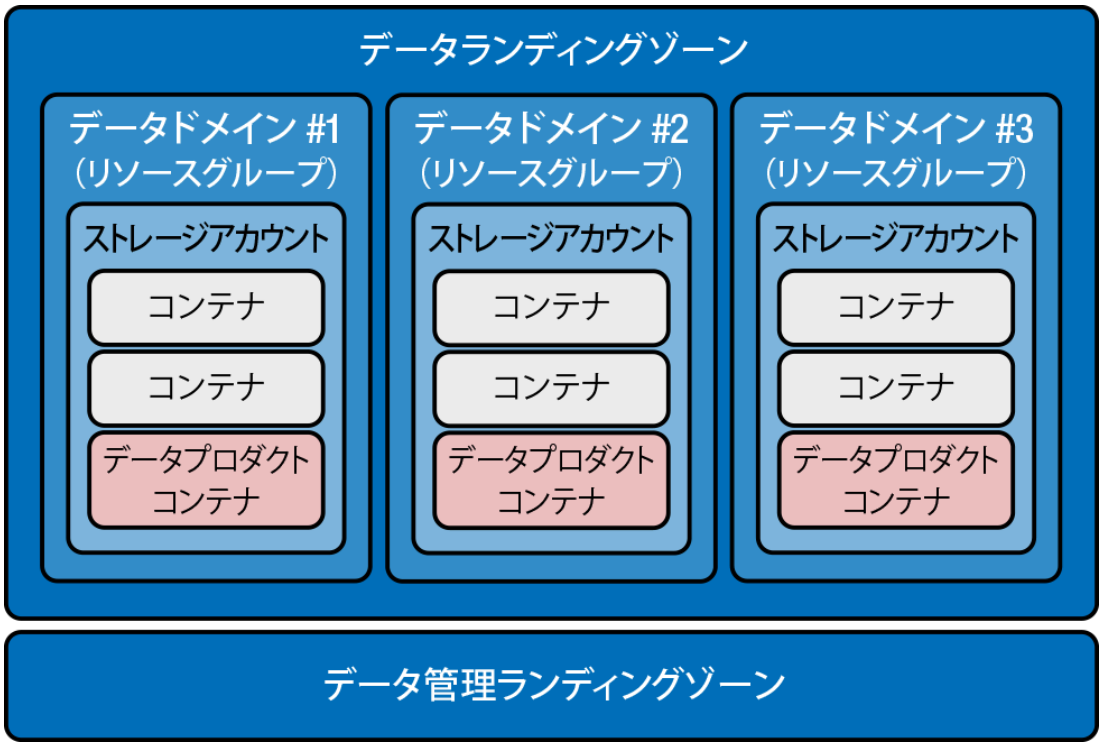

図3-13　すべてのデータプロダクトは、ドメインのリソースに整合したコンテナ内で保持される

この構成により、ドメインはデータプロダクトを管理する際に、より多くの自由度と柔軟性を享受できるようになります。例えば、それぞれのドメインはデータのステージングや階層化方法を自由に選択することができます。この設計では、ドメインごとに異なるセキュリティモデルや、特化した機能、クォータ、サービスタグを使用することもできます。さらに、それぞれのドメインが性能制限を独自に設定できるため、性能が予測しやすくなります。

AWS、Azure、GCPは、それぞれ異なる種類の階層を使ってリソースを管理しています。AWSは、組織、組織単位、アカウント、リソースの4つのレベルを使用します。Azureは、ルート、管理グループ、サブスクリプション、リソースグループ、リソースの5つのレベルを使用します。GCPも同じように、組織、フォルダ、プロジェクト、リソースの4つのレベルを使用します。詳しくは、Petteri Kivimäki氏のブログ記事（https://oreil.ly/oPdAL）を参照してください。

さらに、設計を変更して、ストレージサービスの単一インスタンスを共有することもできます。この場合、データプロダクトの分離は、サービス自体の内部の一段深いレベル（コンテナや、バケット、フォルダ、論理データベースなど）で行われるのが一般的です。このような設計の例を図3-14に示します。

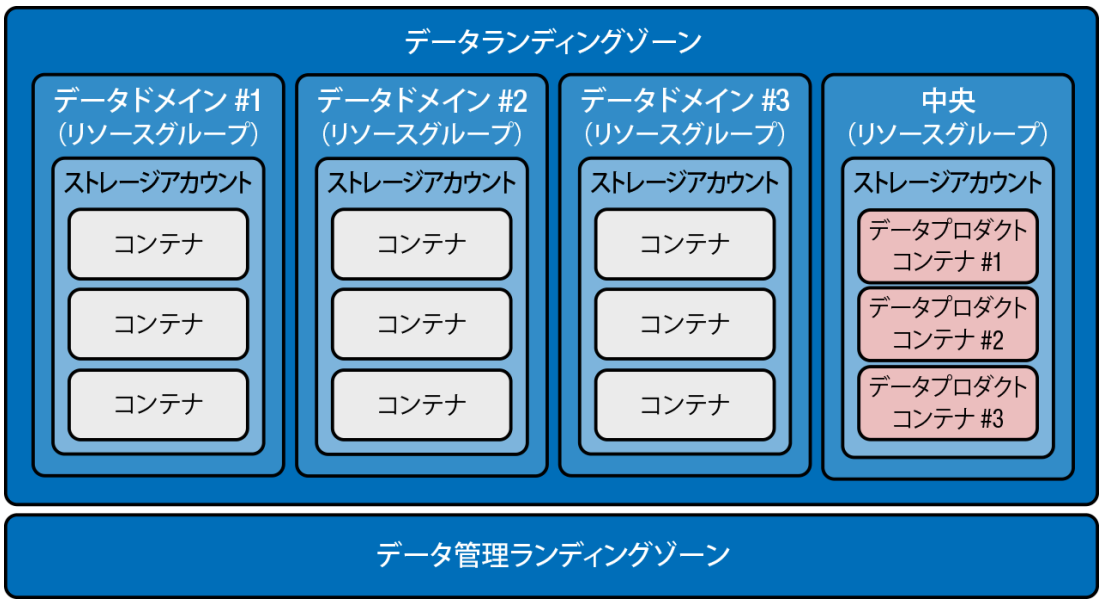

図3-14　データプロダクトは、中央集権型の共有ストレージアカウントインスタンスを使用し、データランディングゾーン内でプロビジョニングされ、コンテナを使って分離される

いくつかの理由から、このアプローチの方が良い場合もあります。第一に、すべてのドメインに対して一貫した階層構造を簡単に適用できるので、ドメインのセキュリティ上の責任が軽減され、サービス管理の効率が向上します。第二

に、すべてのデータプロダクトが中央に格納され、互いに密に連携しているため、大規模なデータ処理タスクを効率的に処理できます。また、中央サービスによる一律のセキュリティや厳格なガバナンスモデルが必要な際にも、この方法が適している場合があります。例えば、データプロダクトにユーザーのアクセス権を自動的に割り当てるようなデータ契約サービスは、さまざまなデータプロダクトが同じストレージレイヤーを共有している方が開発しやすくなります。この点については4章で詳しく説明します。

ドメイン間でストレージサービスを共有することにはデメリットもあります。例えば、アイテムや帯域幅がドメイン間で共有されるため、パフォーマンスや構成に制約が生じる場合があります。また、1つのインスタンスしか使わないため、それぞれのドメインに対して特定の機能を柔軟にオン・オフすることができず、ドメイン間の結合が密になり、ドメインが遵守しなければならないことがらも増えます。

図3-15は中央集権型設計を少し変形したものです。以前の設計に比べて異なるのは、データプロダクトの中央管理をデータ管理ランディングゾーンに移した点です。

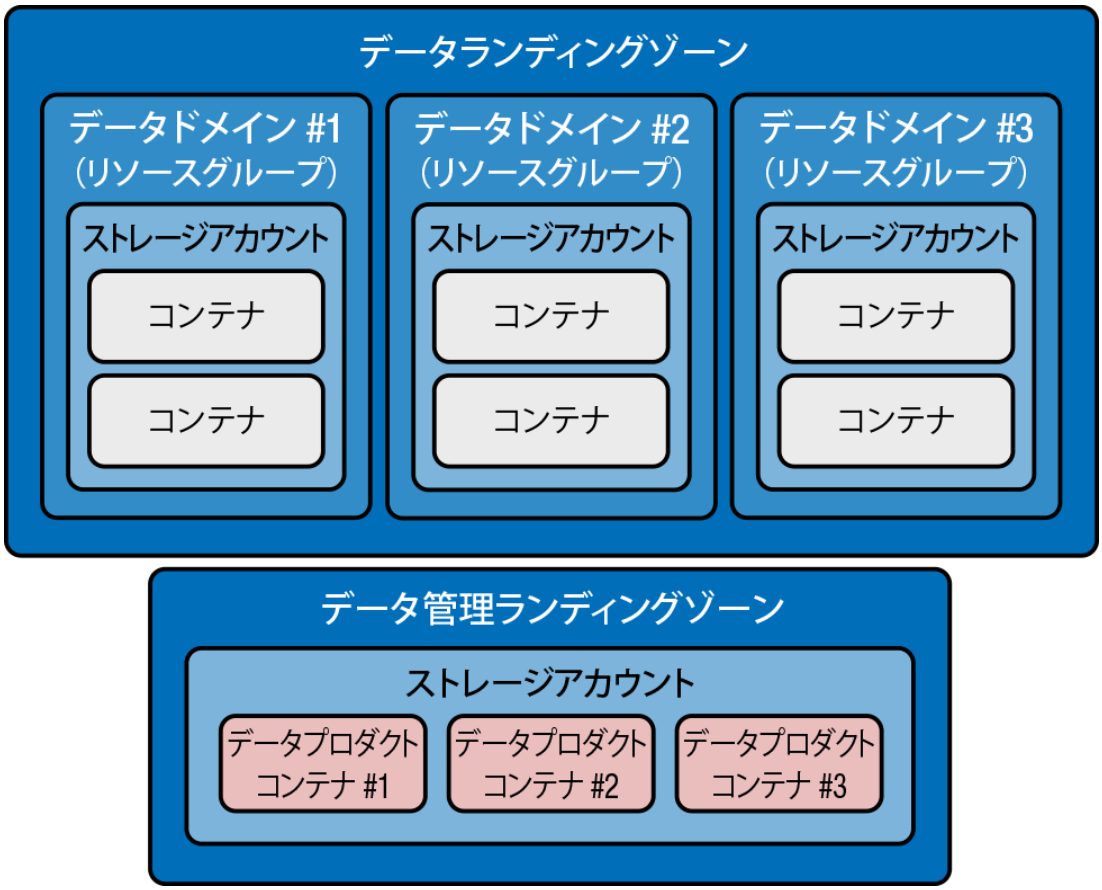

図3-15　データ管理ランディングゾーン内でプロビジョニングされる中央共有ストレージアカウントインスタンスを利用して、データプロダクトはコンテナ

によって分離される

MDMやデータ品質サービスなど、中央集権型で管理されたサービスにデータを移動させる場合、このシナリオのように、データプロダクト管理にデータ管理ランディングゾーンを使用する方法が適しているかもしれません。このようなケースでは、データと、データを処理する場所は近い方が良い場合もあります。

すべてのドメインのデータプロダクトをどのように管理するかについて、どれか一つだけを選択する必要はありません。前述のアプローチのいずれか、またはすべてを組み合わせ、単一ランディングゾーントポロジーや本章で説明するほかのトポロジーと混在させることができます。例えば、ドメインの大部分には専用のストレージアカウントを提供し、残りのドメインに対してはリソースを共有するようにもできます。適切なトレードオフを行うことが重要です。

3.2.1.2　単一ランディングゾーンの大規模化

データプロダクト管理はひとまず置いておいて、データランディングゾーンに話を戻しましょう。単一のデータランディングゾーンを使用する理由は、標準化を行い、物事をシンプルに保つことにあります。単一のクラウドプロバイダーだけを利用し、すべてのリソースを単一のリージョンでプロビジョニングし、複雑な課金やアカウント構造の要件がなく、すべてのサービスやポリシーをすべてのドメインにわたって標準化したい（標準化する必要がある）場合に適しています。このような形式で簡素化と標準化を行う場合、ドメインチーム間で対立する要件はない（またはほとんどない）はずです。全体のブループリントに変更を加える際には、関係するすべてのチームがリリース計画に整合しなければなりません。

単一のデータランディングゾーンを使用したからといって、大規模化できないというわけではありません。より多くのドメインやデータプロダクトをアーキテクチャに導入する必要がある場合は、定義済みのサービスを使用してリソー

スグループをすぐに追加することができます。セルフサービスと自動化を活用すれば、さらに大規模化できます。大規模化する際には、データドメインは前章で紹介したデータ管理の原則に従う必要があるという点に注意してください。

単一のデータランディングゾーンのトポロジーは、小規模な組織やグリーンフィールドのプロジェクト（新規プロジェクト）、あるいは強力な標準化が望ましい場合に有用です。また、複雑なものを構築する計画がある場合でも、その組織の出発点としても適しています。この場合、将来的には複数のランディングゾーンを使用して、よりきめ細かい完全連合型の実装に移行することを前提としています。

3.2.2　ソース整合ランディングゾーンとコンシューマ整合ランディングゾーン

先ほどのトポロジーの議論では、ほかのクラウドサービスのアカウントやオンプレミスのアプリケーションは考慮していませんでした。単一ランディングゾーンでは、対照的な関心事を同時に管理することが難しくなる場合があるからです。このような課題に対処するための、より優れた設計を検討してみましょう。

データ導入は、大規模なデータ活用の中でも非常に難しい部分です。複雑な統合に対処するために、特別なサービスが必要となることが多いです。導入のための統合は、データ消費のための統合とは異なります。というのも、ソースシステムは驚くほど複雑になる可能性があるからです。これに対応するために、2つのランディングゾーンを使用することにして、以前の設計を少し変更します。1つはソースシステム側で複雑なサービスを管理し、もう1つはコンシューマ側に標準化を施したものです。**図3-16**に、このトポロジーを示しています。

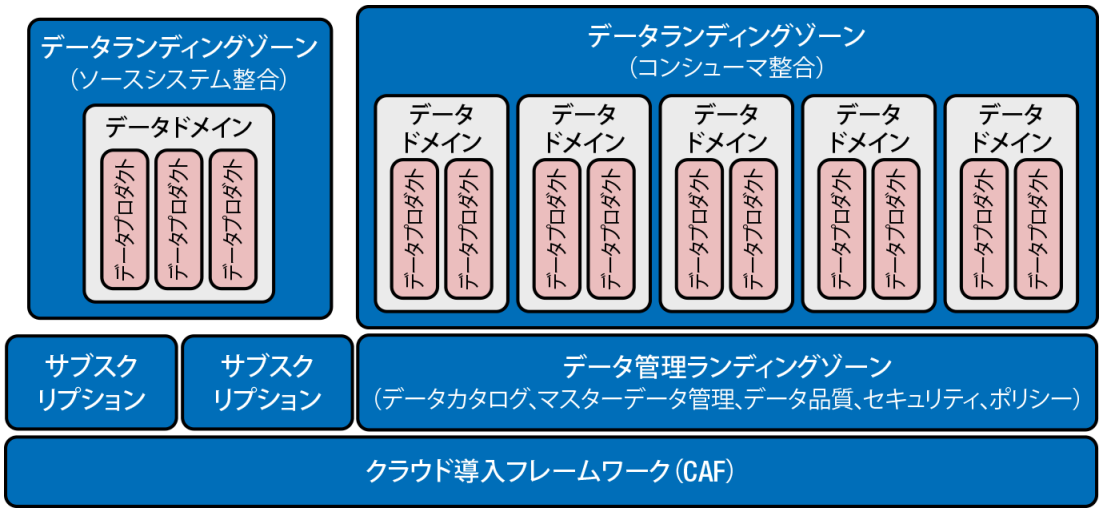

図3-16　ソースシステム整合ランディングゾーンと、コンシューマ整合ランディングゾーンを分離したトポロジーの方が、複雑な統合の課題に対処しやすい場合がある

左側のランディングゾーンでは、データの取得やデータプロダクトの構築を支援するデータサービスを提供します。これらのサービスには、例えば、変更データキャプチャサービス、APIサービス、レガシーシステム用の特殊なコネクタなどがあります。一般的に、オンプレミス、ほかのクラウドベース環境、外部API、SaaSベンダーなど、さまざまな場所からデータを取得します。このランディングゾーンでは、サービスがドメイン間で共有され、基盤となる運用アプリケーションとの結合も増えるため、一般的にオーバーヘッドも大きくなります。右側のランディングゾーンは消費に最適化されており、データを価値に変えることに特化したサービスを提供します。これらのサービスには、例えば機械学習やレポーティングなどが含まれます。

データを提供する側と消費する側を分離する際には、ドメイン指向のデータオーナーシップの原則すべてを、データドメインが遵守することを推奨します。ドメインはデータオーナーシップを持ち、ほかのドメインにデータを直接流通させることができます。このアーキテクチャの配備モデルは、前述したハイブリッドまたは部分連合型トポロジーと完全に整合させることもできます。また、きめ細かい完全な連合型モデルと整合させることもできます。後者の場合、ドメインの役割を検証し、提供または消費のいずれかを選択します。ドメインが両方の役割を果たす場合、アーキテクチャの両側にそのドメインが存在することになります。

3.2.3　ハブデータランディングゾーン

次に検討するトポロジーは、ハブを使用するものです。このハブが、ランディングゾーンの間に位置し、接続と流通の中心として機能します。ハブはドメインが直接データを流通させないようにすることで、ドメイン間を分離します。すべてのデータは、この中央のハブを経由して流れます。ハブは、ある意味、「3.2.1.1　データプロダクトの構成」で説明した、中央集権的に管理されたストレージサービスのスケールアウト版です。相違点は、これらのストレージサービスが、専用のランディングゾーンにグループ化されている点です。

ハブを使用するメリットは、すべてのデータの動きを把握できることです。さらに、ハブアンドスポークアーキテクチャではネットワークをより効果的に利用できます。データプロダクトは一度だけコピーされ、その後ハブから消費ドメインに配信されます。このアプローチは、図3-17に見られるように、自然に統制ドメイントポロジーに準拠します。データは中央の論理エンティティや機関を経由して流通します。

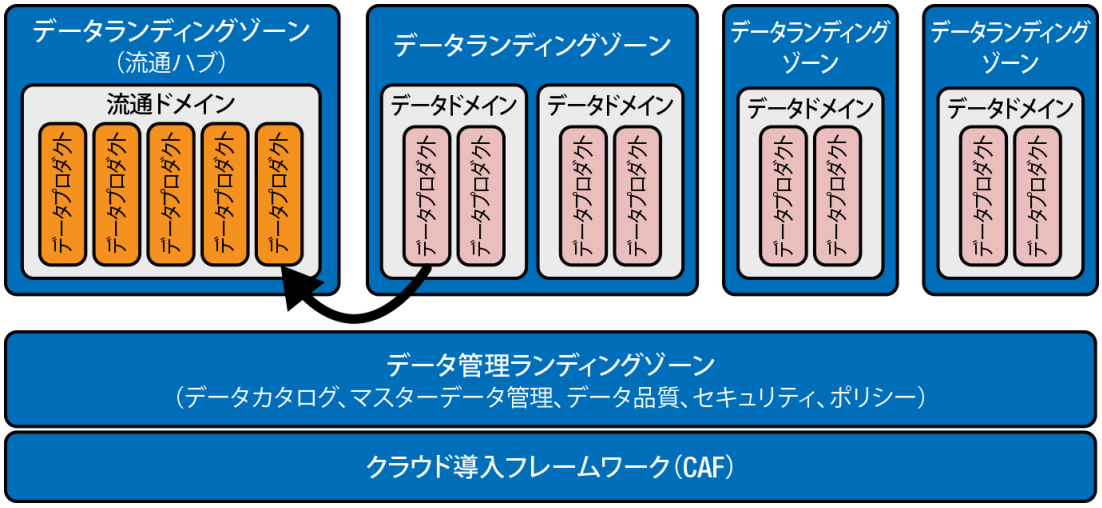

図3-17　このモデルでは、ハブは中央流通ポイントとして機能する

一般的に、ハブの設計は、ほかのデータランディングゾーンとは異なります。ドメインに依存せず、中央チームが所有し、どのデータがどのドメインに流通するかを統括します。ハブの内部には、一般的に中央集権型のストレージサービスがあります。この内部では、データはドメインごとに論理的に管理・隔離されていて統合されていません。ハブはデータの提供や消費を円滑にするための（セルフサービス型の）サービスも備えているのが普通です。

ハブを使えば、データの仮想化も実現できます。データを複製したり、ハブでデータプロダクトをプロビジョニングしたりするかわりに、標準サービスを使用して、仮想化されたデータプロダクトをドメインが提供できます。このような仮想化により、データアクセス管理全体を単純化したり、ドメインがさまざ

まなサービスを使用している場合、多種多様な状況での技術的な複雑さを隠蔽したりできます。

このトポロジーは、さまざまなドメインに流通し消費されるデータを管理する必要がある場合に適した方法です。また、多数のカスタマー間でデータを共有する場合、ハブの方が効率的であるため、多数の大規模なデータコンシューマに大量の過去データを提供する場合にも効果的な選択肢となります。ハブモデルは、金融業界、法規制のある環境、グローバル規模で事業を展開し、地域をまたがるデータの動きを完全に管理する必要がある組織でよく見られます。

3.2.4　複数データランディングゾーン

規模が大きくなれば、複数のデータランディングゾーンを設けた方が、業務や関心事を分離することができて良いでしょう。図3-18は、このようなデータアーキテクチャの例を示しています。

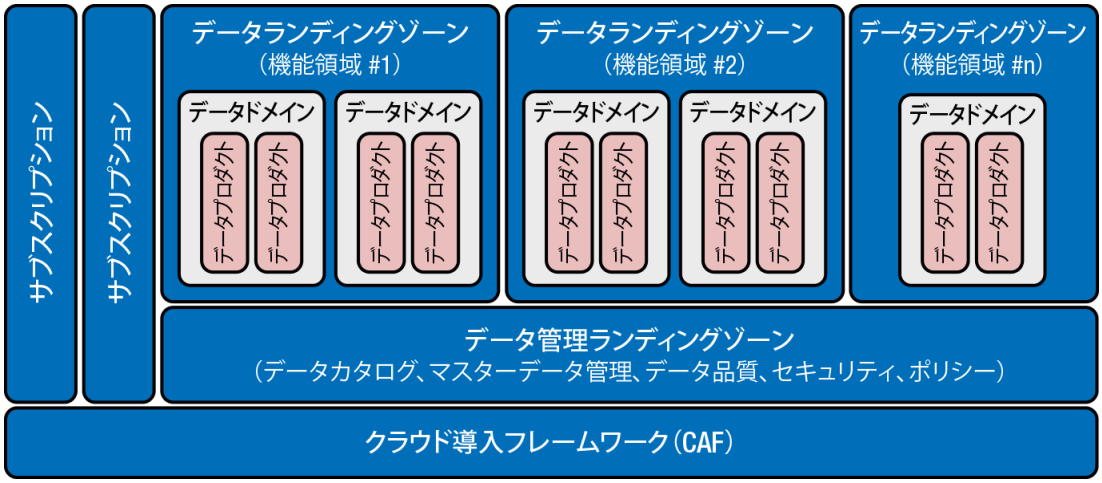

図3-18　複数のデータランディングゾーンにより、関心事の分離が容易になる

どのデータドメインを論理的にグループ化し、データランディングゾーンを共用するかは、複数の観点で決められます。主な要因を見てみましょう。

セキュリティコントロール
アプリケーションによって、異なるセキュリティプロファイルを持ち、異なるコントロールポリシーとメカニズムを必要とするかもしれません。

データ共有の凝集性と効率性
大規模なデータ処理タスクがランディングゾーン内でどのように管理されるかを検討する必要があります。このような種類のワークロードでは、データを近くに格納しなければならないことが多いからです。

地域

地域や地理的な境界ごとに、同じビジネスケイパビリティやブループリントが実装される場合があります。地域が複数あれば、必ず複数のランディングゾーンが生じるはずです。

隔離

ランディングゾーンは、セキュリティ上の保護の単位となります。潜在的なリスクやセキュリティ上の脅威は、ほかのランディングゾーンに影響を与えることなく、ランディングゾーン内に封じ込めなければなりません。あるランディングゾーンをほかのランディングゾーンから隔離するというセキュリティニーズもありえます。データの隔離についても同様です。データストアをランディングゾーンに隔離することで、そのデータストアにアクセスし管理できる人を制限することができます。これにより、個人データの漏洩を防ぎ、例えばGDPRへの準拠につながります。

柔軟性と変化のペース

ドメイン内のイノベーションの速度に差がある場合も考えられます。こうした破壊的な変革は、アジリティよりも安定性を重視するほかのドメインとは相反するかもしれません。

バリューストリームとビジネスプロセス

事業部門や製品によって、目的やプロセスが異なる場合があります。ビジネス固有のニーズに対応するために、さまざまなランディングゾーンを設定する必要があります。

売却

一部のケイパビリティを売却したり分離したりする可能性がある場合、ほかのドメインの共有サービスと密に統合するのは得策ではないでしょう。

チーム間の違い

チームによって責任も必要なリソースも異なります。高いスキルを持ち、成熟したチームは、一般的に独自のサービスやインフラストラクチャーを運用したがります。

コスト管理

企業の中には、クラウドインフラストラクチャーにチャージバック／ショーバックモデルを導入し、使用したキャパシティに応じてコストを分割・管理したいと考えているところもあります。

アロケーションの制限

一部のクラウドでは、サブスクリプションやアカウントごとの制限があります。ワークロードを異なるランディングゾーンに分割することで、制限をより厳密に設定することができ、さまざまなリソースを必要とするアプリケーションが、意図したとおりに動作しなくなるのを防ぐことができます。

実験と学習

実験は失敗する可能性があるので、ほかのワークロードとは別に管理したほうがよいでしょう。

政治的な事情

残念ながら、政治的な壁も理由になり得ます。

SLA

可用性と継続性の要件が相反する場合、結果として追加サービスが必要になる場合があります。

これらの項目がランディングゾーンの設計にどのような影響を与えるか、例を挙げて示してみましょう。クラウドで新しいアーキテクチャを構築する状況を想像してください。最初のリソースを配備するとき、どのクラウドリージョンにアプリケーションを配備するかを決定しなければなりません。例えば、米国を拠点とする場合、最初のランディングゾーンとアプリケーションはUSAリージョンに配備するでしょう。さて、しばらくしてヨーロッパにビジネスを拡大する必要が生じたとします。地理的な境界（データレジデンシー）があるため、ヨーロッパのクラウドリージョン内に2つ目のデータランディングゾーンをプロビジョニングする必要があります。ヨーロッパに事業を拡大した後、ヨーロッパ市場向けのイノベーションのために多額の投資を行います。このような破壊的でリスクの高い事業活動の性質上、これらのリソースを、ほかのすべてのリソースとは別に管理するために、第3のデータランディングゾーンをプロビジョニングすることを決定します。この投資により、さらに事業を拡大します。今度は、これまでとは異なるレベルの信頼関係を持つ別の企業とパートナーシップを組むことになりました。このパートナーを既存の事業活動と統合しないことにしたので、第4のデータランディングゾーンを構築します。

このように複数のデータランディングゾーンをプロビジョニングすることで、凝集性と効率性に基づいてドメインをグループ化することができます。その際、すべてのデータランディングゾーンが、データ管理のために同一の監査とコントロールを遵守するようにしてください。すべてのランディングゾーンをつなぐリンクは、管理ランディングゾーンです。この中央に位置する論理エンティティは、どのドメインがどこにあり、どのようなデータを作成し、流通させ、使用しているかを監視しなければなりません。

それぞれのランディングゾーンは単独で存在するわけではありません。ハブや、データレイクやストレージサービスを共有するほかのランディングゾーンに接続することができます。この接続によって、ドメインが企業全体でコラボレーションできるようになります。例えば、共有ストレージサービスやデータ仮想化を活用して、ドメインがほかのドメインからデータを複製することなく直接読み出せるようにすることができます。

複数のデータランディングゾーンを配備する場合、それぞれの管理にはオーバーヘッドが存在することを理解しておいてください。一般的なランディングゾーンでは、アカウントの設定、サービスの関連付け、ランディングゾーンとほかのゾーンの関連付けなどが必要です。データランディングゾーンの数を`n`とすると、これらのゾーン内のすべてのストレージアカウントとそのほかのサービスのために、少なくとも`n`個のネットワーク接続ポイントが必要になる可能性があります。このため、管理する必要のある設定項目の数が、指数関数的に増加することになるかもしれません。つまり、ランディングゾーンの数と構成管理のオーバーヘッドには強い相関関係があるということです。

3.2.5　複数データ管理ランディングゾーン

最後に紹介するトポロジーは、グローバル規模で事業を展開する大企業向けのものです。例えば、数百または数千のアプリケーションを使用するような、非常に専門性の高い多くの部門を持つ組織向けです。このような場合、組織の各部門間でデータ管理要件が異なることが考えられます。この課題に対処するために、複数の管理ランディングゾーンとデータランディングゾーンを1つのアーキテクチャにまとめて導入します。このような設計を**図3-19**に示します。

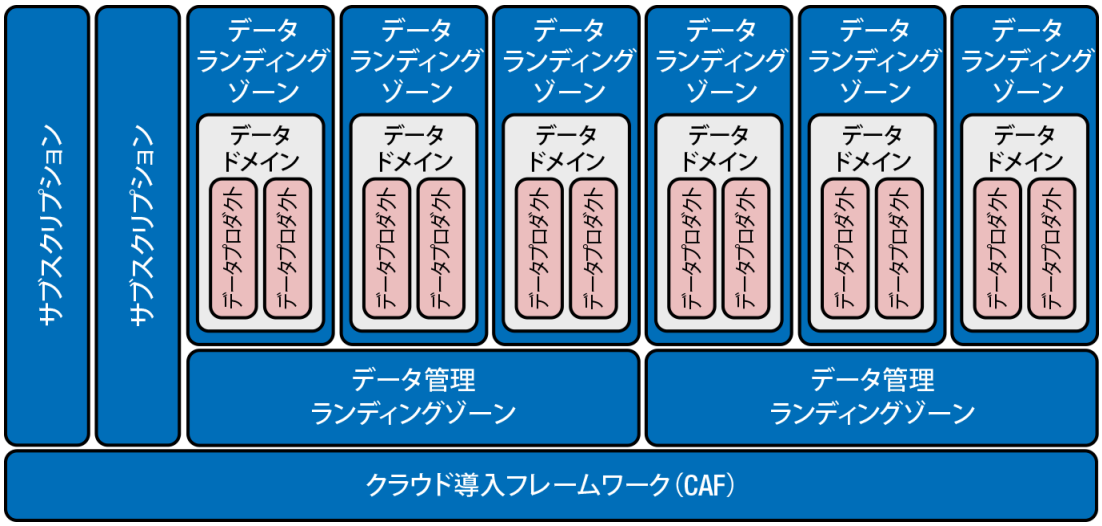

図3-19　大企業では、さまざまな管理ランディングゾーンが必要になる場合がある

ランディングゾーンを追加すると、管理や統合のオーバーヘッドを生むので、それが妥当かどうかを考慮した上で判断しなければなりません。例えば、組織の（メタ）データを組織外の誰にも見られてはならない場合や、組織のさまざまな部署が独自の作業方法、ポリシー、セキュリティ標準、データ管理方法などを使用してインフラストラクチャーを管理している場合などには、管理ランディングゾーンの追加は理にかなっているでしょう。また、組織のデータを管

理するさまざまなMDMサービスがある場合にも、このトポロジーを使用するとよいでしょう。

ここまでの節で説明した大規模化の機構を使うようにすれば、アーキテクチャと組織は制約を受けることなく段階的に成長することができます。ランディングゾーンやドメインを追加することで拡張でき、複数のブループリントを提供することで複雑さとコストを管理できます。具体的な例を通して、この仕組みがどのように機能するかを見てみましょう。

3.2.6　実践的なランディングゾーンの例

2章では、ビジネスケイパビリティとドメインについて説明しました。ケイパビリティをどのように構成し、境界を設定するかを学ぶための例として、架空の企業であるオーシャニック航空を使用しました。大規模なアーキテクチャを設計するために、ドメイントポロジーとデータランディングゾーンをどのように活用できるかを学びました。ここで学んだランディングゾーンを、オーシャニック航空という架空の企業に対して適用した場合、アーキテクチャはどのようなものになるでしょうか。図3-20に示した設計を紐解くことで、この点を明らかにしていきましょう。

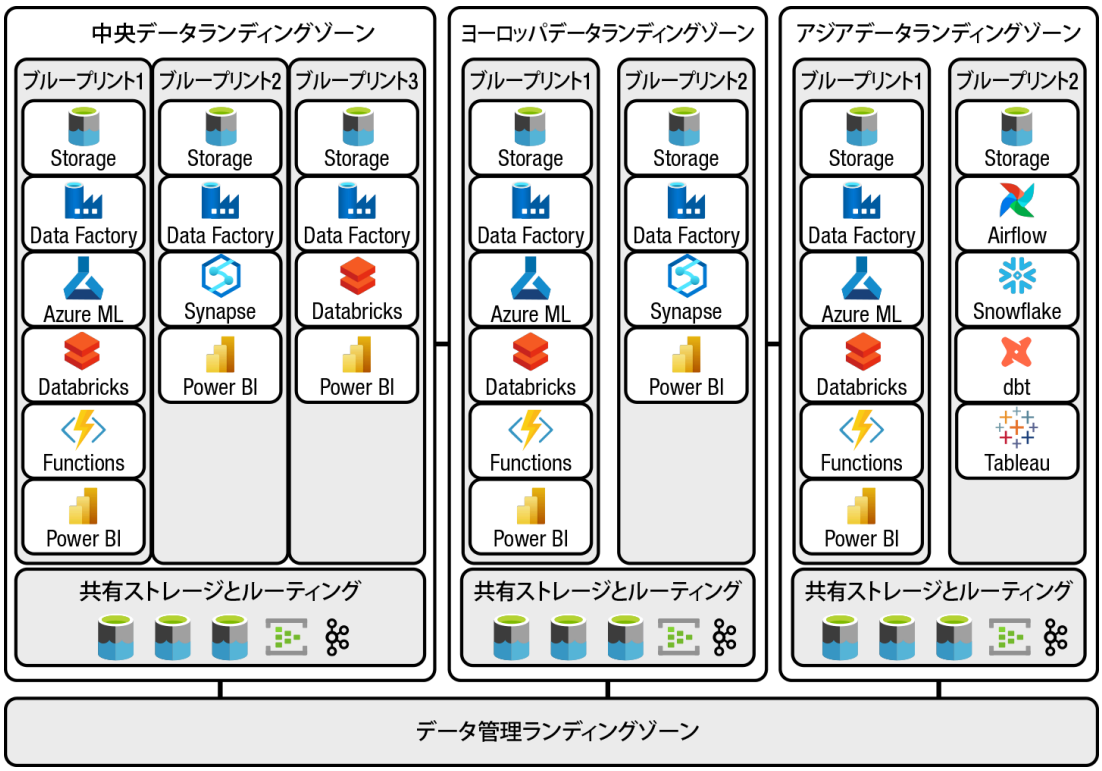

図3-20　複数のランディングゾーンを持つオーシャニック航空のアーキテクチャ

ご覧の通り、3つのデータランディングゾーンと1つのデータ管理ランディングゾーンがあります。このように、複数のデータランディングゾーンを実装するのは、オーシャニック航空が地理的な観点からグループ分けを行い、ドメインをクラスタ化することにしたからです。ドメインは世界中のさまざまな地域に分散しており、低遅延と安定性を保証するために、それぞれのドメインは地理的な位置にできるだけ近いところにデータを置きたいと考えています。そこで、オーシャニック航空は3つのランディングゾーンを設けました。アメリカ（「中央」）と、ヨーロッパとアジアです。

図3-20は、Amadeus（https://amadeus.com）のデータアーキテクチャの実装にヒントを得たものです。この企業はインフラストラクチャープロビジョニングプレーンを活用してアーキテクチャを拡張し、ドメインがデータの共有や利用に必要なインフラストラクチャープロビジョニングをセルフサービスで行えるようにしています。新たなデータドメインを追加するプロセスは、簡単なフォームに入力するだけで数分で完了します。詳細については、MicrosoftのCustomer Stories（https://oreil.ly/UmNQj）を参照してください。

このアーキテクチャでは、それぞれのデータランディングゾーンは、中央レイヤーでサポートされ共有ストレージサービスが提供されます。ここで非中央集権化よりも中央集権化を選択しているのは、オーシャニック航空が柔軟性やアジリティよりもコスト管理やデータの一貫性確保を重視しているためです。同社が事業を展開する地域内のドメインでは、データ検索やデータ品質の検証など、ドメイン横断的な業務が行われています。多くの場合、ドメイン間で大規模かつ履歴データセットの交換が必要になります。さらに、これらのデータセットを地理的に離れた拠点間で流通させる必要がある場合もあります。ドメイン間でデータを流通させるための中央集権的な論理エンティティを持つことで、このような流通に関する問題に対処できます。

オーシャニック航空では、それぞれのドメインの複雑でさまざまなニーズに対応するため、個々のランディングゾーンごとに複数のブループリントを開発することにしました。新たなドメインがデータランディングゾーンに加わるたびに、ブループリントが選択され、新しいアーキテクチャが作成されます。それぞれのブループリントは、基本的な要件に応じた参照設計として使用できます。ドメインが必要としないサービスは無効にします。さらに、ブループリントは特定のドメイン要件に応じて中央チームが拡張できます。例えば、特定のサービスやコンポーネントが不足している場合、ブループリントに追加して、ある特定のインスタンスを作成するようにできます。すべてのブループリントは、中央プラットフォームチームが管理するコードリポジトリ内で管理されます。このチームは、どのブループリントがどのドメインでどのような目的で使用されるかを管理します。

それぞれのブループリントは、一連のカスタムサービスを提供します。これらのブループリントにはそれぞれ違いがあります。例えば、アジアでは、異なるサービスのために分析を行うチームがあります。このようなニーズに対応するために、ほかの組織とは異なるサービスやツールを使用するブループリント2が作成されます。

最後に、オーシャニック航空は統一的なガバナンスを推進するため、共通のアーキテクチャを採用しています。すべてのブループリントインスタンスは、監視、コスト管理、セキュリティ、コントロールのために、ポリシーを使用しています。同じ種類のポリシーがすべてのデータランディングゾーンに適用され、それらはすべて基盤となるデータ管理ランディングゾーンに接続されています。つまり、ドメインチームは自動的に同じ監査、コントロール、データガバナンスの標準に準拠することになります。例えば、計算ガバナンスは、すべてのデータサービスを中央データカタログに接続することで自動的に実施されます。

3.3　まとめ

データ活用の旅は、技術的な旅だけでなく組織的な旅でもあります。理想的には、最初のワークロードやユースケースが開始されるよりもずっと前に、ドメインのガバナンスモデルを含め、戦略の構築に取りかからなければなりません。本章で説明したトポロジーは、データ活用の取り組みを始めるための出発点となります。しかし、実装を始める前に考慮すべきことがあります。どのトポロジーが適切かは、組織の状況によって異なります。小規模な組織や成熟度

が低い組織では、管理すべき複雑さを考慮すれば、データ管理には中央集権型のアプローチが適していることが多いでしょう。このような場合、よりシンプルで中央集権的なアプローチから始め、将来的には連合型や非中央集権型に進める方向で準備することをおすすめします。エンジニアリング能力のある大規模な組織では、この章で概説したさまざまなドメインのトポロジーを検討するとよいでしょう。

完全なドメイン指向アーキテクチャへの移行は、多くの問題やトレードオフ、懸念事項を伴うカルチャー的な変革であることを忘れないでください。この変革には、新しいカルチャーを確立することも必要です。本当に優秀なデータエンジニアはあまりに少ないため、実績のある「データチャンピオン」、「データチアリーダー」、「鼓舞するリーダー」の人材発掘を早くから始める必要があります。データランディングゾーン計画を推進するには、この分野で経験を積んだ人材を探すことです。

社内に投資し、既存の人材をITとビジネスの両方の知識を持つデータ専門家に育成する必要があります。Cレベルの経営陣と信頼関係を築き、トップレベルの支援者を見つけるには「エバンジェリスト」が必要です。また、そのほかのステークホルダーへの重要な広報役となるアンバサダーを探しましょう。組織カルチャーを変えるには、変革のための事例を作り上げる必要があります。データ世界における変革と、その変革がデータ管理に与える影響を受け入れられるように、組織の準備を始めましょう。これは、多くのキャンペーンを行い「魂を救済する」（光を示して、皆が正しい方向に進めるようにする）ことになりますが、物事が間違った方向に進んだときに踏みとどまるようにもしましょう。

連合型といっても、サービスやリソースを過度にプロビジョニングする必要はありません。ドメイン間でサービスを共有することで、アーキテクチャのコスト効率を高めたり、ドメイン間で標準的な作業方法を導入したりすることができます。データ管理アーキテクチャを実装するには、組織の（クラウド）インフラストラクチャーチームと密に連携する必要があります。多くの企業は、時間とコストのかかるプロセスを行っているにもかかわらず、価値あるものを提供できないでいます。このようになる必要はありません。主要なクラウドプロバイダーが提供しているような、ブループリントとランディングゾーンを使った段階的なアプローチを考えてみましょう。そうすることで、新しいデータドメインを迅速、安全、効果的、かつ標準化された方法で導入することができます。データ活用への旅を始める際には、データプラットフォームとクラウドの

チームを連携させるか、仮想チームを立ち上げてください。このようにすることで、さまざまなチーム間で絶え間ないコミュニケーションが発生してしまうことを避けることができます。

最初のランディングゾーンでは、コンセプトを証明するために、規模は小さくても全体的な構想のあるプロジェクトを選びましょう。8週間から16週間以内の完成を目指します。完璧である必要も、本番で使えるものである必要もありません。重要なステークホルダーやアンバサダーを呼んで、進捗状況を示し、レビューを実施してください。不測の事態を避けるため、定期的にフィードバックをもらいましょう。そして、そのフィードバックを踏まえて、設計を進化させます。また、フィードバックが正しいのであれば、一歩引いて方向性を変えることを恐れてはなりません。

データランディングゾーンとそれに関連するブループリントは常に進化しつづけます。ランディングゾーンの設計は、固定された成果物ではなく常に変わりつづけるものであるべきです。コンシューマがどんなものを手にするのか、はっきりと分かりやすくすることが重要です。何が中核となるのかに留意し、新たな要件を見直し、要件を追加する際には注意しましょう。また、セキュリティとコンプライアンスのための基本となるガイドラインも提供します。ランディングゾーンは隔離にも使用できます。標準サービスを使用してデータを管理する境界を設定すれば隔離できます。ゼロから環境を構築するのではなく、基本的な環境から使いはじめることをお勧めします。最初のうちは、あまりカスタマイズしないようにしてください。アーキテクチャをスケーラブルにするために、シンプルさと標準化を心がけましょう。自動化に重点を置いてください。自動化できないのであれば、使わないことも考えてみましょう。

次の章では、再びヘリコプターに乗り、データが作成されるアプリケーションやシステムのレベルまで高度を下げます。データコミュニティでの定義とは異なっているかもしれませんが、データプロダクトの概念について詳しく見ていきます。そして、データプロダクト管理について学びます。お楽しみに。