12章
理論の実践

最終章です。でも悲しまないでください。これからが本番です。この章では、最新のデータアーキテクチャを使った実例について、順を追って解説します。その過程で、本書を通して議論したさまざまなトピックを要約し、理論を実践に移す方法を説明します。全体的な計画、段階、順序の概要を示し、立ち上げと実行に必要なさまざまなケイパビリティを実装する方法を紹介します。

まず、データの旅について簡単に振り返り、中央集権型アプローチと非中央集権型アプローチのどちらから始めるべきかを考えます。そして、戦略的方向性の設定から、基盤の構築、ケイパビリティの高度化まで、データアーキテクチャを導入する段階を説明します。プロジェクトを成功に導くために重要となる、データ駆動型カルチャーの重要性については、ガバナンスやDataOpsの仕事の進め方を含めて議論します。次にエンタープライズアーキテクトが果たすべき役割について見ていきます。そして、この章の最後にいくつか言葉を添えて締めくくります。

12.1　データの旅についての振り返り

本書の目的は、データの旅をサポートすることです。しかし、その旅に出る前に、データ戦略を確認してください。1章で学んだように、小規模に始めるにせよ、大規模なユースケースを実装するにせよ、計画がなければ必ず失敗します。筆者は無数の企業が失敗するのを見てきました。その理由は、全員を参加させることができなかったり、戦略を明確にすることができなかったりしたからです。ビジネスユーザーを巻き込めなかったり、上級幹部の支持が得られなかったりしたからです。このことはいくら強調してもしきれませんが、変革を実行に移す前に、バルコニーから見渡し、正しい方向へ導いてくれる地図を持っていることを確認してください。

自社の目指す姿と進むべき道を明確に示すビジョンを確立したら、次の段階に進みましょう。次のステップは、ビジョンの伝達、適切なチームの構築、アーキテクチャの最適化、実行計画の策定、プロセスの定義、ユースケースの選択です。ここでも、全員のベクトルを合わせ、目標に貢献させることが重要です。開発の初期段階では、小さな実装から始めてください。ただし、それと同時に、目標達成のためには、アーキテクチャはすべてのユースケースに対応できるものにしなければならないので、全体像を念頭に置いてください。最重要なデータを管理するために、役割、プロセス、ポリシー、手順、標準を実現するデータガバナンス機能が必要です。一貫性と信頼性を確保するために、マスターデータとデータ品質管理機能が必要です。リネージの追跡、ビジネスコンテキストの取得、物理データへ関連付けるためのメタデータが必要です。データプロダクトを構築し、データを価値に変えるための統合・分析サービスが必要です。これらすべての目的を達成するには、必要な構成要素を総合的に検討することがおすすめですです。これらの構成要素は、ずっと存在しつづけるものです。たとえ、基盤となるテクノロジーが今後何年かにわたって変化したとしてもです。

重要な構成要素を明確にした後は、トップダウンのコミットメントを取り付ける必要があります。さらに、ビジネス上のステークホルダーとコミュニケーションを図り、関心を高めてください。意図するアプローチ、ビジネス上の目的、目標が明確であり、組織全体でよく理解されていることを確認してください。戦略的構想とビジネスユースケースの洗い出しを開始します。大きな効果が期待できるユースケースの一覧を作成することから始めるのが良いでしょう。それぞれのユースケースが、データ戦略やビジネス戦略と整合していることを確認します。それぞれのユースケースについて、組織にとっての価値が明確でなければなりません。次に、技術的な複雑さを評価し、データプロジェクトに優先順位を付けます。それぞれのユースケースについて、複雑さ、費用、商業的価値、リスク、運用管理性の観点から実現可能性を評価します。その後、最初に始めるものとして最適なものを選びます。最初のユースケースは、実装が難しすぎず、同時にその作業を行うだけの価値があるものでなければなりません。このユースケースは、組織において模範となるものでなければなりません。残りのユースケースは後で考えましょう。

12.2　中央集権型か非中央集権型か

潜在的な課題に備え、最初のワークロードを識別したら、いよいよ実装に取りかかります。この時点で、中央集権的な方法が適しているのか、それとも非中

央集権的な方法が適しているのかを判断する必要があります。

自社のデータ管理の成熟度が低い場合、当初は中央集権的な方法が適しています。なぜでしょうか。複雑な変革には、カルチャーの転換、スキルアップ、成熟したセルフサービス機能の構築、サイロや政治的境界の撤廃、知識の共有が必要です。これらの取り組みの複雑さを過小評価すべきではありません。このため、もし皆さんの組織がこれらの課題に取り組むだけの成熟度や規模をまだ持っていないのであれば、非中央集権化よりも中央集権化を検討してください。より多くのユースケースを導入し、データ管理とセルフサービス機能を強化し、中央集権化の次に連合化を実現できるようにしましょう。

既にデータ管理の成熟度が高い企業や、非中央集権的な組織になっている企業であれば、データ管理に対して非中央集権的な方法から始めることができます。しかし、非中央集権的なチームを連携させるためには、標準と原則を設定し、共有ケイパビリティ用のテクノロジーを選択する必要があります。これらの活動は中央レベルで行う必要があり、優れたリーダーと優れたアーキテクトが必要です。これらの点については、本章の最後でエンタープライズアーキテクトの役割について説明する際に触れたいと思います。

出発点以外にも、中央集権化と非中央集権化に関して考慮すべき点があります。まず、最終的な目標を決めるべきです。目標とする最終状態が非中央集権的なアーキテクチャであるにもかかわらず、中央集権的に開始すると決めた場合、アーキテクチャを構築するエンジニアは最初からこのことを認識しておく必要があります。長期的なビジョンを念頭に置けば、エンジニアはケイパビリティを疎結合にすることができ、後々容易に非中央集権化できるようになります。次に、どのケイパビリティを中央制御のままにし、どのケイパビリティを後で分散化するつもりかを決めるべきです。このことを前もって明確にしておくことで、今後の議論や政治的な対立を避けることができます。

12.3　実現に向けて

組織レベルでデータ戦略とビジョンを明確にしたら、次の活動は現実のものとすることです。筆者の経験やお客様からの成功談に基づくと、段階的な方法で小さく始めることがお勧めです。つまり、価値を高めるための仮説を立て、1つまたは限られた数のユースケースから始め、データプロダクトの構築とはどのようなものかを経験し、原則を定め、運用上の非効率な部分に対処し、組織にとって「ちょうどよい」ガバナンスとは何かを見極めることです。

ここでの議論は「ハッピーパス」（例外条件やエラー条件のない正常なシナリオ）に従っていることに注意してください。つまり、多くの尾を持つ多頭の邪悪な複合獣を相手にしているわけではありません。また、特定のコンテキストに特化した話題に深入りすることもありません。ここでは、一般的なデータの旅について、主要な段階を説明し、何をすればよいかを知っていただくことを目的としています。

12.3.1　戦略フェーズ：戦略的方向性の策定

最初のドメインの導入では、すべてのビジネスケイパビリティをマッピングし、データドメインを明確にして、組織構造と整合させるようなことは必ずしも必要ではありません。このフェーズの目標は、コンセプトがどのような形で機能し、実践に移せるかを知ることにあります。このためには、出発点として1つか2つのソースシステムを持つ、かなり単純なユースケースを選択することをお勧めします。これらのソースをデータプロダクト開発のための入力として使用し、次にこれらのデータプロダクトをコンシューマに直接提供し、データを価値に変えます。しかし、まだデータ価値創造ケイパビリティに注力する必要はありません。それは、後で行うことです。今は、新しいアーキテクチャのソースシステム側に集中します。

この最初のフェーズでは、データオーナーシップを取得し、最初の一連のデータプロダクトを構築するために、チームがどのようなマインドセットを持つ必要があるかを見極めることです。この段階では、中央チームは、ほかのチームを見守り、コーチングを行い、専門知識を提供します。一方で、ドメインチームは、データパイプラインを作成し、問題をデバッグし、データ品質の問題をソースで修正します。ストレージサービス、ETLツール、セキュリティ、データカタログなど、多くのことを総合的に判断する必要があるため、このフェーズでは、すべてのチームが緊密に連携し、共通のニーズを理解する必要があります。

このフェーズでの最初のステップは以下の通りです。

- 最初のユースケースを選択し、最初のデータプロダクトを構築するためのチームとして適切なビジネスチームを選択します。できれば、このビジネスチームは、最初の成果物を開発するのに必要なエンジニアリングスキルをすべて持っていることが理想的です。
- 明確ながら範囲が絞られ、できれば数カ月で終了できるプロジェクトを設定します。トップダウンの支援と調整を受けられるように、上級役員から

なる小規模のプログラム委員会を設置します。

- 全体のプロセスに取り組むデータプラットフォームチームのメンバー（候補）を決定します。このチームは、ドメインチームをサポートし、データプロダクトを作成するために最初のデータパイプラインの構築について責任を負います。

データアーキテクチャの観点からは、ランディングゾーンとデータ管理ランディングゾーンは1つずつにすることをお勧めします。「3.2　ランディングゾーントポロジー：解決空間の管理」で述べたとおり、すべての主要なクラウドプロバイダーがこれらのブループリントを提供しています。ベストプラクティスと推奨事項については3章で説明しました。次に、データの取得、保存、変換、カタログ化に必要なサービスのみをプロビジョニングします。不要なものは横に置き、必要不可欠なものに集中します。

ソリューション設計では、レイクハウスアーキテクチャの採用を検討してください。この設計は中央集権化のように見えるかもしれませんが、多くの利点をもたらしてくれます。実績があり、一般的で、よく理解されているパターンであり、設定が簡単で、インフラストラクチャーの管理が簡素化されます。図12-1は、このアーキテクチャが当初どのようなものになるのかの例を示しています。これは単一のドメイン用に設計された小さなアーキテクチャです。

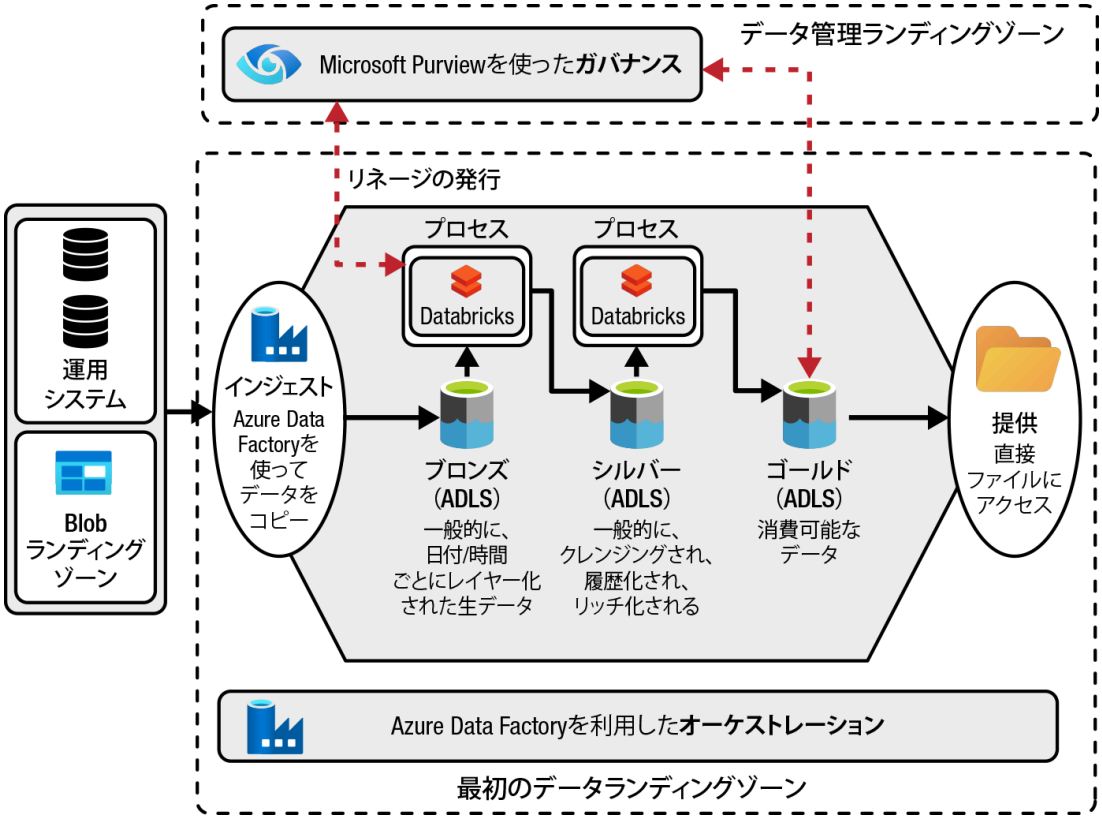

図12-1　レイクハウスの初期アーキテクチャ

まだスタートしたばかりの段階では、アーキテクチャはいくつかの必要不可欠なサービスしか使用しません。初期段階では、ドメインのデータエンジニアがデータプラットフォームチームのメンバーと一緒に作業します。一緒にスコープを決定し、最初のデータプロダクトを構築するために必要なサービスを分析します。

この設計の意図は、大規模なデータプロダクトを構築するための基盤を作り、データオーナーシップとセルフサービスという目標に対して、計算データガバナンスを使ってサポートすることです。最初のドメインチーム、プロダクトオーナー、データエンジニアは、緊密に連携してデータを利用できるようにします。まず、ソースシステムからデータを抽出し、ブロンズレイヤーにインジェストします。このために、チームは、中央プラットフォームチームが提供する統合サービスを利用します。次に、関連するデータを選択し、ノートブックやデータ変換サービスなどを使って、ユーザーが使いやすいデータセットに変換します。これらの活動中に、データはさらに別のレイヤーを通過することがあります。中間データ用のシルバーや、機能的にまとまっており消費可能なデータ用のゴールドです。すべての変換が実行された後、データカタログはすべてのデータをスキャンします。必要に応じて、データカタログは統合サービスをスキャンしてリネージを確認することもできます。スキャンの設定は中央レベルで行われるため、中央プラットフォームチームやデータガバナンスチームが実施します。最後のステップは、データを利用可能にすることです。その後、ほかのチームは分析ユースケースの入力としてこのデータを使用できるようになります。

図12-1の3レイヤー設計は一般的でよく知られています。しかし、それぞれのレイヤーの範囲、目的、ベストプラクティスについては、まだ多くの議論があります。また、理論と実践には大きな違いがあることも分かっています。データアーキテクチャのレイヤーをどのように実装するのがベストなのかについて詳しく知りたい方は、メダリオンアーキテクチャに関する筆者のブログ記事（https://oreil.ly/-rx5m）を読むことをお勧めします。

カタログ構成の難しさを甘く見てはいけません。データカタログの実装を開始する際には、すべてのソースやドメインを一度にスキャンしないでください。新しいエコシステムの一部となっているドメインだけをスキャンします。一度に1つのドメインずつ、順々に導入していきます。ビジネスドメインとアプリケーションドメインの間でどのような整合性を持たせるかは、ビジネスケイパビリティが共有されているのか、それとも専用にしか使用されていないのかによって異なるということを、実際に学んでください。適切な構造を構築するには、まずデータソースとデータプラットフォームを論理的に分割してグループ化します。ここで重要なのは、各データソースやアプリケーションからのデータ資産は、カタログ内の1つの場所にしか保存できないということです。つまり、技術レベルでは、データ資産をアプリケーションドメインに関連付ける必要があります。次に、このアプリケーションドメインレベルで、データベース、アプリケーション、データプロダクト、データパイプライン、そのほかのサービスを管理するそれぞれの担当者に、管理者、データソース管理者、キュレーターの役割を割り当てて責任を分担します。次に、ビジネス上でのデータ、アプリケーション、ドメインの意味を表す情報についても、同じようにグループ化と順序付けを行う必要があります。ビジネスケイパビリティを調査し、共通のビジネス目標に取り組む人々を見つけることによって、ビジネスドメインを明確にします。説明や用語集などのメタデータを管理するために、用語集のオーナーとデータスチュワードの役割を割り当てます。最後に、アプリケーションドメインとビジネスドメインを整合させ、アプリケーションドメインレベルで管理されるメタデータと、ビジネスドメインレベルで管理されるメタデータ間の関係を作成するようにドメインユーザーに依頼します。

最初のアーキテクチャを実装し、分析ユースケースの入力として最初のデータプロダクトを共有した後は、以下のような状態になっているはずです。

- 中央運用モデルがあります。プラットフォームとガバナンスチームが主導して標準を設定し、テクノロジーを選択します。
- データパイプラインの設定は中央チームが行います。並行して、このチームは、ほかのチームのコーチングやトレーニングも行います。
- データモデリングに関するガイダンスがない場合、データプロダクトはあまりにも生のものや、技術的過ぎになる可能性があります。このような事態を受け入れつつも、新たなコンシューマを迎え入れる前に、繰り返し改善することが必要です。
- データパイプラインは通常、手動で起動されるか、一定の間隔で実行されます。

- ソースシステム整合のドメインチームは、データプロダクトを中央カタログに登録する必要があります。このチームは、定義などのメタデータを管理し、それが正確で最新であることを保証する責任があります。このような活動には、中央チームの助けが必要になります。
- 各チームは1つのランディングゾーンと1セットのリソースを使用します。
- データリネージは古くなっているか、どこかに眠っているかのどちらかです。
- データカタログは、まだ公開されていません。ドメインがセルフサービスベースでメタデータを公開し、保守することはできません。これまで発行されてきた情報は限定的です。しかし、これは、チームが品質に対して責任を負わないことを意味するものではありません。たとえ、多少手作業であっても、あるいは中間管理者/中央データスチュワードを介してであったとしてもです。
- 対話的にデータをクエリするサービスは、まだようやく動き出したばかりか、存在しません。その代わりに、消費ドメインはデータを自身の環境に複製します。このため、データコンシューマやユーザーの権限は、手動で割り当てられます。アーキテクチャ構築の初期段階では、データアクセスは、サービス、コンテナ、フォルダレベルで粗視化されます。
- テンプレートの品質や、アーキテクチャを保護しセキュアにするためのハードニングの量は、チームや契約先などによって異なる可能性があります。

この初期フェーズでは、ケイパビリティはまだ成熟していません。また、手作業によるプロセスも多く、次の段階に進むには自動化やセルフサービス化が必要になるでしょう。メタデータも、次の段階ではより重要になります。Excelではうまくいっていたことも、より大規模になると通用しなくなるからです。

大規模なデータプラットフォームの構築は、中央のIT部門やクラウド部門に大きな負担をかけることになります。このため、次の段階に進む前に、プラットフォームとデータ管理ケイパビリティを構築し、IT部門やクラウド部門から賛同を得る必要があります。ベストプラクティスについては7章を参照してください。

ボトムアップで最初のユースケースを実装した後は、組織のほかのメンバーに結果を示すことで、最初の（ビジネス上の）ステークホルダーの理解と共感を得る番です。恥ずかしがらずに成功を披露し、付加価値とデータ活用のメリットを示しましょう。これらの活動を軽視してはいけません。幹部層からのトッ

プダウンのコミットメントを確保するために不可欠です。さらに進めると、読者の取り組みは、レガシーなデータ管理プラットフォームやシステムを一掃し、新しいデータ管理戦略に整合しないようなプロジェクトを中止に追いやれるはずです。これがすべて達成されれば、第2フェーズに向けて新しいユースケース要件を集められます。

12.3.2　変換フェーズ：基盤の整備

最初のユースケースを本番稼働させた後は、いよいよ大規模化です。データドメインを追加し、アーキテクチャを洗練させます。この段階では、ランドスケープの全体像を明確にすることが重要です。そのため、人、プロセス、テクノロジーとの整合性を含め、ビジネスケイパビリティが明確になっている必要があります。どのドメインがどのアプリケーションを所有し、どのような責任を負っているのかもわかっているはずです。また、どのような新しいデータプロダクトが、どのような新しいユースケースに対応できるかを知っておく必要があります（このトピックの詳細や、ビジネスドメインの特定方法を復習するには、2章を参照してください）。さらに、このフェーズでは、予算計画、ロードマップ、ビジネスへの付加価値、運用モデルに取り組みます。これらの活動は、規模を拡大していく上で重要です。

プロセスは重要ですが、それが官僚的になってはいけません。それよりも、ユースケースとその結果に焦点を当てましょう。大規模に価値を提供するには、注意、反省、適応という継続的なループが必要です。

ハイレベルの目標となる状態を念頭に置いて、次のステップは、どのようなドメインとランディングゾーントポロジーが組織に最適かを定義することです。3章で説明したどのトポロジーを使うにしても、データを処理、保存、カタログ化するためのサービスを、ブループリントに組み込んでおくことをお勧めします。メタデータの公開や、ポリシーの実施なども含めてください。次に、ドメイン間のデータトラフィックフローを調査します。この調査に基づいて、いくつかの設計上の判断を下します。例えば、多くのドメインがほかの多くのド

メインからのデータを必要とする場合、高度に非中央集権化されたドメイントポロジーやきめ細かいドメイントポロジーでは、複雑さと管理のオーバーヘッドが増大するためお勧めではありません。このような状況では、共有データプロダクト管理に中央集権的な場を使用する統制トポロジーの方が、良い選択肢となります。ドメイン間を流れるデータ量が大幅に変化する場合は、中央管理とピアツーピア分散データのハイブリッド型で実装することもできます。この場合、ドメイン間・ドメイン内のデータベースやストレージアカウントサービスの中で、データプロダクトをどのように管理するかについて決める必要があります。ベストプラクティスについては、「3.2.1.1　データプロダクトの構成」を参照してください。

最初のドメインが導入された後は、初期フェーズから学んだことを振り返りましょう。おそらく、ドメインチームはより熟練し、自己サポートできるようになりたいと思っていることでしょう。最初のデータプロダクトはそれほど複雑なものではありませんでした。入力された生データをいくつかのデータパイプラインに通し、コンシューマがアクセスしやすいデータに変換しました。難しいのは、これを繰り返し、統制された方法で行う必要がある場合です。データプロダクト開発プロセスに自動化やより高度な機能を追加する必要があります。例えば、スキーマやデータ品質を検証するためのデータ品質フレームワークを追加したり、新しいデータプロダクトを構築する際にドメインが遵守しなければならないETLサービスの標準を設定したりすることが考えられます。ノートブックを書き足したり、1回限りの再利用不可能なソリューションを使用したりする代わりに、この標準機能を実装するためのブループリントやパターンを提供する必要があります。

図12-2は、この次の段階でアーキテクチャがどのようになるかを示しています。この更新されたアーキテクチャでは、リアルタイムのデータインジェスト機能、メタデータ駆動型フレームワーク、ロギングデータベース、仮想化アクセスが追加されていることがわかります。

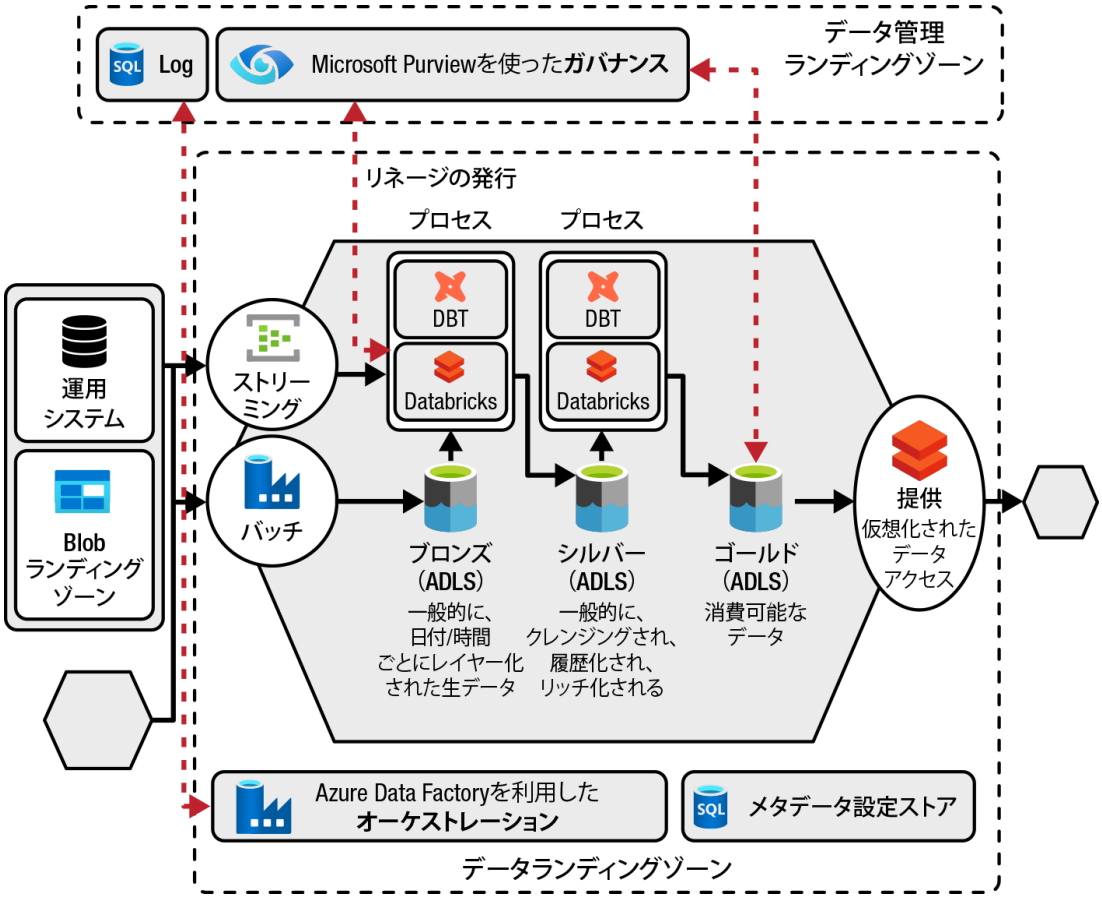

図12-2　更新されたレイクハウスアーキテクチャ

次に、データパイプラインにも同様の改良を加える必要があります。拡張性と柔軟性を確保するために最も効率的な方法は、パラメータ化されたメタデータ駆動型のパイプラインを使用することです。つまり、ハードコードされた値を使用して（独自のデータソース、選択、変換、出力を持つ）新しいパイプラインを手作業で再構築して作成するのではなく、例えばデータベースやコードリポジトリから実行時に設定を取得するような、設定変更可能な汎用パイプラインを作成します。パラメータ化されたワークフローでは、ドメインチームが提供するメタデータと条件を使用します。中央プラットフォームチームの役割は、インフラストラクチャーのブループリントにすべてを組み込み、as-a-service モデルを使用してこれらの機能をすべて提供することです。また、ドメインチームがもっと積極的にチーム間で協力したいと思っているケースもあるでしょう。ドメインチームは、プロバイダーとコンシューマの間でメッセージをやり取りするために、中央のプラットフォームチームに依存したくはないのです。例えば、新しいコンシューマがプロバイダーのデータを利用したいとき、プロバイダーにデータ品質の問題があるとき、データの配信が遅れるときなどです。プラットフォームチームは中央監視サービスと、プロバイダーとコンシューマ間のインタラクションを実現するコントロールフレームワークを実装すべきです。例えば、中央ログストアや、監視サービスを追加すると良いでしょ

う。この監視サービスでは、問題を検出し、警告ルール、通知、イベントを使用してユーザーにプロアクティブに通知を行います。複数ドメインアーキテクチャの例を図12-3に示します。

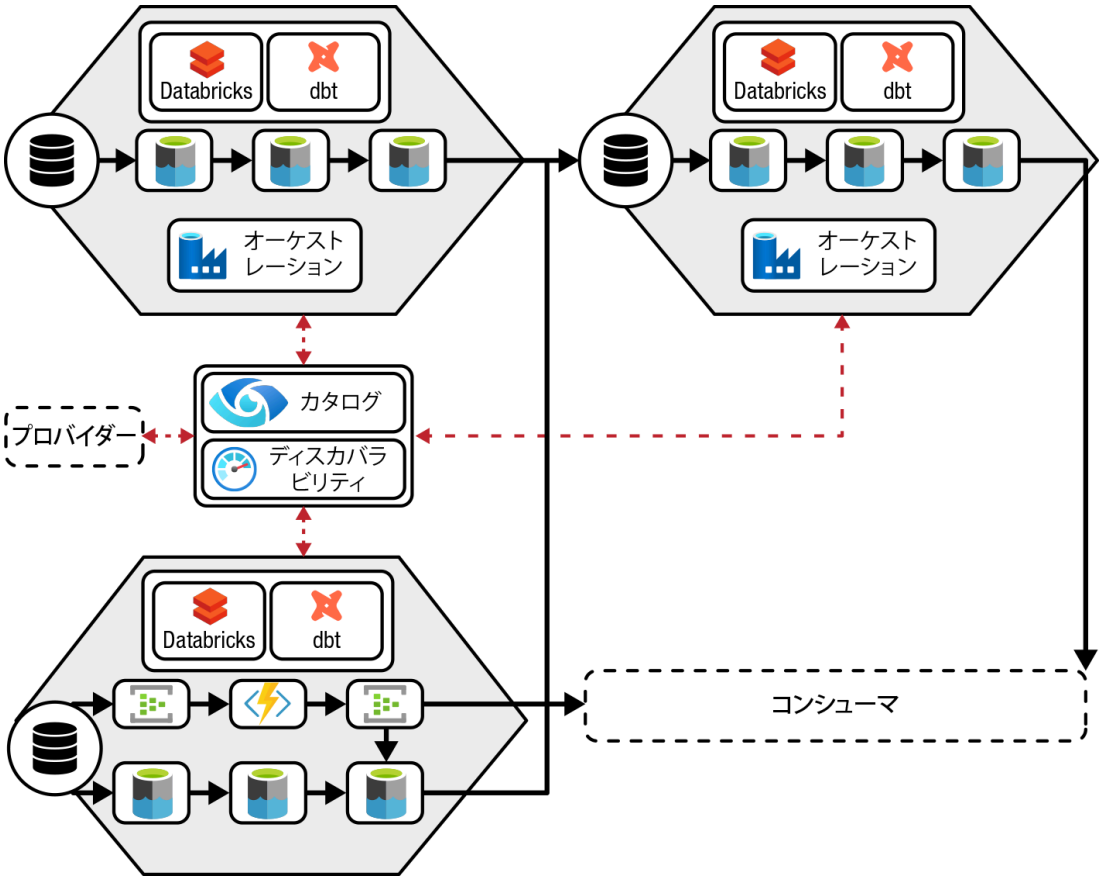

図12-3　新しいドメインの追加をサポートするために、データオブザーバビリティ、データ品質、データ変換、自動化のための標準化されたサービスでアーキテクチャを補完する

ドメインを追加する際のお勧めの方法は、消費側をスケールアップする前に、しばらくの間、アーキテクチャのソースシステム側に集中することです。なぜでしょうか。一般的に、データコンシューマの数はデータプロバイダーよりも多くなります。さらに、コンシューマ向けの分析サービスは複雑で注意すべき点がたくさんあります。そのため、大量のコンシューマを追加する前に、新しいデータプロダクトを安定的かつスケーラブルに提供することが重要になります。コンシューマ側にフォーカスを移すのが早すぎると、同じデータエンジニアリングの問題を、すべてのチームが何度も解決しなければならなくなるリスクがあります。組織全体がアーキテクチャに対する信頼を失い、データへの取り組みが水泡に帰すことになりかねません。そのため、すべてのステップにおいて、ビジネス価値を高めると同時に、データプラットフォームの有効性についてビジネスからの信頼を失わないようにする必要があります。

前職では、3つのユニークかつ補完的な戦略テーマを導入し、実行を指揮しました。

- オーナーシップの確立、データ品質の問題への対処、データ欠落の解消に重点を置いたゴールデンソース管理
- データプロダクトの作成、データ共有、データ収益化の実現に重点を置いたデータマーケットプレイス管理
- 自律的かつインテリジェントなデータ駆動型の意思決定を行うために、すべての人にその権限を与えることに重点を置いた、データの価値への転換管理

この3つのテーマを同時に少しずつ熟成させることで、チーム間のボトルネックを減らし、ビジネス満足度の向上に貢献しました。

データプロダクト開発を効率化した後は、まず計算データガバナンスを実施します。例えば、データをデータオーナーに紐付けずに共有することを禁止します。これには、データガバナンスソリューションが提供するワークフローを使用する必要があります。この演習の目的はガードレールを設置し、ドメインチームが知らず知らずのうちに損害を被ることなく自立できるようにすることです。このフェーズでは、中央チームの役割は変わります。どのような支援が必要かを監督し、必要に応じて介入することもあります。データガバナンスに関連するすべての活動を自分たちで行うのではなく、中央チームがほかのチームを訓練し指導します。さらに、この時点から中央チームは、「コントロールは良いことだ、信頼はもっと良いことだ」と考える必要があります。プラットフォームポリシーと監査レポートは、自動化されたガードレールとして機能します。

さらに規模を拡大する際に考慮すべき点は、チームのニーズに応じてさまざまなデータインジェストパターンやオプションを利用できるようにするかどうかということです。例えば、毎日バッチでデータを読み込むのではなく、イベント駆動型やCDCサービスを提供することで、より高速にデータをインジェスト

できます。また、ランディングエリアを使って、データプロダクトアーキテクチャに格納する前に中間データをステージングできるようにします。これは、外部データソースやレガシーシステムにも必要となる場合があります。

この段階が終わった時点での状況は以下の通りです。

- 8章で説明した新しいガバナンスと運用モデルが定義されます。これには新しい役割と責任が含まれます。
- ドメインとそれに対応するメタデータを表すために、ダッシュボードが作成されます。
- ドメインチームは、データのライフサイクルを最初から最後まで（元のデータを作成するアプリケーションから、ほかのチームが消費するデータプロダクトまで）管理します。ドメインチームはすべてのデータモデルを所有し、どのデータを他チームと共有するのが適切かを判断します。
- ドメインチームは、データプロダクトを管理するためにDataOpsのベストプラクティスを使います。例えば、それぞれのチームが独自のGitリポジトリを使用し、そこからコードを使ってCI/CDとデータパイプラインをプロビジョニングする、というようなことです（これについては「12.4　データ駆動型カルチャー」で詳しく説明します）。
- データプロダクトの開発は、ツールとデータモデリングのベストプラクティスによってサポートされます。ガイダンス（識別子、参照データ、レイヤリング、粗視化セキュリティを提供するための別々のテーブルにおけるデータの構造化に関する標準など）は、コラボレーションを向上させるためにWikiで公開されます。
- 開発チームは、パイプラインとそのパイプラインが下流のコンシューマに与える影響を認識できます。開発者はデータ品質サービスによってサポートされ、問題が発生するとユーザーに警告します。
- 手作業のプロセスやパイプラインは、テンプレートやサービスに置き換えられます。場所やパラメータをハードコーディングする代わりに、開発者は情報をソースコードとしてバージョン管理システムに保存します。これらのリポジトリには、テストや配備のスクリプト、ライブラリ/パッケージ、構成情報など、ほかの成果物も含まれます。
- リアルタイムインジェストやイベント駆動型インジェストなど、インジェストパターンが追加されています。
- 誰がどのデータプロダクトにアクセスできるかを指定するデータアクセスポリシーは、コードや設定として保存されます。この段階では、データア

クセスのプロビジョニングを完全にコントロールできるのは中央チームであることに変わりはありません。

- ランディングゾーンは1つです。提供するサービスのバリエーションは限定的です。すべてのドメインチームが同じブループリント構成を使用します。
- データプロダクトとデータドメインを使った一貫したメタモデルがあります。このメタモデルはデータガバナンスサービスで管理され、すべてのドメインチームがどのデータプロダクトがどのドメインに所有されているかを把握できるようにします。

新しいユースケースやドメインをアーキテクチャに導入する際、マイグレーションやレガシーシナリオに直面することがあります。例えば、コンシューマが数年前の過去データを要求する場面に出会うこともあるでしょう。新しいデータプロダクトアーキテクチャを構築する際、過去データは新しいアーキテクチャに最初のデータプロダクトを導入した時点からのものしか利用できません。そのため、導入前の過去データが必要な場合は、データ欠落が生じます。この問題を解決するには、ほかの環境から過去データを抽出するか、1回限りのコピーを作成します。例えば、データウェアハウスに過去7年分のデータが保存されている場合、そのデータを使用してレガシーデータプロダクトを構築し、そのレガシーデータプロダクトを新しいアーキテクチャに入力されるデータと組み合わせます。こうすることで、ドメインはすべてのデータを把握することができます。ただし、過去データと新しいデータを組み合わせるのは、必ずしも簡単ではありません。多くの場合、フィールドのマッチング、重複の削除、データのクレンジング、ビジネスロジックの記述などが必要になります。

さらに規模を拡大する場合、ドメインを相互接続して、データプロダクトを交換または直接共有できるようにしなければなりません。このためには、相互運用の標準を設定し、クエリサービスを実装する必要があります。ParquetやDeltaなどの一般的なファイルフォーマットや、（サーバーレスの）SQLサービスを使ってほかのドメインがデータプロダクトにアクセスして閲覧できるようにすることを検討してください。

12.3.3　最適化フェーズ：ケイパビリティの高度化

基盤が確立された後は、優先順位をつけてビジネスユースケースを繰り返し、ケイパビリティをさらに高度化させます。この段階での重要な目標は、中央チームからドメインチームへ、すべてのサポート活動を引き渡すことです。非効率的な部分を探し、セルフサービスと自動化で解決するようにします。組織を強化するために、データと対応するデータパイプラインをチームがより効率的

に管理できるように導きます。データプロダクトを自身で導入・購読できるようにします。メタデータを自身で登録したり保守したりできるようなサービスを配備します。例えば、ドメインのCI/CDプロセスに簡単に統合できるAPIを配備します。

アーキテクチャの次の段階では、リアルタイムのデータ処理、消費への対応力、セキュリティ、MDM、キュレーションされたデータの流通に重点を置くことになります。ブループリントとサービスによって、アーキテクチャの消費側を標準化するようにしましょう。データ利用は多様であり、多くのバリエーションが存在することを忘れないでください。コントロールが維持できるよう、新しいサービスを1つずつ立ち上げて徐々に拡張していきましょう。新しいサービスごとに、ドメインに提供する前に必要性を評価します。図12-4に更新された設計例を示します。

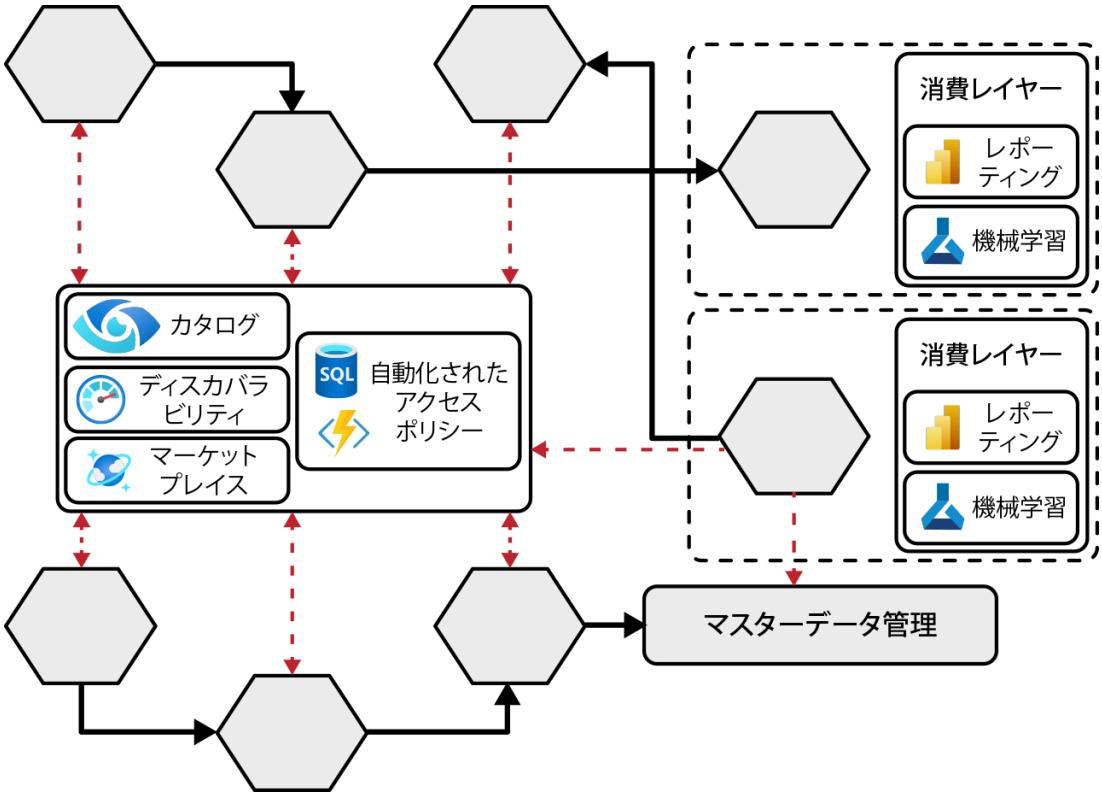

図12-4　アーキテクチャの拡大に伴い、新しいサービスが追加される

ソリューションアーキテクチャでは、多くのサービスがまだ連合型をサポートしていないことが問題です。中央チームは、サービスを統合し、セルフサービスと自動化機能を提供することによって、この溝を埋めなければなりません。中央チームは、標準化、ツール、技術的要件の間の調整を行います。プログラミングフレームワーク、ETLサービス、ストレージサービスに関連するすべての選択を行います。

データの再利用性に関する問題や一貫性を管理するためには、利用頻度の高いデータプロダクトを探しましょう。多くの場合、複数のドメインが、ほかのドメインからのデータと統合したり組み合わせたりするのが難しい、と苦情を言っていることでしょう。そこで、チーム間で繰り返し行われている調和と品質改善に関する取り組みを調べましょう。このような重複する活動が多く見られる場合、問題のデータプロダクトはマスターデータ管理の候補になるかもしれません。または、（繰り返し行われる）一般的な統合ロジックを分離し、カスタマー・サプライヤーモデルを使用して、1つのデータプロダクトチームにデータオーナーシップを担当してもらうこともできます。お勧めの方法については10章を参照してください。

データ共有の一環として、データプロダクトチームは、どのデータプロダクトをどのような目的で使用できるかを説明できなければなりません。ドメインは、中央のガバナンスチームと緊密に連携して、所有するデータのアクセス制御を行うことができます。残念ながら、本書を執筆している時点では、チームに素晴らしい体験をもたらしてくれるような、すぐに使えるソリューションを知りません。分かりやすいワークフロープロセスとポリシーを自動作成することでチームをサポートしたい場合は、ワークフロープロセスを使用してコンシューマ向けの（セキュアな）ビューを展開するような、小規模データ契約フレームワークを自分で構築することを検討してください。このフレームワークには、ビジネスセマンティクスへの参照や、データ品質やSLAを組み込むとよいでしょう。詳細については、8章を参照してください。

この段階が終わった時点で、状況は次のようになっているはずです。

- アーキテクチャは、データ流通とアプリケーション統合のためにさまざまなパターンをサポートしています。できれば、データプロダクト、API、イベントに関するガイダンスが揃っていることが望ましいです。
- Infrastructure as Codeによる自動化とプロビジョニングにより、新しいデータドメインを短期間で導入できます。
- 分類とラベルに関する標準が正式に定められ、ガイダンスとプレイブックが作成され、チームがトレーニングを受けています。
- 自然言語処理や機械学習などの技術を適用して、メタデータ管理でドメインをサポートします。
- ガバナンスとアクセス制御ポリシーは自動化されています。そのためには、小規模なワークフロー、アプリケーション、登録用APIを準備することを検討してください。

- データの利用方法と、データを価値に変えるプロセスが標準化されています。ドメインチームに提供されているブループリントのテンプレートが更新され、そこから個々のユースケースに使用するものを選択することができます。
- マスターデータ管理サービスは、エンドツーエンドやクロスドメインの一貫性を確保するために、アーキテクチャに追加されています。
- ステークホルダー間の交流は、データガバナンス組織によって最適化されます。チームはトリアージと全体的な計画のために定期的に会合します。
- データプロダクトは、多種多様なユースケースに対応するため、複数のエンドポイント（**出力ポート**とも呼ばれます）を備えています。
- ドメインチームが対照的な要件を持つ場合のために、ランディングゾーンが追加されています。

さらに規模を拡大する場合、データガバナンス体制を明確化することが重要です。そのため、データの役割が十分に定義されていない状態から、整合性の取れたプロセスを備えた明確な構造へと移行する必要があります。組織の規模によっては、複数のガバナンス組織とデータプロダクトチームがやり取りしている場合があります。図12-5に、このやり取りがどのように機能するかの例を示します。

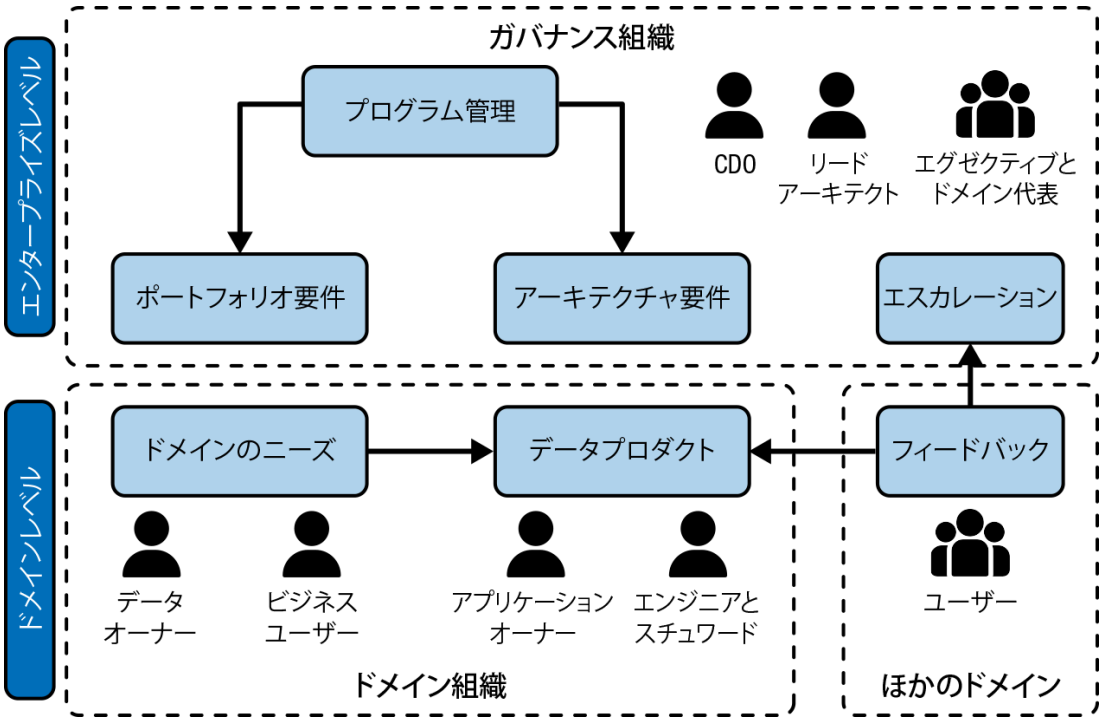

図12-5　さまざまなデータガバナンス組織とドメインチームがどのように協力するかの例

上部では、ガバナンス組織が戦略的な管理を行い、企業のビジョンと目標を推進するために協力します。高レベルの設計、ロードマップ、および大規模プログラムに関する判断は、新しいアーキテクチャに大きく左右されます。この組織には通常、最高データ責任者（CDO）、リードアーキテクト、シニアドメインオーナー、そのほかの経営幹部が参加します。

下部では、ドメインチームが、ユースケースや依存関係の管理、新しいデータの導入、問題への対処などを行うためにドメイン組織にまとめられています。ほかのチームからフィードバックや要求事項を受け取ることもあります。このように、すべての組織間で相互にやり取りが行われます。例えば、あるドメインチームがほかのドメインチームからの支援を必要としたり、プログラム管理チームからの戦略的な判断を必要としたりする場合があります。

ガバナンス体制を構築し、計画とフィードバックのループを同期・調整するための会議日程を設定したら、次はいよいよ最後の仕上げです。インテリジェントなデータファブリックとデータマーケットプレイスケイパビリティです。ここでは、9章で学んだように、埋めなければならないギャップもあるので、待機するか、適合させるか、自前のアプリケーションコンポーネントで解決する必要があります。

12.4　データ駆動型カルチャー

繰り返し、繰り返し行ううちに、データ駆動型のカルチャーも必要であることが分かってきます。ビジネスユーザーをすべての議論に参加させることが非常に重要です。ビジネスユーザーは、価値を理解し、データプロダクト作成の必要性を後押しし、オーナーシップを持ち、基本的な標準を守るべきです。この移行には、多くの啓蒙活動が必要であり、物事が間違った方向に進んだ場合には厳しく対処する必要があります。データオーナーが自分のデータを正しく説明したり分類したりしない場合は、共有させないようにします。データの品質がある閾値を下回ったら、その流通を阻止します。フィードバックと改善をオープンにしながら、組織をコントロールして導きます。

同じようなカルチャーの転換がエンジニアリングコミュニティにも必要です。data as a productの考え方では、データ管理とソフトウェア開発をより緊密に連携させる必要があります。バージョン管理、IaC、自動化、品質テストなどのDevOpsのプラクティスと方法論が必要です。もう少し詳しく説明しましょう。

12.4.1　DataOps

データプロダクトチームがうまくいくためには、開発、構築、テスト、配備、運用、監視の繰り返しプロセスに慣れる必要があります。そこで登場するのが「データのためのDevOps」（DataOps）です。適切に組織化されたデータチームでは、エンジニアと開発者が少なくとも以下の責任を担うことが求められます。

- アジャイルのスプリントとバックログを使用して作業を整理し、ほかのチームからのフィードバックを反映できるようにします。
- データパイプライン、コード、構成、スキーマメタデータ、ドキュメントなどの成果物をコードリポジトリで管理します。
- 本番環境に配備する前に、隔離された環境を使用してすべてのコンポーネントを自動的にテスト・構築します。
- データパイプラインの品質と変更を監視します。
- チーム間で継続的にフィードバックを行い、改善を促します。
- 自動化を追加することで 非効率な作業を削減します。
- テンプレートとコードスニペットを使って、市場投入までの時間を短縮します。

DataOpsの働き方の利点は、柔軟性を高めながらチームの自律性を強化できることです。それぞれが自分のプロジェクトに集中していくことで、複数のチームが互いに干渉されることなく並行して作業することができます。

効率的で独立したワークフローは、DataOpsを成功させるために不可欠な要素です。このようなワークフローの場合、データチームの責任は、2つの異なるオーケストレーターを保守することになります。最初のオーケストレーターはデータパイプラインです。データ関連のプロセスのステップを調整することに重点を置いています。データプロダクトやユースケースを構築するという意味では、データパイプラインは、生の入力データを意味のある情報に変換し、ビジネスに価値を提供します。データパイプライン管理に関連するプロセスは、それぞれのドメインチームのデータエンジニアが所有しています。設計によっては、データパイプラインは多くのステップを持つ長いシーケンスになることもあります。**図12-6**に実際の例を示します。

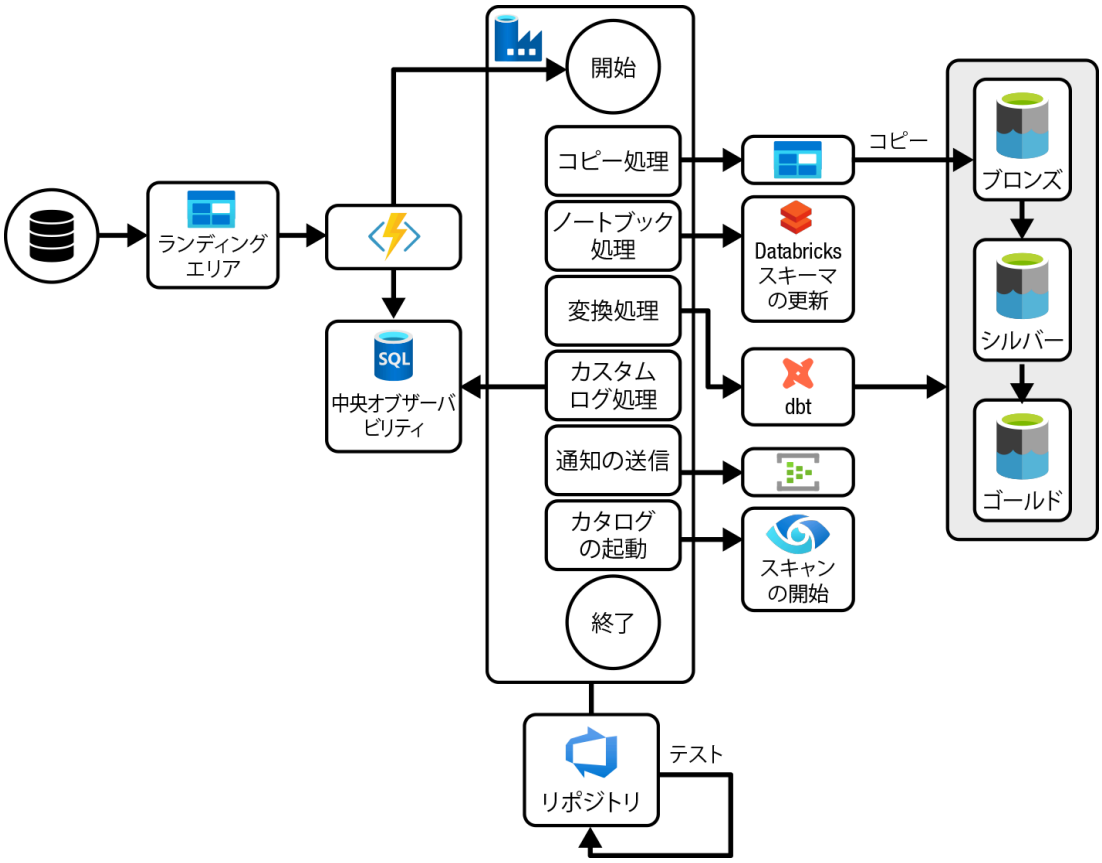

図12-6　実際のDataOps：データパイプラインが複数の処理をどのようにつなぎ合わせるかの例

このデータパイプラインのステップを、最初から最後まで示すと、以下の通りです。

1. データを収集します。このステップは通常、新しいデータがデータランディングエリアにインジェストされるたびに自動的にトリガーされます。例えば、図12-6では、ある機能がデータパイプラインを呼び出して実行しています。この同じ機能はまた、レコードを中央のオブザーバビリティストアに送信します。
2. ソースの場所を検証します。
3. 中間ランディングエリアのソースデータをブロンズレイヤーにコピーします。
4. ノートブックを起動し、データが保存されている最新の場所を使用して、スキーマと外部テーブルを更新します。
5. バッチジョブを起動して、 すべてのデータ品質やデータ変換処理を実行します。
6. 中央のオブザーバビリティストアのレコードを更新して、処理が完了した（または失敗した）ことを示します。

7. 処理が完了したことや、処理に失敗したことをデータコンシューマに通知します。
8. 処理が成功した場合は、中央データカタログを呼び出します。

データパイプラインを設計する際には、考慮すべき要素や疑問点が数多くあります。例えば、データはランディングエリアにプッシュされるのでしょうか、それともデータベースにアクセスしてプルされるのでしょうか。データの変更を取得するためにサードパーティのサービスは必要でしょうか。特定のセキュリティ要件があり、コンシューマごとにデータを異なる構造にする必要があるのでしょうか。具体的な要件によって、パイプラインは、ここに示した例やほかのパイプラインとは異なったものになります。データパイプラインを構築する際、固有のステップもあれば、汎用的なコンポーネントで標準化しやすいステップもあります。例えば、進捗状況のモニタリングとステータスのロギングは、**図12-6**に示すように、汎用的なステップです。ベストプラクティスは、これらの汎用的なステップをチーム間ですべて標準化することです（例えば、共通のコンポーネントや機能を使用します）。

図12-6の下部には、すべての成果物が管理されるコードリポジトリがあります。このリポジトリは、シーケンス全体をエンドツーエンドで実行するための設定とコードを管理します。また、2番目のオーケストレーター（CI/CDパイプライン）にとっても重要な役割を果たします。CI/CDパイプラインは、新しいバージョンのソフトウェア（およびインフラストラクチャー）の提供に必要となるステップを調整する役割を担っています。データプラットフォームの管理という意味では、このオーケストレーターはプラットフォーム構成、スキーマ情報、データパイプラインのコードをある環境から別の環境へ移動させます。CI/CDパイプラインでは、作業方法や成果物が本番環境に配備される方法について、チーム間で標準化が行われます。

データエンジニアリングのワークロードを管理するためのベストプラクティスとしては、各チームに独自のコードリポジトリを与え、3つの異なるブランチを使用して構成するのが一般的です。その3つとは、開発ブランチ、テストブランチ、本番ブランチです。チームは、開発用の典型的なGitワークフローサイクルに沿って作業を進めることができます。

1. 開発者とエンジニアは、機能ブランチで個々の機能を開発し、単体テスト（実装されたノートブックやテンプレートなど）を使用して検証します。

2. 開発者がその内容に納得したら、機能ブランチからメイン開発者（コラボレーションブランチ）に対してプルリクエストを作成します。この後、提案された変更内容がレビューされます。
3. プルリクエストが承認されると、変更がメインの開発ブランチにマージされます。一般的に、CI/CDパイプラインでは、統合テストと単体テストが行われ、すべてが期待通りに動作することを検証します。
4. チームが結果を検証したら、テストブランチに移し、そこで新機能を顧客やエンドユーザーにテストしてもらいます。
5. 追加の変更が必要なく、すべてのテストが問題なければ、本番稼働が承認されます。その後、CI/CDプロセスにより、更新されたすべてのデータパイプラインと構成が本番環境に自動的にリリースされます。

図12-7は、この方法の実践方法を示しています。

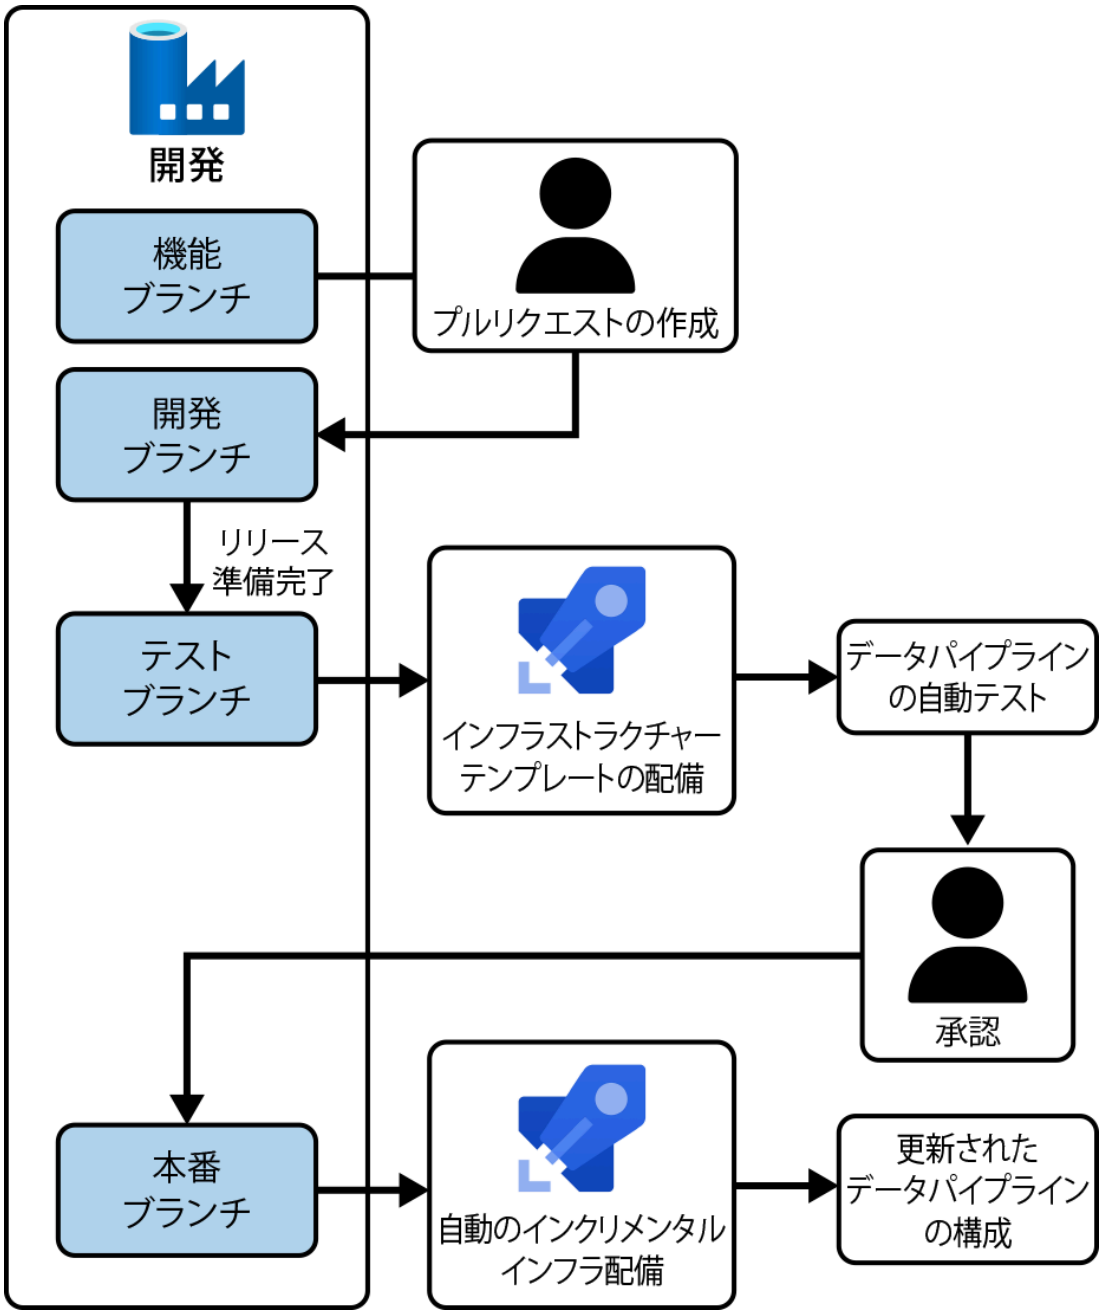

図12-7　DataOpsの実践：CI/CDプロセスで開発からテスト、本番までを進める例

CI/CDの考え方は、開発、テスト、本番作業を完全に隔離しようとする場合に特に有効です。一般的なベストプラクティスは、複数のワークスペースを設定し、それらを異なるコードブランチに連携させることです。この場合、ワークスペースをプロビジョニングするためのインフラストラクチャーテンプレートは、チームのコードリポジトリ内で管理されます。また、ドメインチームによって配備される環境が組織の標準に確実に準拠するようにポリシーを設定することもベストプラクティスです。この方法を使えば、あらゆる面で障害となるものを最小限に抑えることができ、セキュリティの高い環境では好まれます。同時に、イノベーション業務とアドホックな活動は分離されます。通常、開発環境はよりゆるやかなポリシーで管理されるからです。

CI/CDプロセスの構成によっては、環境を必要に応じてプロビジョニングすることもできます。例えば、テスト環境を常に稼働するのではなく、新しいテスト環境をオンデマンドでプロビジョニングするようにもできます。すべてのテストが完了し、すべてが期待通りに動作するようになったら、クリーンアップ処理を実行し、すべてのインフラストラクチャーを破棄することができます。

DataOpsへの移行は、ほとんどがカルチャー的なものです。この移行には、標準を設定し、構成テンプレートとブループリントを開発する中央チームが必要です。また、中央チームは、コーチングを行い、トレーニング資料を作成し、研修会などを開催する責任も負います。これらの活動を過小評価しないでください。このような活動には、さらに人員が必要になることがあります。

12.4.2　ガバナンスとリテラシー

データ駆動型の企業カルチャーを築くには、ガバナンスに取り組む必要があります。そのためには、役割と活動を明確に定義しましょう。8章で説明したRACIモデルを使用して、説明責任の所在を明確にします。次に、データ管理方法に関する実践的な手順について説明します。すべてをデータガバナンスのフレームワークにまとめましょう。データリテラシーにも注意を払ってください。なぜなら、組織内のすべてのリーダーがデータの価値を理解しているとは限らないからです。また、データ管理の概念を用いて、最適なコミュニケーションを行えるとも限りません。

アーキテクチャの変更に加え、ここで挙げたような変化は重要です。エンタープライズアーキテクチャは、これらすべての活動を調整する上で重要な役割を果たします。次にそれを見ていきます。

12.5　エンタープライズアーキテクトの役割

データの旅を進めるにつれ、組織におけるエンタープライズアーキテクトの役割は、アーキテクチャそのものと同様に変化していきます。その一端については7章ですでに説明しました。エンタープライズアーキテクトは、開発チームを導き、アーキテクチャの将来像を実現するリーダーにならなければなりません。アーキテクトは、実践的で現実に即した人物であると同時に、ビジョンを示し、すべての人がそれに従うよう働きかける存在でなければなりません。テクノロジーに精通し、セキュリティ、クラウドインフラストラクチャー、ソフトウェアアーキテクチャ、統合、データ管理など、さまざまな分野に秀でていなければなりません。また、エンタープライズアーキテクトは、ビジネス境界

を深く理解し、最新の統合パターンとビジネスアーキテクチャを使用して境界を分離する方法を知っている必要があります。

このプロファイル（ストラテジスト、熟練したエンジニア、管理者、意欲的なリーダー）は、静的なオブジェクトやダイアグラムだけで物事を考え、IT部門の奥深くや象牙の塔の高いところに座っているという、従来のステレオタイプのアーキテクトとはかけ離れています。この新しい時代において、エンタープライズアーキテクチャを確立するためには、これまでとは異なる役割プロファイルと注力領域が必要になります。ほかにどのような変化が予見されるか見てみましょう。

12.5.1　ブループリントとダイアグラム

これまで、エンタープライズアーキテクトは、形式化されたモデルやVisioダイアグラムとして成果物を提供してきました。このやり方は、ダイナミックな大企業の時代にはもはやスケーラブルではありません。現代では、モデル、ブループリント、ダイアグラムは、コードリポジトリツールを使用して、基礎となるメタモデルから構築されるべきです。このリポジトリは、データモデリングや設計情報、コスト情報、リネージ、新規アプリケーションの登録、オーナーシップの登録などで頻繁に更新されます。リポジトリの上には、視覚化レイヤーを配置し、最新のエンタープライズがどのようなものかがわかるようにします。設計、ビジネスケイパビリティ、ドメイン、アプリケーション、データプロダクトなどを視覚化します。

12.5.2　最新のスキル

エンタープライズアーキテクトのコアスキルは変化しています。従来、アーキテクトはコンテンツの専門家とみなされてきました。しかし、新しい時代のアーキテクトは、問題解決、デザイン思考、創造性のリーダーであることが期待されています。

このような専門家から問題解決者へのシフトには、高額な戦略コンサルタント会社によく見られるように、リーダーシップとイノベーションの両方が必要です。また、デザイン思考、プロトタイピング、ビジネスモデルキャンバスモデリング、マインドマップ、UXデザインなど、さまざまなフレームワークやテクニックも必要です。現実的な目標を設定し、ビジネスユーザーの期待を注意深く管理するようにしてください。

現代のアーキテクトには、傾聴とコミュニケーションのスキルも欠かせません。アーキテクト特有の専門用語でステークホルダーに負担をかけないようにしましょう。肯定的で、オープンマインド、共感的、実践的な人材になるか、またはそのような人材を見つけるようにしましょう。最後に、規範的であるようにしてください。プロダクトオーナーやエンジニアには、よく指導が必要になります。すべてを監視することはできないからです。

12.5.3　コントロールとガバナンス

エンタープライズアーキテクチャの実践にあたっては、長期的な目標と実用性のバランスを取る必要があります。このニーズは、エンタープライズアーキテクチャフレームワーク（Open Group Architecture FrameworkのTOGAF標準など）[†1]の終焉を招いています。なぜなら、長期的で静的な未来の状態を形式化するという考え方は、DevOpsやDataOpsの新しい世界にうまく合わないからです。確かに、全体像を描くことは必要ですが、「取り締まる」という考え方から脱却することも必要です。現代のエンタープライズアーキテクトはコミュニティリーダーとなり、率先してMVP（Minimum viable product、顧客に価値を提供できる最小限のプロダクト）を定義し、設計についての討論やホワイトボードセッションを開催し、顧客のニーズについて議論し、それを反映させる必要があります。詳細についてはチームに任せますが、物事がうまくいかないときには信頼できる専門家として対応します。

[†1] Svyatoslav Kotusev氏は、著書“The Practice of Enterprise Architecture: A Modern Approach to Business and IT Alignment”（SK Publishing）の中で、論理的なフレームワークとしてのエンタープライズアーキテクチャの考え方に公然と異議を唱えています。その代わりに、論理的な仮説ではなく、実際にどのように実行され機能するかを観察した経験に基づいて、エンタープライズアーキテクチャの実践を提案しています。

12.6　最後に

将来の企業データランドスケープは、まったく新しい方法で構成されるでしょう。本書で学んだように、データは今後さらに分散化し、データオーナーシップも分散化します。企業は、中央集権化と非中央集権化のバランスを取る最善

の方法を学ぶ必要があります。まもなく読者自身も経験することと思いますが、この変化には、試行錯誤とデータ管理の新しいビジョンが必要です。

エンタープライズアーキテクチャという言葉からネガティブなイメージを抱く人もいます。しかしながら、筆者はこの役割が大規模な変革を実現するために不可欠であると強く信じています。エンタープライズアーキテクチャは、最初のアイデアから最終的な実装に至るまで、作業を一貫して行うことを基本としています。ビジョンの立案、抽象的なコンセプトの設計、戦略の策定、活力の創出、そしてそのビジョンの実現に向けたチームのサポートが常に必要です。データ管理を大規模に実施する場合も同様です。大規模なデータアーキテクチャを構築するプロセスは、結局のところ、データの価値を見出すことから始まります。

最後のアドバイスです。神経質になる必要はありません。空を飛ぶことは最も安全な旅行方法です。データの素晴らしい世界には、たくさんの楽しみがあります。まだ始まったばかりです。