1章
データ駆動型への旅

COVID-19以前の世界も、すでにデータ駆動型で進化を遂げていましたが、パンデミックはその変化のスピードをさらに加速させています。激しい競争、デジタルファーストの時代、高まり続ける顧客の期待、規制当局による監視の強化などが、組織に対し、自らを最先端のデータ駆動型企業に変革することを要求しています。これからの組織は、データを息をするかのように吸収し、データをビジネスの中心に据えるという考え方を採用することになります。データをプロダクトとして管理し、データ分析に基づいて戦略的に意思決定を行い、データに基づいて行動するカルチャーを持つようになることでしょう。

データ駆動は、単なるバズワードではありません[†1]。データ駆動により、ほかの組織に対して競争上有利な立場に立つことができます。データを積極的に活用することで、何が起こるかを事前に予測し、先手を打つことができます。データを正しく使えば、変化に素早く対応できるようになります。データを活用することで、意思決定が直感ではなく事実に基づいて行われるため、より確実性の高いものになります。データがあれば、業界の新しいトレンドやビジネスチャンスをいち早く見つけることができます。顧客が何を考え、どのように行動し、何を求めているかをデータが教えてくれるため、顧客満足度も向上します。データを活用することで、組織をより柔軟で機動的な、コスト効率の高いものに変えます。これは、データが、実績や、従業員のモチベーション、信頼関係、アプリケーション、プロセスに関するインサイト（洞察）を提供してくれるからです。組織がデータ駆動型企業に生まれ変わることは必要不可欠なのです。

[†1] データ分析市場は急成長しています。IDC社の調査によると、2022年の市場規模は年間2,000億ドルを超えています。

この変革そのものについて語る前に、まずは現在直面している課題を検討し、データの管理方法を見直す必要があることを説明します。データをアセット（資産）として管理するために、データ管理に対する基本的な定義を構築します。この定義には、すべての分野や作業が含まれます。その後、重要なテクノロジーの発展や業界動向に焦点を当て、それらがデータ管理に与える影響について考えます。ここ数年のデータ管理のベストプラクティスを紹介し、以前のアーキテクチャがなぜ大規模化しにくいのかについて解説します。最後に、次世代のデータアーキテクチャとはどのようなものかを考察し、データ戦略を策定する際に必要となるアクションについて述べます。

1.1　最近のテクノロジーの発展と業界動向

組織をデータ駆動型に変えるのは簡単ではありません。それは我慢と粘り強い取り組みが必要であり、また長期にわたるプロセスでもあります。利用可能なデータが増えるにつれ、従来のアーキテクチャでは、その規模、複雑さ、モノリシックな設計、中央集権的な運用モデルのために、もはやスケールアップすることができません。企業は新たなデータ戦略とクラウドベースのアーキテクチャを導入する必要があります。また、パラダイムシフトとカルチャーの変革も不可欠です。既存の中央集権的なデータとITの運用モデルでは、連合型のデータオーナーシップやセルフサービス型の消費モデルを適用することができないからです。このため、組織は人、業務プロセス、テクノロジーをどのようにデータと連携させるかを定義しなおさなければなりません。

最近のテクノロジーの発展や業界動向により、データの管理方法を見直す必要に迫られています。すべてのデータを単一のサイロに閉じ込めるのではなく、ドメインや、チーム、ユーザー自身がデータを簡単かつ安全に配信、消費、利用できるようにする新たなアプローチへと移行することが求められています。プラットフォーム、業務プロセス、パターンは、他者の作業を簡単にするものでなければなりません。単純で、ドキュメント化され、高速で、利用しやすいインタフェースが必要です。大規模で動作するアーキテクチャの構築が求められています。

本格的なデータ駆動型の組織へと移行することは数多くの利点をもたらします。しかし、データランドスケープに変化をもたらすテクノロジーの発展や業界動向に注意しておくことも重要です。本章では、それぞれの動向とデータ管理への影響について説明します。まず、分析によりユースケースが多様化し、データランドスケープが断片化されつつあります。次に、新しいソフトウェア

開発手法がデータ管理を難しくしています。クラウドコンピューティングとネットワークの高速化もデータランドスケープを断片化しています。さらに、プライバシー、セキュリティ、法規制にも注意する必要があり、データの急増や集中的な消費のために、運用システムはますます複雑になっています。最後に、データの収益化にはエコシステム間をつなぐアーキテクチャが必要になります。これらのトレンドがデータ管理に与える影響は非常に大きく、業界全体が今後どのようにデータ管理を行うべきかを再考する必要に迫られています。

幸いなことに、**データメッシュ**や**データファブリック**などの新しいデータ管理手法が近年登場しています。

- データメッシュ（https://oreil.ly/kBtUG）は、データを大規模に管理するための革新的な方法論です。この概念は、データが高度に分散され、責任を連合型で分担するアーキテクチャを活用して、スケーラビリティが実現される世界を構想しています。人間的な側面に重点を置き、複雑化するデータアーキテクチャの管理という課題に取り組んでいます。
- データファブリック（https://oreil.ly/bjl2F）は、インテリジェンスを組み込み、セルフサービスを通じてデータアクセスを簡素化することで、データ管理とスケーラビリティに関する今日の課題に対処する手法です。データメッシュとは対照的に、データファブリックはテクノロジーレイヤーに重点を置いています。これは、データへのアクセス、統合、プロビジョニング、利用を容易にするエンドツーエンド統合レイヤー（ファブリック）を活用して、メタデータを一元的に管理するアーキテクチャ構想です。

データ管理に対するこれらの最新の手法は互いに補完しあうものであり、往々にして両者は同時に使われることもあります。データ担当者の間で一般的に信じられていることや、商用ベンダーの主張とは異なり、これらの手法は決して固定的なものでも独立したものでもありません。実際、これらの手法が共存し、運用データストアや、データウェアハウス、データレイクなどの既存の設備投資を補強することを筆者は期待しています。

データ駆動型への転換期において、組織は**中央集権化**と**非中央集権化**のバランスをとるためにトレードオフを判断しなければなりません。ビジネスチームに高度な自律性を与えたい組織もあれば、品質と管理を優先したい組織もあります。比較的シンプルな構造の組織もあれば、非常に大規模で複雑な組織もあります。完璧なガバナンス構造とデータアーキテクチャを構築することは容易ではないので、戦略を策定する際には、データ管理に対するこれらの手法をフレ

ームワークと考えるようにしてください。どちらが正しいということはありません。例えばデータメッシュの手法で、ベストプラクティスや原則の一部は気に入ったとしても、残りは気に入らない場合もあるでしょう。必ずしもそのすべてを採用する必要はありません。

本書では、データ管理に関する筆者の考え方を紹介します。この考え方は、多くの大企業と緊密に仕事をする中で得た知見に基づくものであり、読者が正しい判断をするのに大いに役立つことでしょう。データメッシュやデータファブリックの概念を超えて、データ戦略は運用面と分析面の双方をカバーする必要があります。データドメインとデータプロダクトの構成方法は、大企業の規模に合わせて変更する必要があると、確信しています。読者の今後の作業の参考になるよう、さまざまな企業がどのような戦略やアーキテクチャを設計し、なぜそうなったのか、そしてどのようなトレードオフを行ったのかについて、筆者の見解をお話しします。

詳しく説明する前に、データ管理とは何か、なぜそれが重要なのかについて納得しておく必要があります。次に、さまざまなトレードオフを踏まえた上で、どのように境界を定義し、どのようなランドスケープを形作るかを判断しなければなりません。最後に、今日のエンタープライズデータアーキテクチャを、現在と将来のためにどのように設計し組織化すればよいかを検討します。

筆者の主張を端的に述べておきます。非中央集権化は、望ましい状態というよりも、データが将来的には必ず行き着く先だ、ということです。このため、スケーラビリティを考慮に入れれば、データ管理は、より非中央集権的な組織化をしなければならないと筆者は確信しています。データを大規模に管理するには、責任を分担し、強力な標準を設定し、中央と現場のリソースや活動を適切に連携させる必要があります。この変化は、人、プロセス、テクノロジーなどさまざまな分野に影響を及ぼします。中央集権から非中央集権へのシフトは、過去数年間に確立されたベストプラクティスである、大規模なデータサイロを構築し、すべてのデータを収集・統合した後にサービスを提供する、という方法と矛盾するものでもあります。データウェアハウスやデータレイクアーキテクチャはデータを活用するための優れた手法ではありますが、このような中央集権型のモデルは非中央集権型の分散データアーキテクチャには向いていません。

さて、まずは深呼吸をして、偏見を捨ててください。多くの方々は、中央集権的なデータアーキテクチャに深く入れ込んでいるのではないのでしょうか。なぜなら、この手法は長きにわたってベストプラクティスとされてきたからで

す。データを調和させ、大量のデータを特定のコンテキストに取り込むニーズは残っており、そうすることが組織に価値をもたらすことは筆者も理解しています。しかし、私たちが考慮しなければならないのは、この手法を適用する規模です。数百、数千のアプリケーションを持つ高度に分散したエコシステムにおいて、すべての次元で中央集権化することが、データ管理の最善の方法なのでしょうか。すべてのデータを統合し、調和させることが最善なのでしょうか。

1.2　データ管理

データを管理するために必要なプロセスや手順のことを、**データ管理**と呼びます。データマネジメント協会（Data Management Association）が発行する“Data Management Body of Knowledge”（DAMA-DMBOK）（https://oreil.ly/BKIm6、和書『データマネジメント知識体系ガイド 第2版』日経BP）では、データ管理について広範に説明されています。このドキュメントの中で、データ管理を、「データおよび情報資産のライフサイクルを通じて、その価値を提供し、コントロールし、保護し、向上させるための計画、ポリシー、プログラム、およびプラクティスの開発、実行、監視」と定義しています[†2]。DAMA-DMBOKでは、**図1-1**に示すように、データガバナンスを中心とした11個のデータ管理機能領域が挙げられています。これらの機能を組織に深く根付かせることが重要です。さもなくば、データからインサイトを得られず、効率が悪くなり、データがコントロールできなくなってしまいます。データ駆動型になること、つまり、データからできるだけ多くの価値を引き出すことは、非常に困難になるでしょう。例えば、分析しようとしても、質の低いデータしかないのであれば意味がありません。

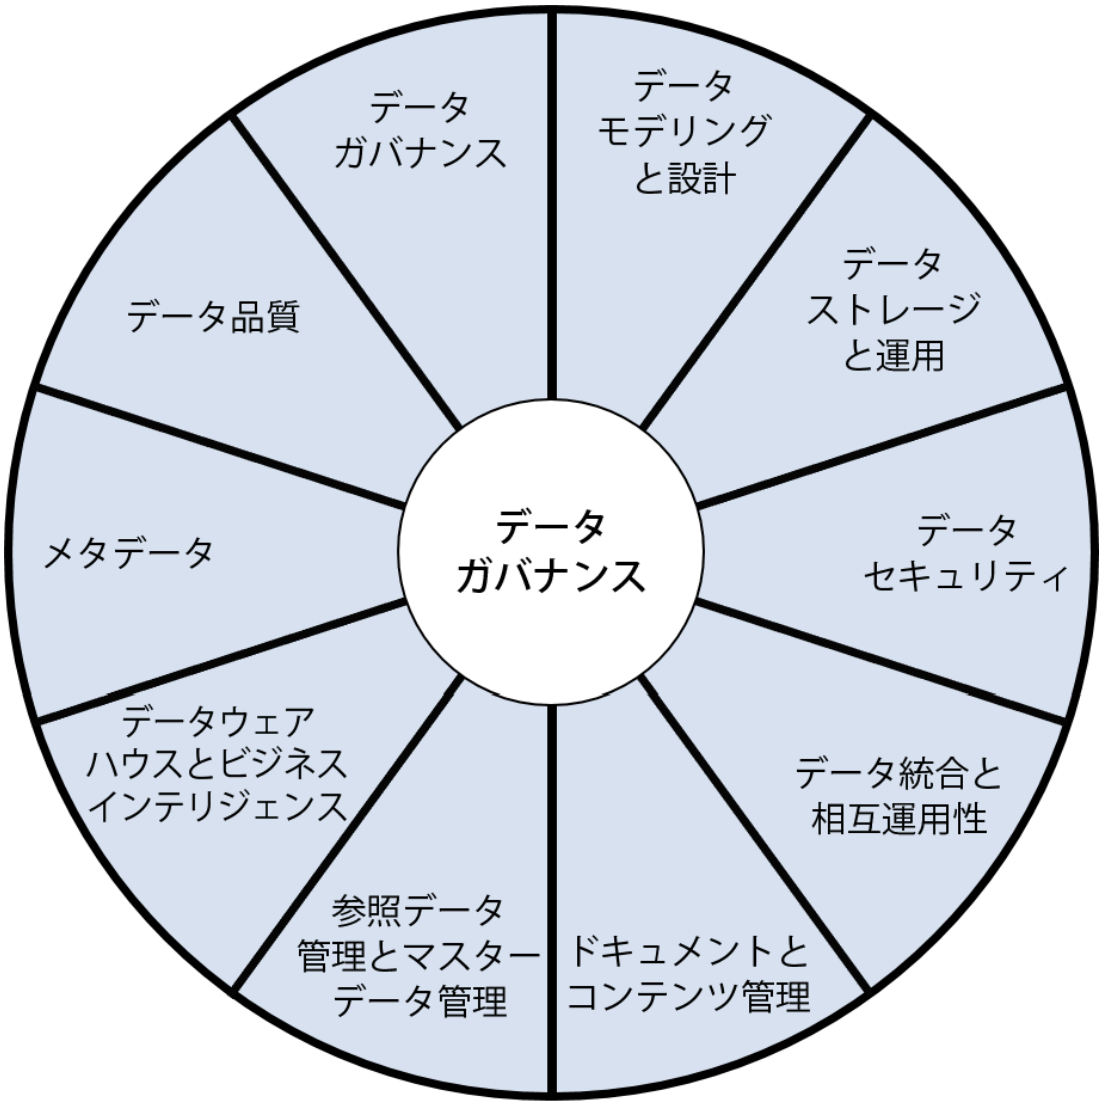

Copyright © 2017 DAMA International

図1-1　データ管理における11個の機能領域

[†2] DAMA-DMBOK は、DAMA コミュニティにより開発されています。更新サイクルはあまり速くなく、最初のリリースは2008年、2回目のリリースは2017年でした。

データ管理に関する作業や分野は多岐にわたります。ソフトウェアアーキテクチャと密接に関連する分野もあります[†3]。本書では、最新の大規模データアーキテクチャを管理する上で重要となる、データ管理の側面に焦点を当てていきます。この図に示されている11の分野について、本書で取り上げる部分を詳しく説明しましょう。

[†3] ソフトウェアアーキテクチャとは、ビジネス要件を満たしつつ、柔軟性、拡張性、実現可能性、再利用性、セキュリティなどの特徴を備えたシステムを開発するために必要となる、ソフトウェアの設計と高レベルの構造のことです。さらに詳しく知りたい方は、Mark Richards氏とNeal Ford氏による『ソフトウェアアーキテクチャの基礎』（オライリー・ジャパン、原書 “Fundamentals of Software Architecture” O'Reilly, 2020）をご一読ください。

- 図1-1の中心に描かれている**データガバナンス**は、すべてのデータ資産を含め、データ管理に関する権限・コントロールの導入と実施に関するすべての活動が含まれます。この分野については8章で詳述します。
- **データアーキテクチャ**は、データのマスタープランを定義するものです。これには、ブループリント†4や、参照アーキテクチャ、将来ビジョン、依存関係などが含まれます。これらを管理することで、組織は効果的な意思決定を行うことができるようになります。本書全体にわたってデータアーキテクチャを説明していますが、2章と3章で特に深く掘り下げていきます。
- **データモデリングと設計**とは、ある特定のコンテキストとシステム内でデータを構造化し表現することです。データ要件の特定や、設計、分析はすべてこの分野に含まれます。4章と7章、11章で説明します。
- **データストレージと運用**とは、データの価値を最大化するために、データベースの設計、正しい実装、サポートを行うことです。データベースの運用管理も含まれます。11章で説明します。
- **データセキュリティ**には、データに対する認証や、認可、アクセスなどに関するすべての考え方と行動が含まれます。これらの行動には、予防や、監査、緩和措置が含まれます。この分野については、8章で詳しく説明します。
- **データ統合と相互運用性**には、あるコンテキストから別のコンテキストにデータを効率的に移動させることを目的に、データの移動や、収集、統合、結合、変換などを行うためのすべての考え方と行動が含まれます。**データの相互運用性**とは、異なるアプリケーション間で、アプリケーションの内部構造をほとんど（まったく）知らなくても、通信や、機能の呼び出し、データの転送ができることを指します。一方、**データ統合**とは、さまざまな（複数の）データソースからのデータを結合して、統合ビューを作ることです。このプロセスは、多くの場合、データの複製やETL（ex-

tract、transform、load《抽出、変換、読み込み》）などのツールによってサポートされます。4章、5章、6章で詳しく説明します。

- **ドキュメントとコンテンツ管理**は、非構造化（メディア）のデータ形式で保存されたデータを管理することです。これについては、5章と6章で説明します。
- **参照データ管理とマスターデータ管理**とは、重要なデータを管理して、データのアクセス性、正確性、安全性、透明性、信頼性を確保することです。10章で詳しく説明します[†5]。
- **データウェアハウスとビジネスインテリジェンス**には、ビジネス上のインサイトを提供し、意思決定をサポートするための一連の作業が含まれます。アドバンストアナリティクスとともに、11章で詳述します
- **メタデータ管理**には、データを分類したり、データを説明したりするデータを管理することを意味します。メタデータを使うことで、データを理解できるようになり、データを統合したり、セキュアにしたりできます。また、メタデータはデータの品質を確保するためにも使われます。この分野については、9章で詳細に説明します。
- **データ品質管理**には、データが実用的であることを保証するために、データ品質を管理するすべての活動が含まれます。この分野については、2章と3章で解説します。

[†4] ブループリントは、**参照実装**とも呼ばれるものです。特定のユースケースに対応した一連のサービスを正しく作成するためのIaC（Infrastructure as Code）定義から構成されます。

[†5] 本書では、「マスターデータ管理」（MDM、master data management）という用語を使用します。これは、この用語が広く使われており、本書の執筆時点では業界としてこれに代わる用語がないためです。「マスター/スレーブ」という用語に代わる、インクルーシブな言葉が登場することを期待しています。

DAMA-DMBOKの中で、もう少し記述が必要と感じたところは、**データ統合と相互運用性**の部分です。ここが、本書の初版を書くきっかけとなったところです。例えば、アプリケーション統合やソフトウェアアーキテクチャとの関係が

はっきりしていません。非中央集権的なアーキテクチャについては触れられておらず、オブザーバビリティ（可観測性）のベストプラクティスや最新のデータパイプライン管理など、データの相互運用性に関する最新のガイダンスも不足しています。さらに、メタデータ管理との連携も十分ではありません。メタデータも統合と相互運用性が必要です。なぜなら、メタデータは多くのツール、アプリケーション、プラットフォーム、環境にさまざまな姿や形で散在するからです。メタデータの相互運用性（2つ以上のシステムやコンポーネントが、データに関する記述データを交換する能力）が、十分に扱われていません。大規模なアーキテクチャの構築と管理には、メタデータの統合が非常に重要です。相互運用性とメタデータに関する説明が、データアーキテクチャともうまく関連付けられていません。メタデータを適切に活用すれば、どのようなデータが流れ、どのように統合され、分散し、セキュアにされるのかがわかります。また、アプリケーションやビジネスケイパビリティに、どのように繋がっているのかも見えてきます。しかし、DAMA-DMBOKには、メタデータを活用してデータを包括的に管理するためのガイダンスはあまりありません。

また、DAMAや多くの組織がエンドツーエンドの意味論的な一貫性に対する見解についても、筆者は懸念を抱いています。現在でも、すべての意味論を統一して、企業全体での一貫性を実現しようとする試みが行われています。これを「**信頼できる唯一の情報のバージョン**」と呼びます。しかし、**アプリケーションは常に一意性を持ち、それに伴いデータも一意性を持ちます**。アプリケーションを設計するには、多くの暗黙の了解が必要です。ビジネス上の課題の（ドメイン）コンテキストは、アプリケーションの設計に影響を与え、データにも影響を与えます。概念設計から、論理的なアプリケーション設計、物理的なアプリケーション設計へと移行する際に、このコンテキストが引き継がれていきます[†6]。これは、将来のアーキテクチャにも適用されるものであるため十分に理解しておかなければなりません。データをアプリケーション間で移動させる場合、必ず変換処理が必要になります。このデータ変換のジレンマから逃れることはできないのです。この点については、以降の章で再度説明します。

[†6] データモデリングのさまざまな段階について詳しく知りたい方は、筆者のブログ記事“Data Integration and Data Modelling Demystified”（https://oreil.ly/qEuCE）を参照してください。概念モデルは、ドメインモデル、ドメインオブジェクトモデル、分析オブジェクトモデルなどと呼ばれることもあります。

さらに、多くの組織で見られるのが、データ管理は中央集権的に行うべきであり、企業の戦略目標と結び付いていなければならないという考え方です。一部の組織では、すべてのデータや管理に関する作業を中央集権化することで、運用コストを削減できるといまだに考えています。また、中央集権化されたプラットフォームを使えば、データを利用したり消費したりする際にデータ統合という厄介な作業をしなくてもすむと深く思い込んでいます。企業は、データウェアハウス、データレイク、サービスバスなどのエンタープライズデータプラットフォームに多額の投資を行ってきました。マスターデータ管理に関する作業は、これらのプラットフォームと強く結び付いています。データを集約することで、特に重要となるデータの正確性も同時に向上させることができるからです。

中央集権化されたプラットフォームと、それに付随する中央集権化されたモデルは、破壊的なトレンドのために破綻する恐れがあります。破壊的なトレンドとは、分析や、クラウドコンピューティング、新しいソフトウェア開発手法、リアルタイムの意思決定、データの収益化などのことです。多くの企業は、これらのトレンドの存在を認知していても、データ管理に与える影響を理解していません。これから、これらのトレンドを吟味し、その影響の大きさを評価してみましょう。

1.3　分析によるデータランドスケープの断片化

このトレンドの中でとりわけ注目を集めているものは、アドバンストアナリティクスです。アドバンストアナリティクスにより、データを活用して企業の対応力、競争力、革新性を高められるからです。なぜ、アドバンストアナリティクスが既存のデータランドスケープを破壊するのでしょうか。利用可能なデータが増えれば、選択肢やチャンスも増えます。アドバンストアナリティクスとは、What-if分析を行い、将来のトレンドや状態、イベントを予測し、隠れた関係や振る舞いを検出し、意思決定を自動化することです。アドバンストアナリティクスの価値と戦略的メリットが認識されているため、さまざまな方法で利用できるように、多くの方法論、フレームワーク、ツールが開発されています。人工知能（AI）や機械学習（ML）、自然言語処理（NLP）については、まだほんの少し使われはじめたに過ぎません。将来どのように進化するかは想像もつきません。

OpenAIのChatGPT（https://openai.com）は、AIの可能性について衝撃をもたらした好例です。OpenAIのモデルには、GPT（Generative Pre-trained Transformer）シリーズが搭載されており、数学の問題を解いたり、コードを書いたり、本の感想を書いたり、食材のリストを使ってレシピを作ったりと、複雑なタスクをこなすことができます。

このような分析のトレンドは、データを多くの分析アプリケーションに分散させます。個々のユースケースごとに必要なデータが異なるからです。個々のビジネス上の課題には、それぞれ特有の考え方、特有のデータ、そして最適なソリューションを提供するテクノロジーが必要です。例えば、あるマーケティング事業部門が、年配の顧客層と若い顧客層に対する新たな販売機会を見出すことを目的としているとします。この2種類の顧客層をターゲットにするには、それぞれ異なるデータセットの特徴量（分析可能な特性）が必要です。例えば、若年層と高齢層の間では、ターゲットのセグメント化やクラスタリングが異なります。マーケティング部門に単一のデータセットを両方の顧客層に使うよう指示すると、さまざまな面で問題が生じ、それぞれのユースケースに付加価値をもたらさない特徴量ストアが出来上がってしまうでしょう[†7]。最大の価値を生み出すためには、それぞれの学習アルゴリズムに最適化し、それぞれのユースケース特有の特徴量セットを与えることが最適な解決策です。

[†7] 特徴量ストアとは、よく使われる特徴量（現象についての、個々の測定可能な特性や特質）を保存するためのツールです。

データの爆発的な増加に伴い、データは無数の場所、アプリケーション、データベースに散在します。これは、データを消費するドメインが、その独自のソリューション用にデータを処理する必要があるからです。このようなデータの分散は別の問題を引き起こします。まず、データが繰り返しコピーされ、組織全体に分散すると、その出所を特定したり、品質を判断したりすることが難し

くなることです。そのため、異なる場所で管理されている同じデータに対して、論理的な単一のビューを開発しなければなりません。さらに、データが広範囲に分散していると、データの管理が困難になります。データはアプリケーションを離れた瞬間に、拡散してしまうからです。このため、データを効率的に再利用するためのフレームワークを開発する必要があり、同時にガバナンスを適用し、外部の法規制に準拠しなければなりません。

分析技術の発展は、データ集約の傾向を強めます。その結果、**読み書きの比率**が大きく変化しています。例えば、定期的に再学習する分析モデルは、定期的に大量のデータを読み出します。このようなデータの読み出しに配慮すると、データの読み出しやすさを観点に最適化を行う必要があります。そして、データの読み出しやすさの最適化によって、アプリケーションやデータベースの設計に影響が出ます。システムが継続的にデータを提供すると負荷が増大するため、データを複製する必要があるかもしれません。また、さまざまなユースケースとそれに対応する読み出しパターンに合わせて、データを前処理しなければならないかもしれません。さらに、同じデータでも、コンシューマごとに異なる表現を提供しなければない場合もあるでしょう。このような多種多様な読み出しパターンに対応しながら、データを複製してコントロールを保つことは容易ではありません。このような問題に対する解決策は、4章で紹介します。

1.4　ソフトウェアの提供速度の変化

今日の世界では、ソフトウェアベースのサービスが多くのビジネスの中核をなしています。このため、新しい特長や機能を迅速に提供することが求められています。よりアジリティが求められる中、Amazon、Netflix、Meta、Google、Uberなどの企業では、新たな思想が生まれています。これらの企業は2つの信念に基づいてソフトウェア開発を進めてきています。

1つ目の信念は、システム開発のライフサイクルを短縮し、ソフトウェアを高品質で継続的に提供するには、ソフトウェア開発（Dev）とIT運用（Ops）を融合しなければならない、というものです。このような考え方を**DevOps**と呼びます。この方法論では、自律性や、オープンなコミュニケーション、信頼、透明性、分野を超えたチームワークを受け入れる新しいカルチャーが必要となります。

もう1つの信念は、開発するアプリケーションの大きさについてです。アプリケーションがより小さく分解されたサービスになれば、柔軟性と開発速度が増

すと考えられています。このような開発方法については、いくつかのバズワードが存在します。例えば、**マイクロサービス**（https://microservices.io）、**コンテナ**、**Kubernetes**（https://kubernetes.io）、**ドメイン駆動設計**、**サーバーレスコンピューティング**などです。ここではすべてについて詳しく説明するつもりはありません。ただ、ソフトウェア開発におけるこのような進化には、複雑さの増大や、データをより適切にコントロールしたいという要求の高まりなどが関係していることを認識しておいてください。

モノリス型のアプリケーションから分散型アプリケーション（例えば、マイクロサービス）への移行は、データ管理に多くの課題をもたらします。アプリケーションを小さなピースに分割すると、データもまた、さまざまな小さなコンポーネントに散らばります。開発チームは、データモデルやすべてのデータオブジェクトをまとめる（単一の）一意なデータストアから、データオブジェクトがあちこちに散らばるような設計に考え方を変えなければなりません。これにより、ネットワーク通信の増大や、読み出し用にデータを複製し同期を行うこと、多数のデータセットを結合する際の手間、データの一貫性の問題、参照整合性の課題などが発生します。

最近のソフトウェア開発のトレンドの変化に伴い、より細分化されたアプリケーションに対して、データ流通を実現するアーキテクチャが必要となっています。また新しい**DataOps**（https://oreil.ly/G8Bt4）のカルチャーと、データの相互運用性、イベントの捕捉、再現可能で疎結合に重点を置いた設計哲学も必要です。この点については、2章で詳しく説明します。

1.5　クラウドがデータ管理に与える影響は計り知れない

ネットワークは高速化しており、帯域幅は年々増加しています。大手クラウドベンダーは、クラウド上でテラバイト級のデータを数分で移動できることを実証しています。このようにテラバイト単位のデータが移動できることで、面白いアプローチが可能になります。これまでは、ネットワークの制約から、計算能力をデータに近づけるのが、一般的なベストプラクティスでした。これからは、逆に、データを移動して、計算能力に近づけることができます。ネットワークはもはやボトルネックではないのです。データを素早く移動させ、アプリケーションがデータを消費（利用）できるようにすることが可能です。このモデルは、SaaS（Software as a Service）やMLaaS（Machine Learning as a Service）市場が普及するにつれ、特に人気となっています。複雑な作業をす

べて内部で行うのではなく、ネットワークを使って大量のデータをほかのパーティに提供することができます。

しかし、コピー（複製）して、クラウドデータセンターなどの他組織の計算能力に対してデータを移動するという、この分散パターンは、データランドスケープをさらに断片化することになります。このため、データ管理戦略を明確化することが、これまで以上に重要になります。データの断片化は、データアクセスの遅延によってパフォーマンスに悪影響を与える可能性があるため、そのガイドラインを示す必要があります。また、クラウドサービスプロバイダーは、計算能力とストレージを分離して設計し、それぞれ独立して拡張できるようにしているため、データの構成やモデル化もこれまでとは異なる方法で行う必要があります。

1.6　プライバシーとセキュリティは最優先事項

データソースの多様化とデータ量の増大に対応して、企業はデータセキュリティについて見直す必要があります。最適化、革新、差別化を目指す組織にとって、データが重要であることは間違いありません。しかし、データの不正利用、差別、民主主義の価値を損なう社会的影響など、望ましくない暗黒面も存在します。ここでは、データプライバシーとセキュリティを不適切に取り扱った場合にどのような影響が生じるかを理解してもらうために、いくつかの事例を紹介しましょう。

UpGuard（https://oreil.ly/TzrsU）は、これまでに起きた大規模なデータ漏洩のリストを管理しています。その多くは、同じミスを悪用されたものです。ケンブリッジ・アナリティカの情報漏洩（https://oreil.ly/lLZSG）やマリオットの5億件のアカウントハッキング（https://oreil.ly/0zJdf）は、大きな被害をもたらした代表的な例です。私たちの生活や業務のあらゆる部分がインターネットに接続されるようになったため、政府はますますセキュリティやプライバシーに深くかかわろうとするようになっています。COVID-19の大流行は、私たちの多くが自宅での仕事や交流を強いられ、このトレンドに拍車をかけました。企業は、知的財産権の侵害やデータプライバシーに関する不祥事という脅威から目をそらすわけにはいきません。

膨大なデータ、より強力なアドバンストアナリティクス、より高速なデータ流通のトレンドは、データの危険性をめぐる議論を引き起こし、倫理的な疑念や論争を巻き起こしています。 筆者の国の例を紹介しましょう。オランダでは、

オランダ税務当局が違法かつ差別的な活動を行っていました。二重国籍者をシステムで追跡し、人種や民族の分類を使って、育児手当の受給資格のモデルを訓練したのです。その結果、何千もの家族が誤って犯罪者に分類され、給付が停止されたのです。ときには、書類に正しく署名しなかったなどの理由で、すでに受給していた金額の返済を命じられることもありました。 債務整理の適用を拒否され、家や財産を売却せざるを得なくなった人もいました。

これは不適切なデータ利用の一例にすぎません。組織が間違いを犯し、倫理的な一線を越えてしまうのは避けられません。このため、今後は政府も法規制を強化し、セキュリティやコントロールの向上や、インサイトの提供などを求めることでしょう。ここで取り上げたデータプライバシーと倫理的問題は、氷山の一角に過ぎないのです。欧州で施行されるデータガバナンスに関する新しい法律（https://oreil.ly/phxAG）や人工知能に関する法律（https://oreil.ly/NiT1T）などの規制により、大企業はどのようなデータが収集・購入され、どのようなデータが組み合わされ、分析モデル内でどのようにデータが使用され、どのようなデータが流通（販売）されるのかについて明らかにしなければならなくなるでしょう。大企業は、透明性とプライバシーファーストの取り組み、そして大規模な法規制問題への対処方法について、もしまだ考えていないのであれば、今すぐ考え始める必要があるでしょう。

法規制は難しい問題です。複数のクラウドリージョンやSaaSサービスが利用され、データが分散している状況を想像してみてください。GDPR（https://gdpr-info.eu）、CCPA（https://oreil.ly/xzWpY）、BCBS 239（https://oreil.ly/zFj8I）、新たに制定された大西洋横断データプライバシーフレームワーク（https://oreil.ly/qDuto）などの法規制を遵守することは困難です。なぜなら、企業はすべての個人データを、保管場所にかかわらず把握し管理しなければならないからです。データガバナンスと個人データを正しく取り扱うことは、多くの大企業にとって最優先の課題となっています[†8]。

[†8] **個人情報**とは、自然人に関連するもので、特定の個人を識別した、または識別可能なあらゆる情報です。

このような法規制の強化やデータ倫理に関する懸念により、さらなる制限、プロセスの追加、統制強化が行われます。データがどこから来たのか、データがどのように流通しているのかを把握することは非常に重要です。その結果、企

業には、より強力な内部ガバナンスが求められます。しかし、このような統制強化のトレンドは、ソフトウェアの高速開発の方法論とは相反するものです。高速開発の方法論では、ドキュメント化されるものが少なく、内部統制は強くないからです。この対立を解消するには、より統合されたプロセスと高度なツールによって、これまでとは異なる、より防衛的な視点でデータ管理を行う必要となります。これらの懸念事項に関しては、8章で説明します。

1.7　運用システムと分析システムの統合の必要性

ビジネスイベントに迅速に対応しなければならないため、新たな課題が生じます。一般的に、トランザクション（運用）システムは、大量のデータを提供したり、データを絶えず出力したりするには適していません。このため、伝統的に、トランザクションアプリケーションと分析アプリケーションは明確に分離されていました。データ戦略を運用用のトランザクション処理と、分析用のデータウェアハウスやビッグデータ処理の2つに分けることがベストプラクティスとして信じられています。

しかし、この考え方は今後崩壊する可能性があります。**運用分析**は、既存の運用プロセスを予測・改善することに重点を置いており、トランザクションシステムと分析システムの両方と密接に連携する必要があります。分析結果は、運用システムのコアに統合し、運用に関するインサイトが得られるようにする必要があります。イベントが状態を伝えるように設計されていれば、同一のイベントを業務上の意思決定やデータ流通などに利用することができます。

このようなトレンドにより、運用システムと分析システムの両方を同時に適切に管理するために、これまでとは異なる統合アーキテクチャが必要となります。また、運用システムと分析システムでは、データを取り扱う速度が異なるため、データ統合を異なる速度で行う必要があります。本書では、過去データを元々の運用コンテキストで保存しながら、運用システムと分析システムの両方で同時に利用可能にする方法について検討を進めます。

1.8　組織は共同エコシステムで運営される

多くの人は、すべてのビジネス活動は、企業内の単一の論理的境界の中で行われると考えています。実際はそうではありません。多くの組織はほかの組織と密接に連携しているためです。自社のコアビジネスケイパビリティをサードパーティのサービスと統合することが増えてきています。データを素早く流通さ

せたり、オープンデータ[†9]を取り入れたり、APIを一般公開したりする必要があるため、このような協力関係は、アーキテクチャの設計に大きく影響します。

[†9] オープンデータとは、自由に利用でき、一般に公開されているものを指します。

このような変化により、データは環境間で分散されることが多くなり、その結果、非中央集権化が進んでいます。データを他社と共有したり、クラウドやSaaSのソリューションで利用したりすると、データは異なる場所に置かれることになり、統合やデータ管理が難しくなります。さらに、プラットフォームや環境間でデータを移動させる場合、ネットワークの帯域幅、接続性、遅延などの問題がどうしても発生します。単一のパブリッククラウドや単一のプラットフォームを使うようにしても、これらの課題を解決することはできません。なぜなら、非中央集権化は将来の姿だからです。つまり、APIやSaaSシステムを効率的に利用し、パブリッククラウドの機能を活用したいのであれば、データ統合をマスターする必要があります。その方法を本書では紹介していきます。

本書で取り上げるトレンドは、人々がデータを利用する方法や、企業がアーキテクチャを構築する方法に影響を与える大きなものです。データの増加は加速しており、計算能力は増大し、分析技術は進歩しています。データの消費量は増加しているため、データを素早く流通させる必要があります。このため、より強力なデータガバナンスが必要です。また、クラウドサービス、SaaS、マイクロサービスなどのトレンドにより、データ管理は非中央集権化へと導かれます。さらに、これらの要素は、競争力強化のために、早期の市場投入という要求ともバランスを取らなければなりません。このような変化に対応するためには、これまでとはまったく異なる方法でデータを管理する必要があります。

1.9　企業を悩ます時代遅れのデータアーキテクチャ

多くの企業が抱えている大きな問題として、現在のエンタープライズデータアーキテクチャから価値を引き出すことが挙げられます[†10]。データアーキテクチャの多くは、エンタープライズデータウェアハウス（EDW）[†11]やデータレイクを活用したモノリス型の設計を使用し、データを中央集権的に管理し流通させています。しかし、高度に分散化され、コンシューマ駆動の環境では、こ

のようなアーキテクチャは将来のニーズを満たすことはできません。これらのアーキテクチャの特徴を見てみましょう。

[†10] 企業のデータアーキテクチャとは、情報アーキテクチャの分析要件を満たすために必要なインフラストラクチャー、データ、スキーマ、統合、変換、ストレージ、ワークフローなどのことです。

[†11] （エンタープライズ）データウェアハウスの概要や、なぜ大規模化できないのかについては、筆者のブログ記事“The Extinction of Enterprise Data Warehousing!”（https://oreil.ly/RO6Hv）をご覧ください。

1.9.1　エンタープライズデータウェアハウス：信頼できる唯一の情報源

ほとんどの企業において、第一世代のデータアーキテクチャは、**データウェアハウス**と**ビジネスインテリジェンス**を基盤としています。その根底にある考え方は、中央集権化こそがデータ管理の問題を解決する銀の弾丸（特効薬）であるというものです。この手法では、統合データリポジトリが、組織全体に対して1つだけ存在することになります。そして、このリポジトリには、数年分にわたる正確で信頼性の高いデータが格納されます。しかし、大規模にデータを流通させるとなると、このようなモノリス型の設計にはいくつかの欠点が存在します。

企業のデータを統合するのは非常に複雑な作業であり、完了するまでに多大な年月を要します。たとえデータの属性名が似ていたとしても、データの意味がドメイン[†12]、部門、システムによって異なっているケースは少なくありません。そのため、多くのバリエーションを作るか、一貫性がなくても違いをそのまま受け入れることになります。データが増えれば増えるほど、そして矛盾や不整合が生じれば生じるほど、データを調和させることは難しくなります。さらに、機械学習などのアドバンストアナリティクスでは、コンテキストがおかしいことは重大な問題となり得ます。なぜなら、データに意味がなかったり、理解不能であったりしていては、未来を正しく予測することは不可能だからです。

[†12] **ドメイン**とは、コンピュータプログラミングの分野において、特定の問題を解決するために構築されたソフトウェアプログラムにおける共通の要件、用語、機能を定義する領域のことです。

エンタープライズデータウェアハウスは、図1-2に示すように、**統合データベース**（https://oreil.ly/vDCOh）のような役割を果たします。データを使用する複数アプリケーションのデータストアとして機能します。つまり、データウェアハウスはデータにアクセスするすべてのアプリケーション間の結合点になります。中央集権化がデータ管理の解決策であると思われがちですが、それには中央に一つのチームを置き、一つのデータプラットフォームを構築し、一つのETLフレームワークと一つの標準モデルを使用するなど、すべてのデータと管理活動を中央集権化しなければなりません。しかし、中央集権型のアーキテクチャでは、さまざまなアプリケーション間で強い相互依存が生じるため、変更する際には慎重に行わなければなりません。このように結合が密で、変更が容易でない設計を作り上げた場合、エンジニアの中には「大きな泥だんご」を作ってしまったと言う人もいます。

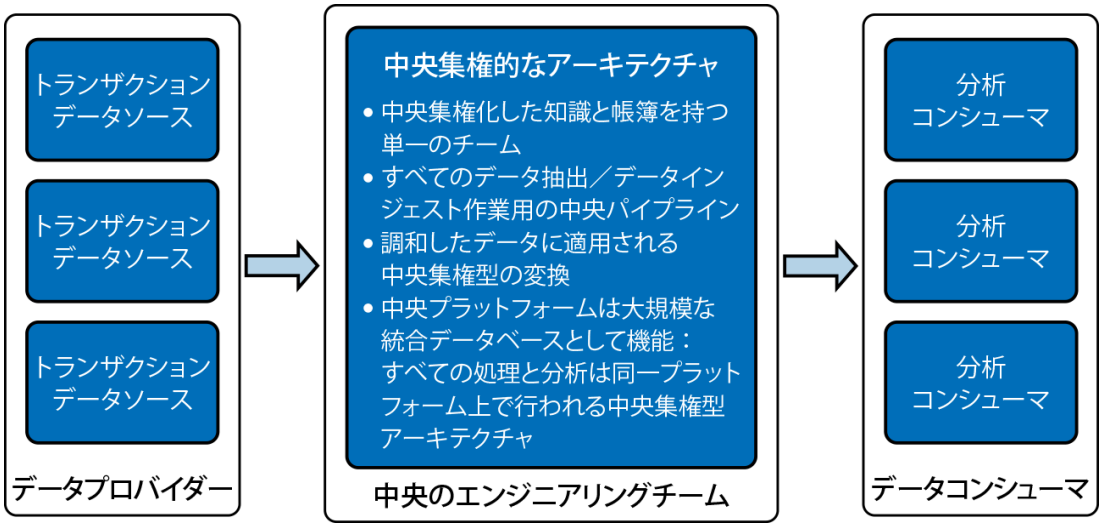

図1-2　中央集権的なアーキテクチャは、多くの組織にとってボトルネックになっている。チームはほかのチームが作業を終えるのを待たなければならないから

大きな泥だんご

大きな泥だんご（https://oreil.ly/8bY2t）とは、無造作に構造化された、広大でずさんな、ダクトテープと針金でまとめたような、スパゲティコードのジャングルのことです。この言葉は、Brian Foote氏とJoseph Yoder氏によって提

唱されたものです。モノリス型で、理解しにくく、保守が困難で、依存関係が多く、密結合しているシステムアーキテクチャを表した言葉です。**図1-3**は、このようなアーキテクチャを表す依存関係図（https://oreil.ly/Fdckr）です。それぞれの線は、2つのソフトウェアコンポーネントの依存関係を表しています。

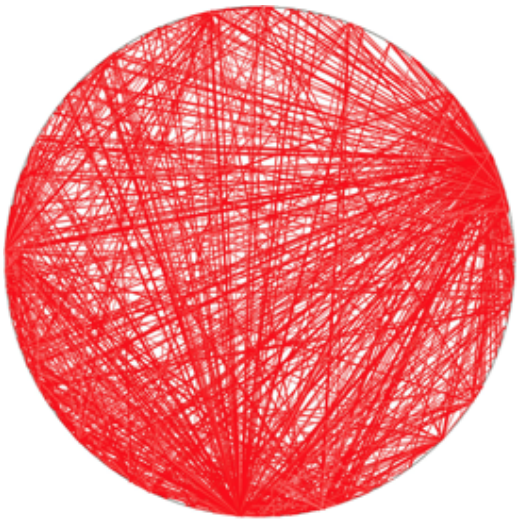

図1-3　大きな泥だんごの依存関係図

大きな泥だんごは、ご覧のように、すべてのコンポーネント間に非常に強い依存関係があります。このため、ほかのコンポーネントに影響を与えずに、あるコンポーネントだけを変更することは事実上不可能です。データウェアハウスには、レイヤーや、ビュー、無数のテーブル、関係性、スクリプト、ETLジョブ、スケジューリングフローなどが含まれます。これらが絡み合い、依存関係が混沌とした状態になり、大きな泥だんごとなってしまうことが多いのです。

データウェアハウスは非常に複雑で、単一の中央チームが管理しているため、アジリティの欠如が懸念事項になりがちです。このように待ち時間が増えていくと、人々は（悪い意味で）創造的になります。例えば、エンジニアは統合レイヤーをバイパスして、ステージングレイヤーからデータマートに直接データをマッピングしようとします。また、さまざまなレイヤーからデータを素早く組み合わせるためにビューを作成してしまう開発者も出てくるかもしれません。このような試みは、**技術的負債**（将来の手直し）として蓄積されていき、後々大きな問題になります。中央チームの対応を待てなかったために生み出された創造性やショートカットによって、アーキテクチャはより複雑になり、インサイトを失ってしまうことになるでしょう。

さらに、データウェアハウスは、特定のソリューションやテクノロジーと密接に結び付いているため、異なる読み出しパターンを必要とするデータコンシューマは、データをほかの環境にエクスポートしなければなりません。ベンダーの変更や、新しいタイプのデータベースが登場すると、データウェアハウスが、データを管理する場所とは離れた場所にデータを流通する必要が出てくることがあります。このような流れは、（高価な）ハードウェアを活用するという長期的な構想を根底から覆してしまいます。

過去データのライフサイクル管理も、よく問題となります。データウェアハウスは信頼できる情報のアーカイブと考えられています。データがデータウェアハウスに保持されることがわかっているので、運用システムは無関係なデータを削除することができます。しかし、データウェアハウスが登場した後に現れた高度な運用分析では、これが問題になることがあります。組織の全データを管理する中央チームによってデータが変換された場合、そのデータを配信したチームにはそのデータがもはや理解できなくなる（もしくは、本来の運用上のユースケースに使用できなくなる）可能性があります。さらに、多くのデータウェアハウスでは、通常、データを保存する前に何時間もデータを処理するため、データを素早く利用できるようにするのは大変かもしれません。これは、データを保存する前に、データを変換し、結合し、ほかのデータと統合する必要があるためです。

また、データの品質もよく問題になります。例えば、データウェアハウスのデータは誰のものでしょうか。ソースシステムのデータが壊れていたら誰が責任を取るのでしょうか。組織において、筆者がよく目にするのは、中央のエンジニアリングチームが、ほかのチームの引き起こしたデータ品質の問題に対処するというものです。ある例では、エンジニアがステージングレイヤーのデータを修正し、データウェアハウスに正しく読み込めるようにしていました。これらの修正処理は恒久的なものとなり、データ処理を開始する前に何百ものスクリプトを追加で適用しなければならなくなりました。これらのスクリプトは、信頼できるETLプロセスの一部ではないため、データのオーナーシップやリネージ（https://oreil.ly/tGbQC）を管理することもできなくなります。

法規制の問題もあります。特に、管理されている境界を越えてデータが持ち出された場合、データウェアハウスはデータのアドホックな消費や、さらに別の場所に流通されてしまうことに対して、追跡が困難になってしまいます。新しい法規制では、データのオーナーシップと、データの消費と流通に関する透明

性が重要となっています。どのような個人データが、誰に、どのような目的で消費されたかを説明できるようにする必要があるからです。

一般的に、データウェアハウスに蓄積されたデータの量、開発に要した年月、人々が持つ知識、ビジネスでの集中的な利用を考慮すると、マイグレーションはリスクと時間のかかる作業となります。そのため、多くの企業は、保守コストが高く柔軟性に欠けるにもかかわらず、このアーキテクチャを使用しつづけています。これらの企業は、ビジネスレポートや、ダッシュボード[†13]、データ消費量の多いアプリケーションなどへのデータ供給をデータウェアハウスに頼っています。。

[†13] レポートは主に表形式で構成されていますが、グラフが含まれることもあります。一方、ダッシュボードは、より視覚的で、さまざまな種類のグラフを使用します。

1.9.2　データレイク：構造化データと非構造化データに対する中央リポジトリ

データ量が増え、より迅速なインサイトが求められるようになると、エンジニアは別のコンセプトに着手しました。より大量の生データにアクセスするための方法として登場したのが、**データレイク**です[†14]。データを構造化せずにそのまま提供することで、コンシューマ側で、データをどのように使用し、どのように変換・統合するかを自由に決めることができます。

[†14] データレイクという用語は、Pentahoの最高技術責任者（CTO）であったJames Dixon氏によって作られました（https://oreil.ly/4E_WB）。

データレイクは、データウェアハウスと同じように、中央集権化された（モノリス型の）データリポジトリです。ただし、データウェアハウスとは異なり、変換、クレンジング、構造化される前のデータを保存します。そのため、スキーマが決められるのは、データを読み出す際になる場合が多いです。あらかじめ定義された固定の構造を使用するデータウェアハウスとは、ここが異なりま

す。また、データレイクは、構造化、半構造化、非構造化といった複数のデータ形式をサポートし、より多様なデータを提供してくれます。

多くのデータレイクでは、オリジナルのソースシステムから、修正されていない純粋な生データを収集しています。生のアプリケーション構造（正確なコピー）をそのまま渡すことで、データアナリストやデータサイエンティストは、データに素早くアクセスすることができます。しかし、生データの難しいところは、ユースケースごとにデータを修正する必要があることです。データ品質についても考える必要があります。変換も行わなければなりません。データのコンテキストを整えるために、ほかのデータと組み合わせなければなりません。何度も何度も作業を繰り返す必要があります。このため、データレイクは、一般的にデータウェアハウスと組み合わせて使用されます。この組み合わせにおいて、データウェアハウスは、クレンジングされ調和された高品質なデータのリポジトリとして使われます。一方で、データレイクは、分析を容易にするための多種多様な生データを保持する（アドホックな）分析環境として活用されます。

データレイクを設計するのは、データウェアハウスと同じように、非常に困難です。ガートナーやVentureBeat AI、デロイトなどは、ビッグデータプロジェクトの失敗率はかなり高く、おそらく60%を超えていると指摘しています[†15]。データレイクの導入が失敗する主な原因として、その膨大な複雑さ、メンテナンスの困難さ、依存関係などが挙げられます。

[†15] Brian T. O'Neill氏は、失敗率についてのリストを公開しています（https://oreil.ly/oxZ_D）。

- アプリケーションからデータレイクへプッシュされるデータは生データであることが多く、それぞれのアプリケーションにおいて、そのデータの内部的な構造をそのまま表現した複雑なものである可能性が高いでしょう。このような手法を採用すると、データレイクはすぐに何万ものテーブル、理解不能なデータ構造、アプリケーション自身しか理解できない技術的な値を含んだ寄せ集めになってしまいます。さらに、提供側のアプリケーションと同じ構造を共有するため、密結合になりやすくなります。コンシューマがこのデータを直接使用している場合、提供アプリケーションがデータ

構造を変更したときにデータパイプラインが壊れてしまうというリスクが存在します。

- データレイクにおける分析モデルは、多くの場合、生データと、調和されたデータの両方で訓練されます。データエンジニアとデータサイエンティストの両方がデータパイプラインを構築し、データを作成し、これらのデータパイプラインやモデルを操作します。作業は手動で行われる場合もあれば、データサイエンスプロジェクトの一環として自動化されている場合もあるでしょう。このような多様な操作が行われるため、データレイクにおいて運用上のリスクが高まります。
- データレイクは単一のプラットフォームであることが多く、さまざまなユースケースで共有されています。このようなプラットフォームは、密結合され、互換性の問題が生じやすくなります。また、ライブラリの共有や、構成管理などのために、保守が非常に難しくなります。

これらの問題は、ビッグデータプロジェクトが失敗しやすい原因のごく一部にすぎません。このほかにも、経営陣の抵抗や、社内政治、専門家の不足、セキュリティやガバナンスなどが原因として挙げられます。

1.9.3　中央集権の苦しみ

エンタープライズデータウェアハウスや中央集権型のデータレイクは、メタデータ駆動型ELT、データ仮想化（https://oreil.ly/g_dve）、クラウドサービス、分散処理、リアルタイムインジェスト、データをリッチ化する機械学習などの技術を使って、スケールアップすることができます。しかし、それよりも、はるかに大きな問題があります。それは、これらのアーキテクチャの背後にある中央集権的な考え方です。中央集権的な管理、中央集権的なデータオーナーシップ、中央集権的なクラスタ化されたリソース、中央集権的なデータモデルなどです。このような中央集権化の結果として、データ専門家がビジネスドメインから排除され、創造性やビジネスインサイトが失われてしまいます。チームは離れたところにいるために、常に相互コミュニケーションやチケット管理をしなければなりません。**ボトルネックになっているのは、中央集権的な運用モデル**なのです。中央チームは、すべての質問やリクエストに素早く対応することができないからです。組織がデータメッシュのような非中央集権的な方法論を採用し、ドメイン駆動設計を標榜しているのには、それなりの理由があるのです。ドメインチームによる連合型モデルは、非常に強力です。独立性と説明責任能力を向上させます。自律的なチームが並行してデータを管理、共有、消

費するため、大規模化が可能になります。そして、品質、協力体制、生産性が高まります。

しかし、非中央集権化には注意が必要です。連合型の責任分担を実現する場合は、まず中央から始める必要があります。企業レベルで標準を定義し、境界を設定し、専門知識と拡張性を提供しなければなりません。中央の権威がなければ、非中央集権的な権限委譲に混乱を招くことになりかねません。筆者の経験では、チームが独自のテクノロジー、相互運用性、メタデータ標準を定義し始めたことがありました。また、それぞれの部署が自分たちのデータを完全に管理することを義務付けたために、ほかのチームのデータと組み合わせることができなくなった場合もありました。さらに、チームが独自のデータモデリング標準、参照データ標準、粒度レベルなどを適用し、ドメイン間のデータの結合や統合が不可能になってしまった場合もありました。まとめると、非中央集権による大規模化にはリスクがつきものであり、組織、ガバナンス、テクノロジー、アーキテクチャを中央で適切に調整することで、このリスクを緩和できます。つまり、必要なのは**データ戦略**です。データ駆動型の組織を実現するために必要となるカルチャーや、組織と人材、アーキテクチャ、ガバナンスとプロセス、ルールを（再）定義するための構想です。

1.10　データ戦略の定義

データの重要性、最近のトレンド、中央集権化と非中央集権化に伴う課題を理解したところで、データトランスフォーメーションを成功させるための戦略的な道のりとはどのようなものでしょうか。この問いに答えるためには、企業のビジネスモデルと、その中でデータが果たす役割を深く理解する必要があります。ストラテジストとアーキテクトは、既存のビジネスモデルを変更する必要があるかどうか、また、例えば連合型を採用する環境が整っているかどうかを検討する必要があります。

まず、企業がどのような組織であり、どのような状況に置かれているかを分析することから始めるのが一般的です。ここから、企業の構成要素と、その戦略を実現するために活用されるアプリケーションやデータソース、プロセス、人材、そのほかのテクノロジーソリューションを結びつけるエンタープライズビューを策定する必要があります。このビューによって、企業の戦略目標を達成するための（データ）アーキテクチャが明確になり可視化されます。次の章では、これらの側面すべてに焦点をあてていきますが、まずはデータ戦略を定義するためのステップを見てみましょう。

戦略の策定は難しいものです。それは往々にして、どのようなビジネス価値が創出され得るのか、あるいは将来何が実現され得るのかを予測しなければならないからです。また、高レベルの目標をリソース、プロセス、サポート機能などとうまく組み合わせることも必要です。データ戦略がまだ存在しない場合、または自社の目標が明確でない場合は、以下の点について考えてみてください。

- まず、ビジネスの目標と戦略に焦点を当てましょう。最新のテクノロジーに関する宣伝文句に振り回されないでください。
- 会社のビジョンを理解し、データがそれをどのように推進させるかを考えてみましょう。ビジネス上の課題を解決するために、データがどのような役割を果たせるかを判断します。ビジネスインパクトを定量化しましょう。次に、今後3年間とそれ以降のコアビジネス戦略を定義します。
- 「守り」と「攻め」のバランスを見極めてください。完全にコントロールすることが最重要なのでしょうか。それとも、破壊的イノベーションのための柔軟性を確保したいのでしょうか。法規制が戦略に与える影響はどうでしょうか。これらの検討事項が、初期設計や、連合型の責任分担の方針に影響します。
- 明確で数値で測定できるマイルストーンを設定しましょう。データ戦略が成功し、価値が提供された時点を見極めるための計画を策定します。成果を測定するための指標と重要業績評価指標（KPI）を定義します。
- 組織全体に戦略が理解され、伝えられるように、意思疎通のための計画を作成します。
- 最初の重点領域を決定します。研究開発、法規制遵守、コスト削減、収益改善などです。
- 組織内において、成果を妨げる可能性のある障壁を特定し、それを回避する方法を探します。
- 自社の人材を活用する戦略を見直し、自社がデータを十分に活用できる組織かどうかを判断します。そうでない場合は、（カルチャー的な）転換と採用計画を立て、ビジネス部門を大規模データの管理と活用の責任者として再編成します。
- 次世代のIT機能がどのようなものかを定義します。将来のITはすべての業務に責任を持つのでしょうか。それとも、リーダーシップ、ベストプラクティス、教育、研究、サポートを提供するセンター・オブ・エクセレンス（CoE）として機能するのでしょうか。
- データ駆動型のカルチャーとはどのようなものかを定義しましょう。例えば、どのようなスキルや教育が必要かを明確にします。ビジネスユーザー

による完全なセルフサービスでのデータ利用を認めるつもりですか。データを他者と共有する意思はありますか。

- 既存の環境についてデータを集めます。例えば、すべての組織の事業部門は同じエコシステム境界の中に入っていますか。それとも、異なる環境で異なるルールを使っていますか。まず、さまざまな環境とデータソースを分析し、データランドスケープの高レベルの概観を作成することから始めましょう。データがどこで作成され、どのように流通され、使用されているかを調査してください。
- ソフトウェア開発手法を変える必要があるかどうかを判断します。もし必要であれば、それが次世代アーキテクチャを開発する際の提供モデルにどのような影響を与えるかを判断します。
- 将来に向けた移行をどうするかを明確にします。移行は急激であるべきでしょうか。それとも自然な流れで良いのでしょうか。
- 初めに、ある程度の上位レベルのテクノロジーについて選択します。例えば、データ処理にスケーラブルなクラウドコンピューティングを活用しますか。柔軟性と適応性を重視し、ベンダーに左右されないIT機能を開発したいですか。それとも、ベンダーロックインのリスクを承知で、ベンダー固有のサービスを利用しますか。
- なぜ実行するのか、何をするのか、どのようなギャップが存在するのか、ロードマップ、投資事例など、重要な要素を盛り込んだ、エグゼクティブ向けの高レベルなプレゼンテーションを作成します。
- 予算と目標およびユースケースを照らし合わせ、コスト管理に関する戦略を策定します。データ管理への投資に対する見直しと意志決定のための計画を決めます。さらに、予算をITライフサイクル管理プロセスと整合させましょう。ITライフサイクル管理プロセスには、計画、アウトソーシング、調達、配備、撤退のプロセスなどが含まれます[†16]。

[†16] テクノロジーは移り変わりが激しいので、いつかはリプレースやアップグレードが必要になります。

これらの行動指針に対応することで、高レベルの目標と戦略を明確にすることができるはずです。これを最初に行うことが重要です。なぜなら、戦略の方針は、アーキテクチャ、プロセス、業務プロセス、移行ロードマップ、ガバナンスなどを決定するための判断材料となるからです。

データ駆動型にするための戦略は、その組織の目標、事業の規模や種類、資金調達や投資の計画、既存のカルチャーや成熟度、ビジネス上の目的によって、組織ごとに異なることに注意してください。例えば、筆者が以前勤めていたABN AMRO社では、自社のデータ駆動型の銀行システムを利用されるお客様に対して、カスタマイズされシームレスで統一されたエクスペリエンスを提供したいと考えていました。そのため、個人、法人、海外のすべての事業部門を強く連携させ、 統合することにしました。つまり、すべての事業部門が同じデータ中心のエコシステムの中で業務を行い、同じデータの活用に取り組み、同じアーキテクチャの原則に従う必要があったのです。これを推進するにあたり、企業全体を設計、指導、コントロールするために、さまざまなエンタープライズアーキテクチャ機能も統合することになりました。

組織が変われば、データ戦略はまったく異なるものになるでしょう。例えば、ビジネス目標が組織全体で一致していない場合、標準化と統合の必要性は少ないかもしれません。もし昨今、データ漏洩というトラウマになるようなできごとを経験したのであれば、おそらくデータセキュリティに重点を置くことになるでしょう。データの収益化とパートナーシップの構築が主な目的であれば、経済的な価値をもたらすようなデータの相互運用や、データの購入側にとって消費する価値があるデータの提供に重点を置くことになるでしょう。重要なのは、データ戦略を現在および将来のビジネスニーズに合致させることです。

最後に、包括的な戦略は不要だと主張する人々がいることについて言及しておきます。準備が大変すぎると感じているのでしょう。計画を策定する代わりに、とにかく始めて、ユースケースを実装しながらその過程で何が起こるかを見るべきだと考えています。この手法は、確かにすぐに価値をもたらしてくれます。しかし長期的には、一貫性と標準化への取り組みが行われないため、アーキテクチャに悲惨な結果をもたらすことになるでしょう。指針となる計画がなければ、間違った方向に延々と進むことになりかねず、何度もやり直しや後戻りをしなければならなくなるからです。

1.11　まとめ

戦略はあらゆるデジタルトランスフォーメーションの出発点です。データがその中核をなすことは間違いありません。しかし、データが長期的な目標と夢に確実に役立つようにするにはどうすればいいのでしょうか。また、データを活用するために必要な組織改革をどのように進めればよいのでしょうか。そこで必要となるのが、ビジネスを隅から隅まで正しく理解するための俯瞰的な視点

です。成功に向けた計画を立てるには、まず全体像を把握する必要があります。具体的な課題領域に焦点を当てる前に、ビジネスをいったん俯瞰し、抽象化してください。そして、組織変革をサポートし、全体的な計画、仕事の進め方、ガバナンスモデルと連携するアーキテクチャと組織構造を明確にすることが必要です。本書を読み進めれば、このような考え方についてさらに理解が深まることでしょう。

データ戦略に必要なすべての要件と目標に見合うアーキテクチャを設計することは、変革において最も難しい部分です。まず、組織構造、アプリケーション、プロセス、データ環境の全体像を把握する必要があります。次に、柔軟性、オープン性、コントロール、時間、実現コスト、リスクなどのバランスをとりながら、さまざまなシナリオを検討します。それぞれのシナリオには、ロードマップ、変革後のアーキテクチャ、変革後の状態などを盛り込みます。この作業は、単純な視覚化よりもはるかに重要であり、コラボレーションを必要とする作業です。この際、重要な注意点があります。それは、将来の戦略的な方向性を定めることは、トップダウンで、ビジネスから始めるということです。IT部門だけで考えるべきではありません。

データ戦略において重要なことは、中央集権化と非中央集権化のバランスを取ることです。例えば、ガバナンスと作業を連合型にするのか、それともアーキテクチャとインフラストラクチャーを連合型にするのでしょうか。あるいはその両方でしょうか。このテーマについては、往々にして両極端な意見が見受けられ、混乱が生じています。例えば、データメッシュでは、中央集権的なデータ組織、アーキテクチャ、ガバナンスモデルへの反動から、まったく180度反対の方針を示しています。すべてのデータは、非中央集権的に管理されたインフラストラクチャーを使用して、ドメインによって非中央集権的に所有されなければならないと主張し、あらゆる面で非中央集権化を取り入れています。紙の上では、非中央集権化はビジネスリーダーやIT管理者の共感を得られますが、実際にはそう簡単ではありません。

非中央集権化にはリスクも伴います。組織全体に作業が広がれば広がるほど、戦略を整え、計画を調整・組織化することが難しくなります。また、それに加えて、データを適切に管理するために必要不可欠な企業カルチャーの形成や人材の確保も難しくなるからです。その結果、断片化が進み、「ビジネスモデルやドメインはいくつあるのか」、「データプラットフォームはいくつ必要なのか」といった新たな問題も生まれます。筆者の経験では、多くのアーキテクトやデータ担当者が非中央集権化で一番難しいと感じていた部分は、ドメインの

分割と境界の設定でした。多くの場合、ビジネスアーキテクチャとドメイン駆動設計に対する基本的な知識が欠如しています。多くのデータ担当者は、ドメイン駆動設計の概念が難しくて理解できないと感じています。また、単純化しすぎたり、オブジェクト指向プログラミングの手法をデータランドスケープに適用しようとする人もいます。

非中央集権化を実現する原則の対象には、データやプラットフォームの管理方法も含まれます。データエンジニアの間では、データプロダクトのオープンな相互運用標準がまだ存在しないため、懐疑的な意見も聞かれます。さらに、個々のチームが独立した環境で業務を行う場合、データの使い勝手が悪くなるのではないかという懸念もあります。

こうした意見に対しては、以降の章で議論していきます。次の章では、ヘリコプターを一段低いところを飛ぶようにして、アーキテクチャや、データドメイン、ランディングゾーンが十分理解できるところまで、読者のみなさんをご案内します。ドメイン関連の用語をわかりやすく説明し、実践的なガイダンスと現場からの視点も紹介することで、読者の理解を深めます。その後、ソースシステム側の上空を飛行し、いくつかの章を経て、次の旅へといざないます。それでは、良い旅を。