9章
メタデータによるデータの民主化

多くの人がOpenAIの力を目の当たりにしています。将来、メタデータと人工知能は融合していくことでしょう。強力なAIがメタデータについて学習しはじめたら、どんなことができるようになるでしょうか。その影響は計り知れません。現在行っているデータ統合の方法が大きく変わる可能性もあるでしょう。AIモデルは、言語を解釈し、予測し、コードを書くことができるようになるでしょう。AIは、データ品質の問題を修正したり、リネージに基づいてデータランドスケープをどのように整理・構造化するのが最適かについて提案したりできるようになるかもしれません。最高データ責任者は、こうしたトレンドに備える必要があります。メタデータがすべての中心になる、ということを理解しておいてください。

この章では、最新のデータアーキテクチャにおけるメタデータの役割と、メタデータをどのように管理しなければならないかについて、詳しく見ていくことにします。これまで学んできたように、**メタデータ**は、新しいアーキテクチャに必要な情報をすべて提供してくれます。メタデータはすべてを結び付け、大企業が必要とするインサイト、コントロール、効率化を実現するための鍵になります。

メタデータは、多くのツール、アプリケーション、プラットフォーム、環境に散在しているため、管理も複雑になります。一般に、大規模なデータアーキテクチャには、多数のメタデータリポジトリが存在しています。また、ほとんどのメタデータは特定のベンダー製品に緊密に結び付いています。その量と多様性は膨大であるため、メタデータを管理する前に、適切に選択し、整理し、統合することが必要になります。この章では、優れたエンタープライズメタデータモデルのコアとなる要素について学びます。

メタデータ管理については、少しずつ成長させていくのが優れた戦略です。まず、最重要な領域を特定し、シンプルで小規模なものから始めます。また、サ

ービスや、明確なプロセスによってサポートするようにします。

まず、メタデータのさまざまなカテゴリーについて理解しておきましょう。

ビジネスメタデータ
ビジネスメタデータは、ガバナンスのためや、データを検索・理解するために使われるものについて記述したものです。例えば、ビジネス用語、定義、データオーナーシップに関する情報、データの利用や出所に関する情報などがあります。

技術的なメタデータ
技術的なメタデータは、設計時のデータ構造について記述したものです。例えば、スキーマ情報、データ形式や プロトコルに関する情報、暗号化キーや復号キーなどがあります。

運用メタデータ
運用メタデータは、実行時のデータ処理について記述したものです。例えば、プロセス情報、実行時間、プロセスが失敗したかどうかの情報、ジョブIDなどがあります。

ソーシャルメタデータ
ソーシャルメタデータは、エンドユーザーに関連するデータを記述したものです。例えば、利用状況やユーザー追跡情報、検索結果、フィルター、クリック数、閲覧時間、プロフィールアクセス数、レビュー、評価、コメントなどのデータがあります。

メタデータは、データファブリックや、AIがサポートするデータガバナンスなど、最新コンセプトの基盤にもなります。例えばGartnerが示したビジョンでは、実際のデータそのものへのポインタを持つナレッジグラフを利用するというものがあります。このナレッジグラフは、ML（機械学習）を活用したインテリジェントエンジンを使って、調和され統合されたデータセットを自動的に作成します。このような高度なソリューションを構築するには、メタデータの収集、発見、保守、利用を自動化し、アーキテクチャの重要な要素とすることが必要です。そこで、この章では統合パターンにも注目し、特定のメタデータを中央集権的に永続化しなければならない理由について説明します。

車輪の再発明という事態を避けるために、できるだけ多くの統合パターンを再利用するのがベストです。

そして最後に、データの民主化と、データガバナンスを推進するためにメタデータをどのように利用できるかについて説明します。このためには、メタデータは企業レベルで遍在し、誰もがアクセスできるオープンなものでなければなりません。メタデータは、唯一の中心となるデータモデルなのです。

9.1　メタデータ管理

メタデータの概念とメタデータ管理に適用される原則そのものが考案されたのはもっと古いのですが、**メタデータ**という言葉自体は、1990年代に作られた「データについてのデータ」という意味の言葉です。この時代、多くのベンダーがメタデータの流行に乗り、データベースのデータとデータモデルを効率的に管理するためのツールを提供しました。これらのツールの大半は、アプリケーションのデータモデルを自動的に生成する、フォワードエンジニアリング機能も備えていました。この機能では、概念と依存関係を記述した概念データモデルと、論理アプリケーションデータモデルを使用することで、テーブル、列、外部キー関係、データ型などの物理アプリケーションデータモデルが自動的に生成されます。さらに、これらのツールでは、運用面にも考慮し、どのデータを有効にして、どのデータをアーカイブすべきかを判断できます。

ビッグデータや新たなテクノロジー（NoSQL、アドバンストアナリティクスなど）が登場した時代において、メタデータ管理はよりダイナミックで、多様化し、さまざまな形態を持ちはじめています。ビッグデータとともに、データカタログも盛り上がりを見せています。データカタログを利用することで、多くのデータを管理できるようになったからです。また、今日の変化のスピードやソリューションの多様性は、これまでのアーキテクチャと比べると、まったく異なったものになっています。

現在では、メタデータは、アプリケーション、データベース、データ統合テクノロジー、マスターデータ管理、クラウドインフラストラクチャー、分析サービスなど、あらゆる場所に存在します。その結果、メタデータはよりサイロ化

し、それぞれのプラットフォームやツールが、メタデータを管理するために独自のデータベースを持つこともあります。

このようにメタデータは散在しているため、メタデータを利用することが難しくなっています。ばらばらに散らばった連合型環境では、データがどこにあり、どのように移動し、何を意味するのかを把握することは困難です。この問題を解決するには、メタデータをさまざまな次元で結び付ける必要があります。つまり、企業規模のメタデータビューが必要なのです。

筆者の経験では、企業全体でメタデータを統合、自動化、コンソリデーションするプロセスには、標準化や、考え抜かれた選択、手順が必要です。メタデータ機能に対して、互換性のないテクノロジーが乱立すると、強力なデータ管理機能を構築するという熱意が損なわれてしまいます。このため、さまざまなソリューションの橋渡し、自動化の適用、どのメタデータが最適かを決めるなどの判断をしなければなりません。大きく3つの目標に絞って考えることをお勧めします。

- エンタープライズメタデータモデルを設計して、このモデルを基に、すべてのエンタープライズ領域とその属性および関係を表すメタモデルを実装します。
- 重要なメタデータコレクションを定義し、メタデータを収集するために最適なアーキテクチャを見極めます。筆者はメタレイクという新しいアーキテクチャを提案します。
- カタログやデータマーケットプレイスポータルなど、ナレッジグラフやセルフサービス機能を通じて、メタデータの価値を民主化し提供します。

以降の節では、それぞれの目的について詳しく説明します。

9.2　エンタープライズメタデータモデル

メタデータ管理は、少しずつ成長していきます。適切なブループリント、明確なプロセス、構成要素の適切な選択によってサポートします。メタデータのブループリントは、統合・統一されたモデルです。すべてのデータ管理の領域とテクノロジーにわたって機能します。ここで重要なのは、狭い範囲のカタログや商用メタデータソリューションにこだわるのではなく、より広い視野に立ち、エンタープライズメタデータモデルのコアとなるエンティティを見極めることです。

エンタープライズデータベースモデルを構築しなさい、と言っているのではなく、読者の組織を結び付けているものは何かを考えてほしいのです。自分に問いかけてみてください。どのようなビジネスメタデータが重要なのか。相互運用に必要となる技術的なメタデータは何か。どのようなドメインがあり、どのようなアプリケーションを使っているのかをどのように把握しているのか。どのようなプロセスやストリームでデータを取り込んでいるのか。アプリケーションとデータベースのモデルやスキーマはどこで作成され、管理されているのか。データガバナンス組織が適切に業務を遂行するために、どのような情報を、チームが中央に提供する必要があるのか。これらの質問に答えを見つけ出した後、各メタデータ領域ごとにコンテンツのライフサイクルをマッピングし、すべての依存関係を明らかにする必要があります。その結果、組織単位、ドメイン、ビジネスプロセス、テクノロジーコンポーネント、データプロダクトなど、多くのエンティティを結び付ける、ベンダーに依存しない統一メタデータモデルができあがります。

DataOpsはメタデータと深い関係がある

DataOpsは、組織内のチーム間のコミュニケーションや、統合、データフローの自動化の効率化に主眼を置いた、先進的かつ協調的なデータ管理手法です。また、全員が「同じ言葉で話す」ことで、データが何であり、何でないかに合意することでもあります。メタデータはこれらの意味論を提供し、データの意味を広く理解できるようにします。したがって、DataOpsの実践にはメタデータ管理標準が必要になります。

メタデータモデル自体を構築する場合、最初は物事を抽象的なものにとどめておき、あまり多くの変更や複雑なものを、すぐに導入しないことをお勧めします。まずは、ドメイン、アプリケーションのリストや、権威あるデータソース（ゴールデンソース）、データベースとスキーマのメタデータ、データオーナーシップ、セキュリティなど基本的なことから始めましょう。徐々に範囲を広げていけば、メタデータ管理をコントロールできます。まとまりを作ることと、すべてのメタデータを統合できるようにすることが重要です。

9.2.1　メタモデルの実例

メタデータ管理については、データガバナンスソリューションを使用してメタモデルを構築することをお勧めします[†1]。これは、ブループリント（設計図）やマップと考えることができます。関係や基準点を使って、アーキテクチャを

ナビゲートしやすくしてくれます。メタモデルは、データがどのようにグループ化され、整理され、ほかの領域にマッピングされているかを示します。例えば、データがビジネスプロセスでどのように使用されているのか、データがどのようなプロジェクトに影響を与えているのか、最終的にデータがビジネスの日々の業務にどのように組み込まれているのかなどです。

[†1] **メタモデル**とは、一連のモデルを管理するモデルのことです。**意味論的モデル**は、項目の基本的な意味とモデル内の項目間の関係を表します。意味論的モデルが、メタモデルの出発点となります。

メタモデルの簡単な例として、2章で説明したオーシャニック航空の顧客管理ドメインについて考えてみましょう。データソースをスキャンした後、2つの物理データセットをカタログ化したとします。このカタログ化されたデータを、プロセス、部門、業務ライン、データオーナー、データプロダクトなどの概念に結び付けることによって管理したいとします。これはどのようにすれば良いのでしょうか。

図9-1に、Microsoft Purviewで作成したメタモデルの例を示します。これは、単に、どのメタデータ領域に注力するのかを示す図（マップ）です。メタモデルは論理エンティティとその間の関係から構築されます。

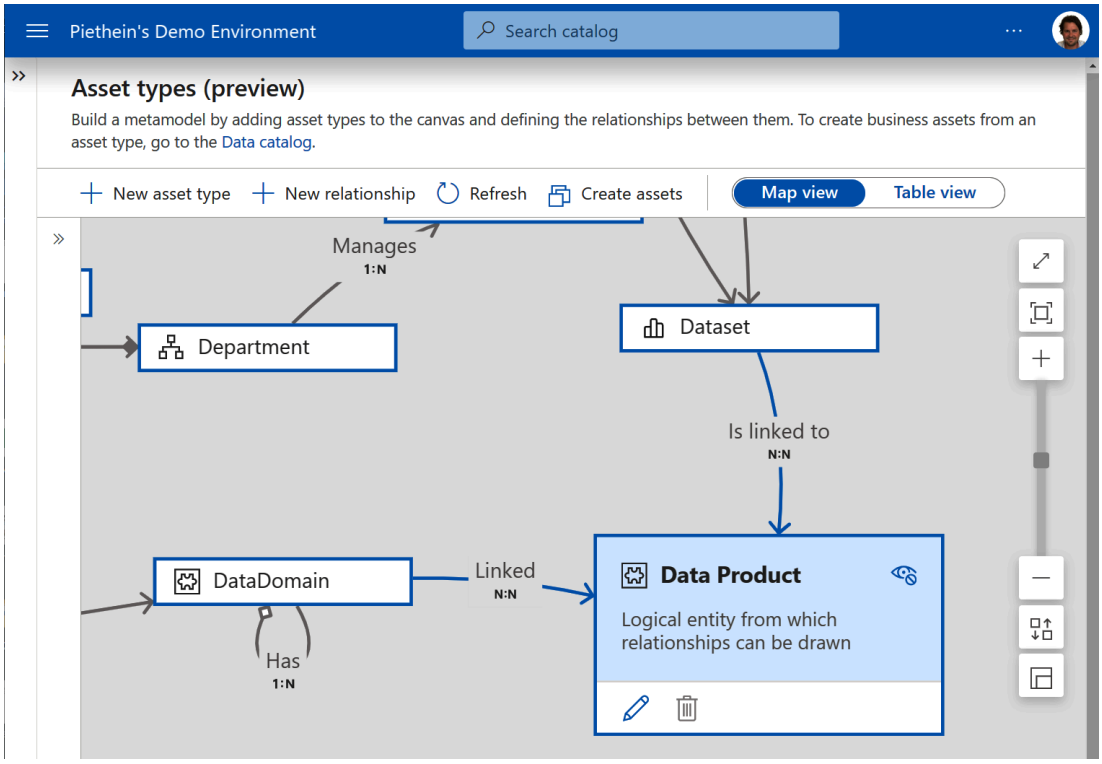

図9-1　Microsoft Purviewでメタモデルを管理する

この画面では、データプロダクトが論理エンティティとして定義されていることがわかります。また、データプロダクトは、データドメインと（物理）データセットという、ほかのエンティティとの関係も持っています。

このマップを使用してメタデータを管理する方法を説明しながら、具体化してみましょう。図9-2に、論理エンティティをインスタンス化し、実際に使用する方法の例を示します。ここでは、ブループリントを使用して「customer dataset」（顧客データセット）アセットをインスタンス化しています。このエンティティはデータプロダクトのすべてのプロパティを継承するため、名前、説明、データオーナーなどの情報を指定する必要があります。次に、マップを参照しながら、ほかのエンティティとの関係を定義します。

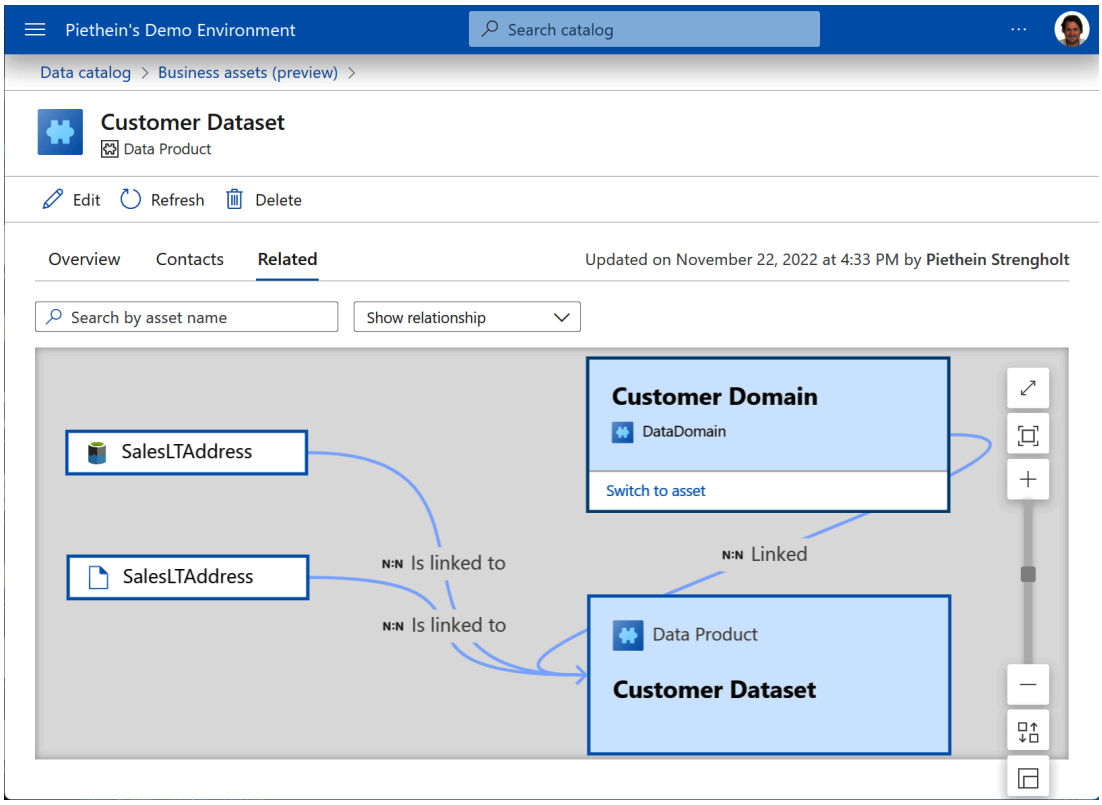

図9-2　Microsoft Purviewによるビジネスエンティティの可視化

図9-2では、customer datasetエンティティが、複数の項目に関連していることがわかります。この例では、（データドメインの論理エンティティに基づいて）customer domain（顧客ドメイン）ビジネスエンティティと、データセットの2つの物理表現です。データセットのうち1つはParquet形式で保存され、もう1つはCSV形式で保存されています。これらの情報をすべてメタモデルに記述すれば、customer domainとcustomer datasetが存在し、同じデータの物理的な表現が2つ存在することが誰にでもわかるようになります。

この例では、メタモデルの設計から、関係を導き出されることを学びました。設計に関係を追加したい場合は、線を増やします。今回示した例は比較的単純なものでしたが、完成段階のメタモデルは非常に大きなものになることがよくあります。多くのデータ管理やそのほかの分野にまたがり、多くの項目や関係を網羅し、外部コンテンツで拡張されることもあります。

メタモデルは、エンタープライズメタデータモデルを実装したものと見なせます。このモデルを出発点として使用することはできます。ただし、データガバナンスソリューションにおけるメタモデルの実際の実装は異なっている場合があります。例えば、概念レベルで定義した要件のサブセットしか含まれていなかったり、使用しているツールに制約があり、その制約のためにある特定の方法でメタモデルを調整する必要が生じたりする場合があります。以降の項では、メタデータモデルの基本要素について詳しく見ていきます。

9.2.2　データドメインとデータプロダクト

エンタープライズメタモデルの中心には、データドメインとデータプロダクトがあります。図9-3は、4章のデータプロダクトの定義を使用して、データプロダクトがどのようになっているかを示しています。4章では、データプロダクトは論理的なエンティティであり、管理やガバナンスが必要となる価値を表すことを学びました。データプロダクトは（前の項で見たように）（物理的な）データオブジェクト、アプリケーション、 プロセス、オーナー、ビジネス用語、使用条件などに関連付けることができます。

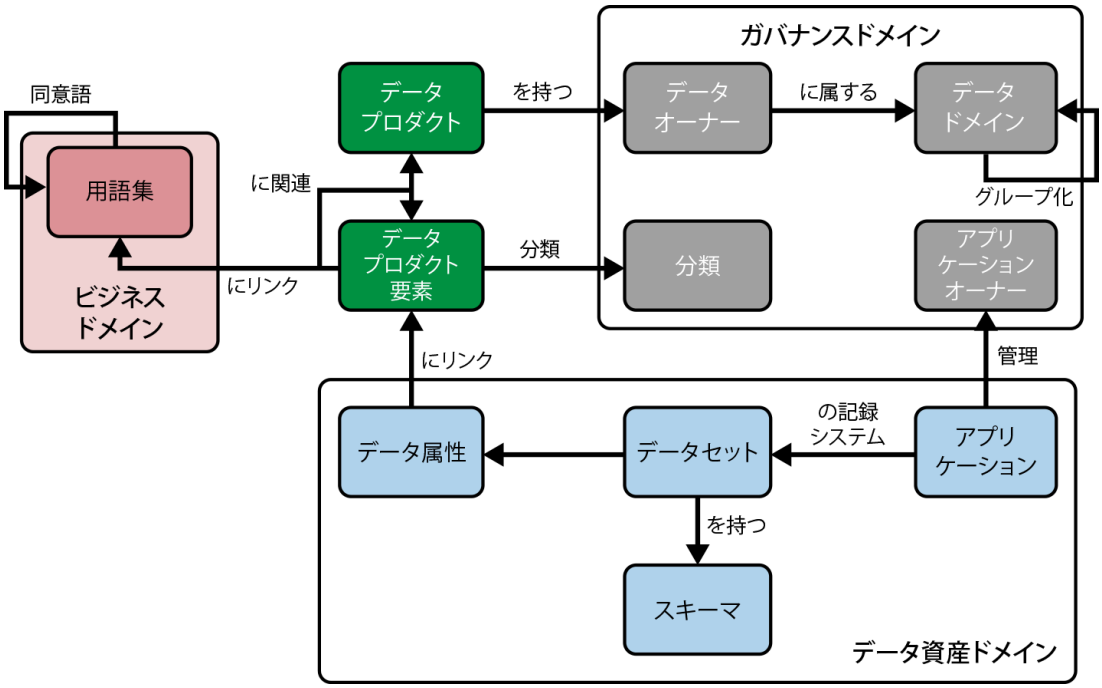

図9-3　データプロダクトのメタモデル設計

この情報を検索し追跡できるようにするには、メタモデルとメタデータをデータカタログで管理することをお勧めします。

データドメインとは、データを管理する境界のことです。バリューストリームやビジネスケイパビリティと整合させる必要があります。データ、プロセス、人材、テクノロジーはこれらのエンティティの内部でまとまりになっているため、データプロダクトと同じように、データドメインは、ほかのエンティティと多数の関係を持っています。

データプロダクトを管理するためのお勧めの方法は、まずデータプロダクトをメタモデル内で論理エンティティとして定義することです。図9-3に示すように、これを**データプロダクト要素**と呼ばれる別のエンティティに関連付けます。データプロダクト要素は、用語集や技術データ属性へのリンクピンとなり、直接リンクされることがよくあります。つまり、これも柔軟性を提供するための抽象化です。ビジネス用語とデータ属性が直接リンクされる場合が多いことを考慮すると、これらの要素をどのように設計し、実装すればよいでしょうか。これには2つの方法があります。

データプロダクトが用語集にリンクされ、その用語集がデータ属性と関係がある場合、その用語は「データプロダクト要素」を表していると言えます。この場合、カタログ内のこれらの要素をすばやくフィルタリングして検索する機能が必要になります。コンテキストを共有するだけのビジネス用語と、関係を保持しデータプロダクト要素（リンクピン）のように振る舞う用語集を簡単に区別できるようにしたいでしょう。

また、メタモデルに「データプロダクト要素」という別の論理エンティティを作成することもできます。このエンティティについては、説明が不要で、物理属性への関係が常に求められるように構成することをお勧めします。この場合の説明は、接続するビジネス用語を継承します。この方法でメタモデルを実装すると、データプロダクト要素を拡張してより多くのエンティティにリンクできる、というメリットがあります。つまり、この方法では、コンテキストをよ

り詳細に作成することができます。一方で、管理するオーバーヘッドが増えます。

次に、さまざまな種類の（概念的、論理的、物理的）データモデルが、メタデータモデルにどのように対応するかを見ていきます。

9.2.3　データモデル

データモデルを論理的に順序付けたりグループ化したりするのは容易なことではありません。モデルにはさまざまな種類やレベルがあるだけでなく、それぞれのレベルの中にも、成熟度、深さ、複雑さの度合いがそれぞれ異なるモデルがあります。さらに、どのレベルのモデル間にも、そして異なるレベルのモデル間にも関係があります。そこで、ベストプラクティスに入る前に、さまざまな種類のデータモデルと、そこからメタデータを抽出する方法を改めて見てみましょう。

9.2.3.1　概念データモデル

最上位レベルには、**概念データモデル**[†2]があります。概念データモデルは、フォークソノミー（https://oreil.ly/MuBUC）、オントロジー（https://oreil.ly/HLye3）、タクソノミー（https://oreil.ly/qeYLv）として設計されます。重要なビジネスの概念を要約し、ビジネスの観点から見た、データの意味と目的を説明するものです。これらは抽象的なものでもかまいません。ただし、すべてのビジネス用語に、定義、属性、依存関係を持たせて詳細に説明することをお勧めします。定義はドメインに特化したものであるべきです。データプロバイダーとデータコンシューマの双方のコンテキスト境界を理解し、ある特定のコンテキストにおけるデータの意味を、組織が十分に理解できるようにする必要があります。

[†2] 概念データモデルは、**ビジネスデータモデル**と呼ばれることもあります。また、**ドメイン**、**ドメインオブジェクト**、**分析オブジェクトモデル**と呼ばれることもあります。

概念データモデルや用語集には、コンテキストを明確にするために使われる概念も含まれます。ただし、アプリケーションやデータベースの設計では（まだ）直接的な役割は果たしません。また、将来の要件を表すものの、実際の設

計ではまだ使用されていない概念も含まれます。利用する用語が漏れてしまわないように、この点については、チームに意識させることをお勧めします。

概念データモデルは、多くの場合、ユーザーが作成した用語集の形になりますが、その大きさや表現にルールはありません。抽象的で高レベルなものから、属性、依存関係、関係、定義を詳細に記述したものまであります。概念データモデルや用語集は、単一のドメインについての説明だけに限定されるものではありません。複数のドメインにわたって、無数のアプリケーションや複数のデータベースに対応させてもかまいません。

ドメインの観点で見れば、特定のビジネスニーズを実現するために、複数のアプリケーションが連携する場合があります。つまり、概念データモデルや用語集とデータ属性の関係は、一対多になります。このルールの例外は、マスターデータ管理や企業全体のコンテキストなど、共有ビジネスケイパビリティや共有情報ドメインです。これらの場合、用語集とデータ属性の関係は通常多対多になり、ドメインをまたぎます。

なぜ概念データモデルが欠落しがちなのか

概念データモデルは、いくつかの理由で欠落しがちです。1つの理由としては、概念モデルは、例えばホワイトボード上のスケッチやドキュメントなど、暗黙のうちに作成されることが多いからです。デジタルデータとして保存されることがありません。また、概念モデルは、ほかのデータモデルと混同されることもよくあります。多くのビジネスユーザーやITの専門家は概念モデリングに精通していません。概念モデリングに関する専門知識や深い知識を持つ人はまれです。

また、概念モデルを記録し、すべてのアプリケーションにマッピングするための使い勝手の良いツールがないため、概念モデルの把握が困難になっています。ほとんどのツールは、狭い範囲のテクノロジーにしか対応していません。Protégé（https://protege.stanford.edu）は、OWLを使用して、概念データモデルを構築するための有名なオープンソースツールです。しかし、使い方を十分に学習しないと、非常に操作が難しいという欠点があります。

概念データモデルが欠落しがちな理由には、概念データモデルを作成することの意義を疑問視する人々がいるということもあります。アジャイル開発プロセスの中や、時間的な制約の中で、暗黙の了解や概念的なものをまったく管理しない、という決断を下すのを見たことがあります。このような状況では、ビジ

ネスユーザー、開発者、エンジニアは、アプリケーションを期限内に完成させるために安易な手段を取ることになります。

用語集におけるビジネス用語と定義については、さまざまな構成方法があります。例えば、ビジネスドメインに合わせた個別の用語集を作成したり、親子関係という階層構造を使用したりできます。このような論理的な区分は、同じ用語がドメインやチームによって異なる意味を持つ場合や、用語集の管理権限を各分野の専門家に与えたい場合に便利です。一貫性を確保し、ビジネスメタデータに関する付加情報を取得するために、命名規則や用語テンプレートを採用するのも良いでしょう。用語集の用語間には、**略語**、**関連用語**、**同義語**などの関係がある場合もあります。これらの関係を定義することで、混乱を避けることができます。また、同義語を明確にすることで、重複する用語を排除し、1つの用語に標準化することができ、管理のオーバーヘッドを削減することができます。

概念的データモデルにより明確にされることに、知識の重なりがあります。これは、コンテキストドメインが重なっていたり、ほかのドメインにまたがっていたり、より大きなドメインのスコープで管理されていたりするために当然起こることです。この概念レベルの構成は、結果的に、ソリューション空間を管理したり見たりする方法とは大きく異なります。ソリューション空間では、成果物（アプリケーション、データベース、ファイル、フォルダ、テーブルなど）は具体的なものです。このようなソリューションの成果物を設計するために、論理データモデルと物理データモデルを使用します。これらの下位レベルでは、境界をより厳密にするのが一般的です。

9.2.3.2　論理データモデル

概念データモデルの1つ下のレベルが**論理データモデル**です[†3]。この論理データモデルは、概念モデルから論理的に発展したものであり、ソリューション設計を始める場所となるものです。抽象的なビジネス用語がエンティティや属性に変換され、関係が把握されます。概念設計から論理設計への変換は、SqlDBM（https://sqldbm.com）やerwin Data Modeler（https://oreil.ly/Je4P3）などのデータモデリングツールから取得できるため、この種のメタデータを過去に遡って復元できる場合があります。

[†3] 論理的なアプリケーションとデータベースの設計は、テクノロジーを選択した際の、具体的な取り組みの第一歩です。つまり、テクノロジーをどのように選択するかは、設計に大きく影響します。関係データベースを選択する場合、論理モデルにはデータベースのテーブル、列、キーが含まれます。XMLドキュメントの場合、モデルにはXML要素、属性、参照が含まれます。

9.2.3.3　物理データモデル

一番下のレベルは、**物理データモデル**です。これは、どのデータベースやアプリケーションなどに、どのようなデータが格納されているかを正確に表すスキーマです。物理データモデルに関する情報をデータカタログに格納するには、3つの方法があります

- アプリケーション、データベース、レポートなどをスキャンし、メタデータを自動的にカタログにアップロードするようなコネクタ（エージェント）を使用します。
- データモデリングツールやフレームワークからメタデータを手動で抽出し、APIを使用してカタログにアップロードしたりインジェストしたりします。
- カタログ内部で情報を手動でドキュメント化（メタデータを提供）します。

データベーススキーマの設計では、セキュリティ、完全性、性能要件が重要になります。論理レベルでは、2つのオブジェクトを（論理テーブルとして）定義するかもしれませんが、性能上の理由から、2つのオブジェクトを同じ（物理）テーブルに格納する場合があります。したがって、物理的なデータベース設計は、論理モデルとはかなり異なるものになる場合があります。また、同じ論理アプリケーションデータモデルを使用しても、物理設計はまったく異なる実装になる場合もあります。例えば、同じ論理モデルを使用してトランザクションシステムやレポートシステムを実装することはできますが、それ

ぞれ独自の物理設計を使用することになるでしょう。

9.2.3.4　制限とベストプラクティス

これらすべてのモデルと、モデル間の関係に関する問題としては、すべてのツールが全種類のサービスやデータベースをカバーしているわけではないという点が挙げられます。ほとんどのカタログは、メタデータスキャナを提供し、物理モデルを論理モデルに、そして最終的には概念モデルにリバースエンジニアリングすることができます。このようにビジネス用語を技術的属性に関連付けることで、データをより速く見つけられるようになります。また、機械学習などの分析機能で拡張すれば、ユーザーが見たいと思うものをより正確に予測したり、データに隠された価値を発見したりすることができます。ただし、問題として、これらのスキャナがすべてのソリューションをカバーしているわけではない、ということが挙げられます。

データモデリングツールの適用範囲についても同じような問題があります。本書執筆時点では、すべてのデータベースをサポートするデータベースモデリングツールはありません[†4]。さらに、自動フォワードエンジニアリングは一部のデータベースにしか対応していません。

[†4] DBMS Tools（https://oreil.ly/Bzjd5）は、これらのツールの一覧と、それらがどのようなデータベースで動作するかについての情報を提供しています。

このような制限を考慮に入れると、使用するサービスや、データベースタイプ、スキャナ、データモデリングツールを標準化することをお勧めします。データソースでメタデータの抽出が困難または不可能な場合は、中央メタモデルを使用して、物理データモデルの上位レベルのものや、抽象化されたものをデータカタログに保存します。これにより、どのようなメタデータが管理されているのかについて、チームが少なくともある程度把握できるようになります。

データモデルに関するメタデータを収集する方法としては、**クラウドソーシング**という方法もあります。これは、大勢の知恵を利用し、使いやすく直感的なツールを使って、不足情報の収集作業を大規模に行うものです。このような方法では、データを処理するすべての人に、そのデータに関する情報を提供するための入力場所を提供します。クラウドソーシングは、リンク、注釈、説明、評価、コメントなどのコンテキスト情報の提供に便利な方法です。

メタデータのスキャン、エクスポート、クラウドソーシングという方法は、組み合わせたり混ぜ合わせたりすることができます。例えば、最初の概念モデルをスキャン、収集、生成するボトムアップの方法は、データオーナーやアプリケーションオーナーが手作業で修正を行い、最終的な結果を完成させることで実現されます。

アプリケーションとデータベースのメタデータを取得する主な利点は、ビジネス用語と、その基盤となるデータベース設計への変換が、組織にとってはっきりしたものになることです。これにより、技術チームは、新しい要件を迅速に評価・対応できるようになり、データにまつわる問題を解決できるようになるはずです。また、既存の知識を再利用することができ、データ移行や統合プロジェクトにも役立ちます。

さらに、データモデリングと設計のすべてのメタデータを関連付けることで、インテリジェントな統合と消費も実現できます。ビジネスメタデータが技術メタデータと関連付けられていれば、物理的なデータオブジェクトとそのデータ属性が、どこに保存されているかがわかります。そして、このデータを自動的に抽出し、結合・統合して、データコンシューマに提供することができます。この方法は、**オントロジーベースのデータ統合**（https://oreil.ly/9_YyJ）とも呼ばれています。

> データモデリングのメタデータが古くなっていると、データファブリック構想は失敗に終わります。正確なメタデータがないと、データの意味、ビジネス概念の変換、データの物理的表現、可用性、アドレス指定可能性に関する情報が欠落するため、自動化やインテリジェントなデータ統合が不可能になります。

9.2.4　データリネージ

リネージ情報とは、データの出所と、データが時間の経過とともにどこに移動したかを示すものです。リネージは重要です。なぜなら、リネージはアプリケーションの依存関係を示し、リネジージによってデータが情報サプライチェーンを通じてどのように流れているかを可視化できるからです。また、デバッグや変換ロジックについての情報も手に入れることができます。関係性、統計値、バリエーションに基づいて、リネージを使用することで、ソースシステムのデータ品質が、さまざまなデータコンシューマに与える影響を判断できる場合もあります。

リネージを取得するには、データモデルで使用したのと同じようにエクスポートという方法を使用できます。データカタログに付属しているスキャナは、多くの場合、この機能を備えています。このスキャナはクロールして、リネージを自動的に抽出します。このリネージには、変換の詳細が含まれます。また、コードの実行中にリネージを収集することもできます。例えば、Sparkノートブックを実行中に、APIやソフトウェア開発キット（SDK）を使用してリネージを取得できます。また、別のソースからリネージをアップロードするなどして、リネージを手動で提供することもできます。

メタデータ管理とデータガバナンスにおいて、リネージは重要な役割を果たします。そのため、リネージをどのように取得すべきかの原則と基準を設定することが重要です。例えば、チームが特殊なETLツールやプログラミング言語を使用している場合、リネージメタデータが格納されているカタログやリポジトリにリネージを渡すために、投資してカスタマイズしなければならないかもしれません。

9.2.5　そのほかのメタデータ領域

価値をもたらすメタデータの種類について、さらに見てみましょう。

アプリケーションメタデータ
ITプロセスとアプリケーションの開発をサポートするために、IT管理システムを使って、組織全体のアプリケーションの全リストを管理します。この情報は、アプリケーションオーナー、使用されているテクノロジー、運用上のインシデントなどに関するインサイトを提供するため、ユーザーにとって重要かもしれません。

コラボレーションメタデータ
コラボレーションによってもたらされるソーシャルメタデータは、大きな付加価値をもたらします。データを可視化し、知識を共有し、ユーザーがコラボレーションできるようにすることで、コミュニティが形成されま

す。コラボレーションメタデータの例としては、フィードバックフォーム、評価、投票、ブックマーク、コメントなどがあります。

データ品質メタデータ

データ品質に関するメタデータは、数多くのビジネスプロセスや分析モデルにとって必要不可欠なものです。これは、正確性、最新性、完全性など、さまざまなデータ品質の次元に従って評価されます。これらの評価指標やスコアは、監視対象となる物理データの属性に関連付けられます。

ビジネスアーキテクチャメタデータ

データにコンテキストを持たせるには、メタデータをビジネスアーキテクチャに関連付けます。ビジネスケイパビリティ、部門や部署などの組織構造、プロセス、アプリケーション、汎用アプリケーション機能などで、この作業を行うことができます。こうした情報により、データとドメイン駆動設計モデルを関連付け、どのようなプロセスにどのデータが存在するのかを識別できます。

テクノロジーメタデータ

テクノロジーメタデータには、サーバープラットフォーム、アプリケーション、データフロー、データストア、インフラストラクチャーなど、テクノロジーに関連付いたすべてのメタデータが含まれます。プラットフォームやビジネスケイパビリティの関係について、このような情報を持つことで、IT部門は、システム更新や変更を行う際に、保守や、バージョン管理、ベンダー管理、課題管理などがどのようにデータ管理に影響を与えるのかを把握することができます。

インタフェースメタデータ

インタフェースメタデータには、インタフェースの設計、バージョン番号、リネージ、配信パターン、スケジュールなどが含まれます。このようなメタデータを利用できることで、開発者やデータエンジニアは、インタフェースがどのように機能し、どのようなデータが利用可能で、各インタフェースにどのようなトレンドが存在するのかを知ることができます。また、インタフェースメタデータにより、互換性のテストと検証が容易になり、データコンシューマが安全に購読できるようになります。

ビジネスインテリジェンスとMLのメタデータ

最後に、ビジネスインテリジェンス（BI）や機械学習（ML）サービスに関連するメタデータを紹介します。レポート用メタデータ、モデル管理用メタデータなどがこれにあたります。このメタデータには、ソースからレポートまで、一連のジョブや小さな変換を通じて、データがどのように移動したかを示すリネージや、さまざまなモデルがどのようなデータセットで学習されたかを示す情報なども含まれます。このような情報を収集することで、個々の測定値や数値にどのような粒度のデータが使用されたのかを知ることができます。

このように、メタデータとその管理は、組織に多くの価値をもたらします。メタデータを効率的に管理すればするほど、より多くのインサイトが得られま

す。開発期間を短縮し、メンテナンスの手間を省き、コストを削減することができます。また、コンプライアンスに対応し、アーキテクチャ全体をセキュアにすることにもつながります。メタデータをまとめるのは大変な作業です。そこで、メタデータレイクがどのように役立つのかを見ていくことにしましょう。

9.3　メタレイクアーキテクチャ

データ管理を成功させたいのであれば、メタデータレイク（**メタレイク**）が必要です。メタレイクとは、あらゆる種類のメタデータを保存・管理する統合リポジトリのことです。データ管理のための情報を提供するために使用されます。メタレイクによって実現されることは、ビジネスユーザーが利用可能なデータを把握できるようにすることだけではありません。メタレイクを使えば、最高データ責任者は、データ管理を次のレベルに引き上げることも可能になります。データレイクによって、データ管理部門は、データの発見、リネージ、データ利用、データ品質、データオブザーバビリティなどを監視できるようになります。それでは、メタレイクの主なアーキテクチャコンポーネントを見てみましょう。

9.3.1　カタログの役割

メタレイクアーキテクチャの重要なコンポーネントの1つがデータカタログです。簡単に言えば、データカタログとはメタデータのコレクションを管理するリポジトリやインベントリのことです[†5]。データカタログはデータ管理や検索サービスと組み合わされることがよくあります。データカタログは、データアナリストやそのほかのユーザーが必要とするデータを簡単に見つけられるようにします。また、目的とするユースケースや将来のユースケースに対するデータの適性を評価するための情報を提供する場合もあります。

[†5] Microsoft Purviewと連合型の作業方法のベストプラクティスについては、筆者のブログ記事（https://oreil.ly/cR1hh）をご覧ください。

Ole Olesen-Bagneux著“The Enterprise Data Catalog”（O'Reilly）は、データカタログの導入を計画している人にとって必読の一冊です。

しかし、問題は、データカタログがさまざまな理由で十分ではない場合が多いことです。まず、自動制御とプロアクティブな施行に関する機能が欠けています。次に、ほかのメタデータ収集サービスとの統合機能や、ほかのソースをスキャンしてメタデータをインテリジェントに発見しインジェストする機能が存在しないことがよくあります。このため、ユーザーが手作業でメタデータを入力しなければならない状況になったり、メタデータが古くなったり無効になったりする危険性があります。そして最後に、ベンダーがデータ管理をどう考えているのかが、カタログによって広められてしまいます。ベンダーの考え方は、読者の考えと一致しないかもしれません。組織がデータガバナンスをどのように行うかは、その組織が内部でどのように組織化されているかに大きく依存するためです。データガバナンスに関する要件は、一般的に企業ごとに大きく異なります。

データカタログの作成は複雑な作業になります。そのために必要なパターンは、4章、5章、6章で説明したものと同じです。

データカタログの持つ特性を踏まえた上で、どのように取り組めばよいのでしょうか。データカタログを大きな視点から見ることをお勧めします。データカタログをメタデータ管理アーキテクチャのコンポーネントとして位置づけ、ほかのサービスでその弱点を補完します。長所や気に入った機能は活用してください。ただし、ベンダーの考えに自分を当てはめようとはしないでください。これは言うは易く行うは難しで、製品の持つ欠点に対処するために投資を行える大企業にのみ可能なことかもしれません。中小企業ではそこまで手が回らな

いため、ある程度の妥協が必要になるかもしれません。データカタログの能力を十分に発揮させるには、プロセスや作業方法を変更しなければならない場合もあるでしょう。ここでは、いくつかのベストプラクティスを紹介します。

- 現在および将来的に管理したいメタデータを列挙して、メタデータ戦略を定めることから始めましょう。優先度の高い作業を特定し、メタデータオブジェクト間の関係を標準化します。また、データガバナンスの役割を、重要な作業、権限付与モデル、カタログ内で実行する必要のある作業と整合させます。
- ドメイン指向のやり方で作業を進めるには、スコープを明確にし、オーナーシップを委譲し、ビジネスメタデータと技術メタデータをデータドメインに整合させる必要があります。技術メタデータは、データ資産とソースをまとめるために使われます。このメタデータをクラスタリングし、境界を設定し、特定のドメインに整合させます。つまり、特定のドメインチームが管理するソースシステムやデータプロダクトの技術メタデータは、クラスタリングされ、そのチームによって管理されます。ビジネスメタデータも同じようにします。用語集内に個別の用語集や階層構造を作成し、これらをドメインに整合させます。さらに、用語集と技術的属性の関連付けは、ドメインに責任をもって行ってもらいます。こうすることで、データオーナーシップに関する透明性が生まれ、データの意味論が強化されます。
- データオーナーシップを整合させることから始めましょう。新しいデータを導入する際のワークフローは、オーナーを定義することから始めなければならないという原則を定めるために、エンタープライズアーキテクトとして尽力したことがあります。この原則により、明確にオーナーを設定することなく、データが共有されることを防ぐことができます。セマンティックディスカバリーにも同じような原則を導入することができます。用語集への関連付けが古くなっている場合は、データプロダクトの公開や共有を許可しないようにします。
- エンタープライズデータとマスターデータ管理のための特別な項目を作成します。どのようなデータがマスターデータ管理に含まれるかを把握しておくことが重要です。これには、MDMの対象となるデータのビジネス用語や、ドメインデータとの関係についての合意形成も含まれます。したがって、「ゴールデンソースデータ」の管理に施行されるビジネスルールやポリシーについても合意しておく必要があります。
- メタデータのライフサイクル管理ポリシーを定義し、それを実施します。メタデータ管理は1回限りの作業ではないので、メタデータのコレクション

が増えるのに合わせて、組織をサポートするプロセスを確立してください。

- ラベルと分類は厳密にして一貫性を持たせてください。自動的なデータ処理やセキュリティのプロセスで、これらを使用する場合は、ドメインが使用するラベルや分類を常にコントロールできるようにします。
- リネージに注意してください。ツールやサービス間で相互運用性が欠如していることが多いため、これはとりわけ困難です。そのため、チームにどのような変換サービスを提供するかについて、一貫性のある判断を行うことをお勧めします。
- すべてのデータをスキャンすることと、関連するデータだけをスキャンすることの間で、うまくバランスを取りましょう。すべてのデータをスキャンすると、何が重要で何が重要でないのかがはっきりせず、複雑になり過ぎます。

メタデータ管理、データカタログの導入と活用は難しい作業です。これらの作業の重要性に関心を持たせることで、トップダウンのアプローチを検討してください。構想、目的、進捗状況、マイルストーン、阻害要因を明確に伝えましょう。データ管理のビジョンに興味を持たせ、周囲の賛同を得ましょう。そうすることで、メタデータを完全で高品質なものにするために、ユーザーが協力的になります。このようなメタデータは、検索、保守、自動配信などの高度なサービスの基盤となります。これがメタレイクアーキテクチャにおいて、2つ目の重要な構成要素であるナレッジグラフを提供してくれます。

9.3.2　ナレッジグラフの役割

ナレッジグラフは、データ管理の機能として、ますます重要になっています。ナレッジグラフは、実世界の概念と関係のコレクションを表します。さまざまなソースからのデータを統合して関連付け、そのデータをエンティティのネットワークとして表現します。このネットワーク構造は、ナビゲーション、検索、複雑なクエリへの回答に役立ちます。オブジェクトやリソースをリンクさせる方法は、World Wide Webの仕組みと同じです。ハイパーテキストリンクは、あらゆるものをあらゆるものにリンクさせることができます。ハイパーリンクは、別のページ、Webページの特定の場所、画像、ファイルを参照することができます。検索エンジンは、ハイパーリンクを追跡し、それらの関係を通じて、すべてのリソースを簡単に見つけることができます。

ナレッジグラフには大きな可能性があります。現在のデータカタログの欠点に対処するだけでなく、AIと組み合わせることで、未来のデータ管理技術になり

ます。

9.3.2.1　テクノロジーと標準

2000年に、World Wide Webの発明者の一人であるTim Berners-Lee氏は、どんなものでもリンクできるという考えをもとに論文を発表しました。現在のインターネット標準を、セマンティックWebフレームワーク（https://oreil.ly/d0LYh）で拡張することにより、どんなデータでもアプリケーション、企業、コミュニティの垣根を越えて共有、再利用することができるようになります[†6]。データとともにセマンティクスをエンコードするさまざまな技術を以下に紹介していきます。

[†6] **セマンティックWeb**とは、W3Cが提唱する「リンクトデータによるWeb」というビジョンです。セマンティックWebテクノロジー（https://oreil.ly/kkJv3）により、Web上にデータストアを作成し、ボキャブラリーを構築し、データを扱うためのルールを記述できるようになります。

リソースディスクリプションフレームワーク（RDF、Resource Description Framework）
RDFは、リソースに関する情報をグラフ形式で表現するためのフレームワークです。データを分散型・非中央集権的に扱えるようにするのと同時に、HTTPプロトコルを用いて、データのクエリや結合を行うことができます。RDFのデータモデルは、RDFのトリプルのコレクションを使ったスキームレスな設計になっており、容易に拡張や表現ができます。

OWL（Web Ontology Language）
OWLは、RDFにオントロジー機能を追加する仕様です。妥当なオントロジーを作成するために、RDFで何を書けばよいかを正確に定義しています。また、OWLは、データモデルを実世界に展開するための表現とアノテーションを規定しています。OWLは概念的なモデリング言語と考えられていますが、データセットをリンクし相互に関連付けるので、論理的なデータモデルでもあります。OWLの面白い点は、この言語はRDF表現を持つことができるため、データの意味をデータセットの一部として記述できることです。

SPARQL（SPARQL protocol and RDF query language）
SPARQL（https://oreil.ly/5eHVY）は、RDFに格納されたデータを、取得したり操作したりするために用いられるクエリ言語です。連合型データソースにまたがってクエリできるため、複数のグラフデータベースを取り込

むことで、単一のバックエンドで複数のデータモデルをサポートすることができます。

SHACL（Shapes Constraint Language）

SHACLはRDFグラフを記述し、その妥当性を検証するための言語です。SHACLを用いると、形状グラフとデータグラフを入力として、両者を互いに検証することができます。

SKOS（Simple Knowledge Organization System）

SKOSは、知識体系をWeb上で共有・連携するための共通データモデルです。シソーラス[†7]、分類スキーム、件名標目体系、タクソノミーなどの知識体系を定義するために使用されます。

[†7] **シソーラス**とは、同義語や関連する概念の単語をグループ分けしてリスト化した文書のことです。

セマンティックWeb標準は、Webにおけるオントロジーに基づく相互運用性とコンテンツ公開のための新たなデファクトスタンダードです。Meta、Google、Microsoft、Amazonなどの大手テクノロジー企業が、その原則と方法論を採用し利用しています。このセマンティックWebの素晴らしいところは、同じようにデータ管理にも適用できることです。より具体的に言えば、メタデータ管理にも適用できることです。

オントロジーベースの管理機能を組み合わせることで、企業全体でオープンなナレッジグラフを作成することができます。このナレッジグラフは、組織（ドメイン）のすべての知識と関係を表し結合したデータベースのことです。エンタープライズメタデータモデル内に記述されたすべてのものへの参照を集めたものです。このリポジトリには、できるだけ多くの関連するメタデータを格納するとともに、コンテキスト情報や意味情報でリッチ化することができます。

この構想の素晴らしいところは、ナレッジグラフを（見方によって異なりますが）直接データやメタデータにもつなげられることです。定義したオントロジーをもとに、グラフを自動的に作成したり、対応するデータを探したりすることができるようになります。RDF、OWL、SPARQLなどの業界標準に従うことで、分散したデータに対するクエリや結合を行うことができます。意味、出所、リネージ、データのライフサイクル上の段階、オーナーシップ、関連法規など、すべてのデータ関連情報を一箇所に集めて、深く分析することができま

す。情報を追加し、つなげればつなげるほど、ナレッジグラフはより強固なものになります。

Cambridge Semantics（https://oreil.ly/p6Pqg）のような企業は、メタデータとデータのナレッジグラフを組み合わせるという構想にすでに取り組んでいます。あらゆる形式のメタデータを収集・分析し、その情報を変換し、データ統合のための基幹を構築しています。次の項では、例を挙げて具体的に説明します。

9.3.2.2　データファブリックの例

データファブリックは、データを管理するための新しい考え方です。データファブリックでは、データをネットワークベースのメタデータ駆動型アーキテクチャで管理します。このアーキテクチャのメタデータは、柔軟性、再利用性、発見可能性、インテリジェント性、拡張性を備えています。データファブリックの構築を検討しているのであれば、Anzo（https://oreil.ly/alkGe）を試してみることをお勧めします。Anzoは、ナレッジグラフ、仮想化エンジン、レポートソリューションを組み合わせたプラットフォームです。このプラットフォームは、データの統合レイヤー（ファブリック）を構築するという構想に適しています。このプラットフォームでは、（物理的な）データセットのコレクションであるGraphmartを使用し、接続、共有、発見、拡張を共同で行うことができます。データの発見と設計の際、このプラットフォームはメタデータをスキャンして利用します。スキャン後、データエキスパートやデータエンジニアに追加情報を提供してもらい、関係付けを行うことでエンティティを相互に結び付けます。Graphmartが作成されると、ユーザーはGraphmartにData Layerを追加し、データのクレンジング、変換、リンク、アクセス制御を行い、インメモリグラフを動的に拡張できます。

図9-4は、GraphmartとData Layerの管理方法を示しています。面白いのは、メタデータとソースをレイヤーにマッピングし、その上に別のレイヤーを構築できることです。例えば、最初のレイヤーは、ソースとメタデータを直接入力とする「ソースレイヤー」とすることができます。最初のレイヤーを構築するためのメタデータは、提供済みのオントロジー（OWLファイル）や、スキャンによって発見されたメタデータから得ることができます。2つ目のレイヤーは、エンティティを接続し、SPARQLを使用して修正を加えることで、最初のレイヤーを拡張します。これがData Layerです。次に、コンシューマ向けに設計されたレイヤーを追加し、データ情報を活用できるようにします。これらのレイヤーもData Layerと呼ばれますが、セマンティックレイヤーを使用するコ

ンシューマ向けに設計されています。すべてのレイヤーの間には関係があります。変換ステップが適用される手順を記述したレシピは、RDF形式のオントロジーとして保存されます。レシピには、各レイヤーの内容を記述する別のオントロジーへの参照が含まれています。

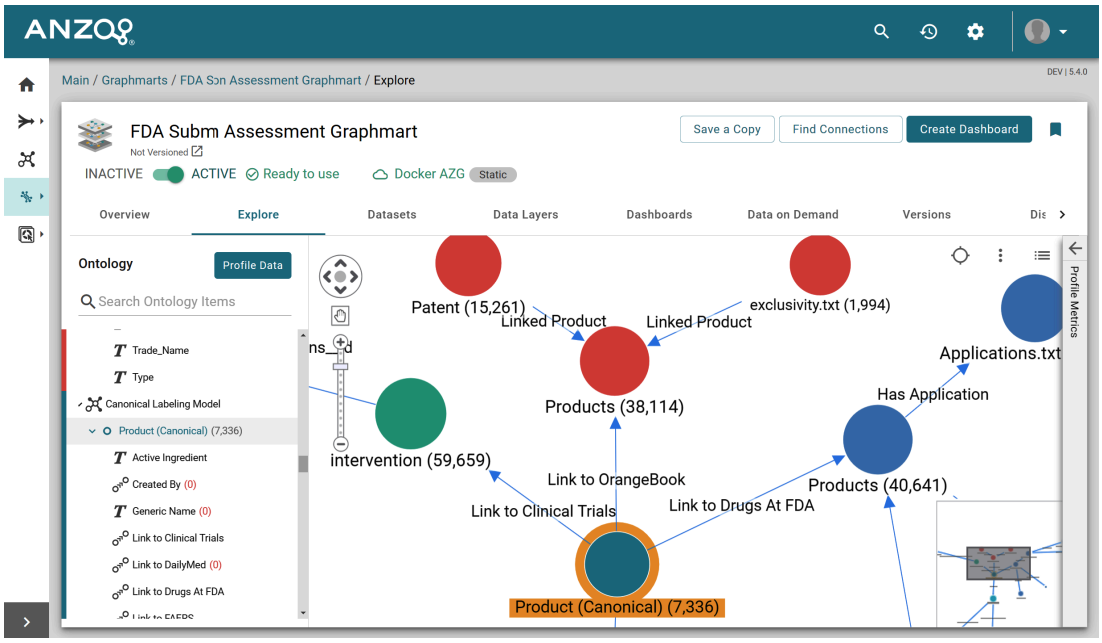

図9-4　Anzoがグラフ内のエンティティを視覚化し、接続する様子を示す画面（モデルはクエリを実行できるデータセットを表す）

この構想の先進的なところは、ナレッジグラフを分散モデルで構築し、ある部分はドメインで管理し、別の（中心的な）部分は中央や企業レベルで管理することもできるということです。この中央部分がモデルの核となります。もちろん、中央集権モデルを導入する場合は、最重要なメタデータオブジェクトと、それらのオブジェクトが互いにどのように関連するかについて、全社レベルの標準を設定することが重要です。

分散型設計を実装すると、ドメインはコアモデルを損なうことなく中央メタデータモデルを拡張できます。例えば、マーケティングドメインチームは、自分たちが必要とするコンテキストやデータのために、ドメイン固有のエンティティやプロパティをこのモデルに追加することができます。また、ほかのユーザーやコンシューマのために、自分たちのモデルを公開することもできます。基盤となるデータリポジトリにアクセスでき、リソース（データ）ロケーションへの関係が組み込まれている限り、すべてを簡単に拡張、結合、クエリすることができます。

9.3.2.3　メタデータ管理のためのデータファブリック

メタデータ管理にセマンティックWeb標準を使用するという構想を広げれば、エンタープライズメタモデルに関連付けることもできます。メタモデルは、ナレッジグラフの上に位置するセマンティックレイヤーとなり、重要なメタデータがすべて保存されます。このセマンティックレイヤーは、複雑なクエリに対するナビゲーション、検索、応答に利用できます。 つまり、ナレッジグラフを使用して、通常のデータをクエリするのと同じように、メタデータをクエリすることができます。例えば、この方法では、中央のデータプライバシー分類を概念的な用語に関連付けることができます。また、アプリケーションデータへのリンクがあるため、どのデータ属性が機微（センシティブ）であるかを知ることができます。

ナレッジグラフは、エンティティやその属性の巨大なセマンティックWebと見なせます。ナレッジクラフを使えば、エンティティ間の意味上の類似性に基づいて、最も適合性の高いエンティティを検索することができます。また、図9-4に示すように、ドメイン固有の語彙や、タクソノミー、オントロジーを使って、ドメインがドメイン固有のナレッジグラフを拡張することもできます。オントロジーベースのアプローチは実装が困難ですが、その影響は非常に大きなものです。データランドスケープ全体の一貫性を大幅に改善し、データの消費と生産性を向上させることができます。ユーザーが複雑なデータ表現に対処する方法を完全に変えることができます。オントロジー、分類、グラフ関係、自然言語処理、推薦、検索アルゴリズム用のデータを自動的に生成することができます。このため、データファブリック開発に向けて準備しておくことが重要となります。

データファブリックを支えるテクノロジーは、オープンな標準を利用しています。Webを動かしているのと同じものです。このため、内部的な知識やデータに関連する意味に誰もがアクセスできるようになります。大手ハイテク企業では、この技術を人工知能、機械学習、自然言語処理と統合しています。データ統合やデータセキュリティの領域と関連付けることもできます。例えば、与えられた意味論的コンテキストや関係性に基づいて、データを自動的に統合して変換したり、ナレッジグラフに記述されたプロセスに基づいて、データアクセスを動的に変更したりすることもできるでしょう。

データファブリックは、メタデータ駆動型のインテリジェントアーキテクチャとして、メタデータを大規模に管理するための優れたソリューションになります。メタデータ管理にナレッジグラフベースの考え方を適用する場合、少しずつ段階を踏んでいくことをお勧めします。すべてのつながりを持った巨大なグ

ラフを作ろうとすると、一部の技術者しか理解できないものになります。徐々に構築し、ビジネスユーザーもモデルにアクセスできるようにすることで、誰もが、新たなインサイトから恩恵を受けられるようになります。最終的には、高度なアルゴリズムとツールをナレッジグラフに適用して、インテリジェントなデータ消費を実現し、全体的に品質を向上させ、隠れたパターンを見出だせるようになります。

9.3.2.4　メタレイクソリューションの設計

ナレッジグラフアーキテクチャを設計する際には、前の章で説明したパターンを参考にしてください。メタデータは通常のデータと同じように、メタデータ管理のためにナレッジグラフに格納する前に、その品質を確認し、クレンジングし、ほかのメタデータと統合する必要があります。データプロダクトアーキテクチャのブループリントとサービスを再利用すれば簡単に始められます。図9-5を見れば明らかなように、4章のいくつかのパターンと重なっています。これらの上に、APIアーキテクチャからいくつかのサービスを追加し、フロントエンドサービスと、メタデータが格納されている基盤サービス間のリアルタイム通信を実現します。

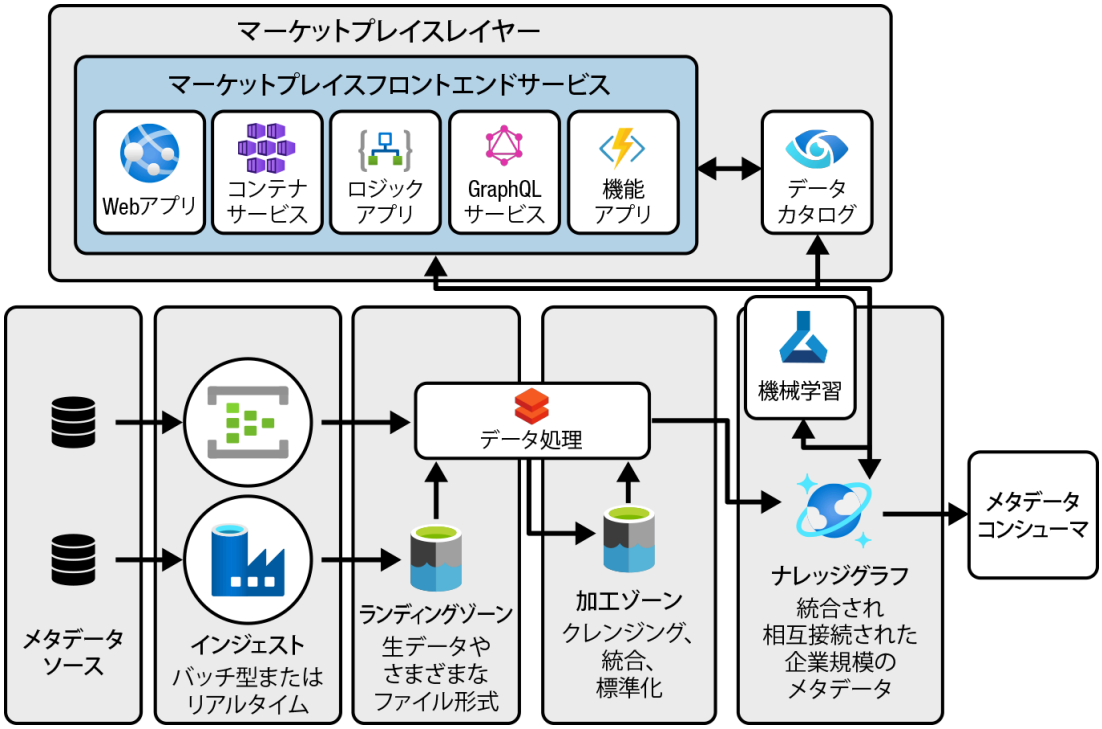

図9-5　ナレッジグラフをデータマーケットプレイスにどのように活用できるかを示すメタレイクソリューションの設計。マーケットプレイスのフロントエンドサービスは、エンドツーエンドのデータ管理に関するインサイトを可視化するためにある

データカタログとナレッジグラフは密接な関係にあります。メタデータの大部分はデータカタログで管理されます。この2つの違いは、ナレッジグラフがより柔軟で、順応しやすく、より広範囲であることです。より広い範囲のメタデータをカバーし、さまざまな場所のメタデータを統合できます。一方、データカタログは、データの利用やデータ管理のためにデータを見つけ検索することを目的としています。

筆者は、将来のデータカタログは違ったものになると予想しています。ある時点で、データカタログは、可視化、ワークフロー管理、統合などのための多くのサービスを備えた、オープンで相互運用可能なナレッジグラフプラットフォームになるでしょう。

ナレッジグラフの設計が完了し、データ管理メタデータを管理するためにナレッジグラフを使用しはじめたら、エンタープライズアーキテクチャの成熟度を把握するためにナレッジグラフを使用することもできます。2章のオーシャニック航空のビジネスケイパビリティモデルを例にして、組織内の各ビジネスケイパビリティのデータ管理成熟度レベルがどのように表せるかを**図9-6**に示します。

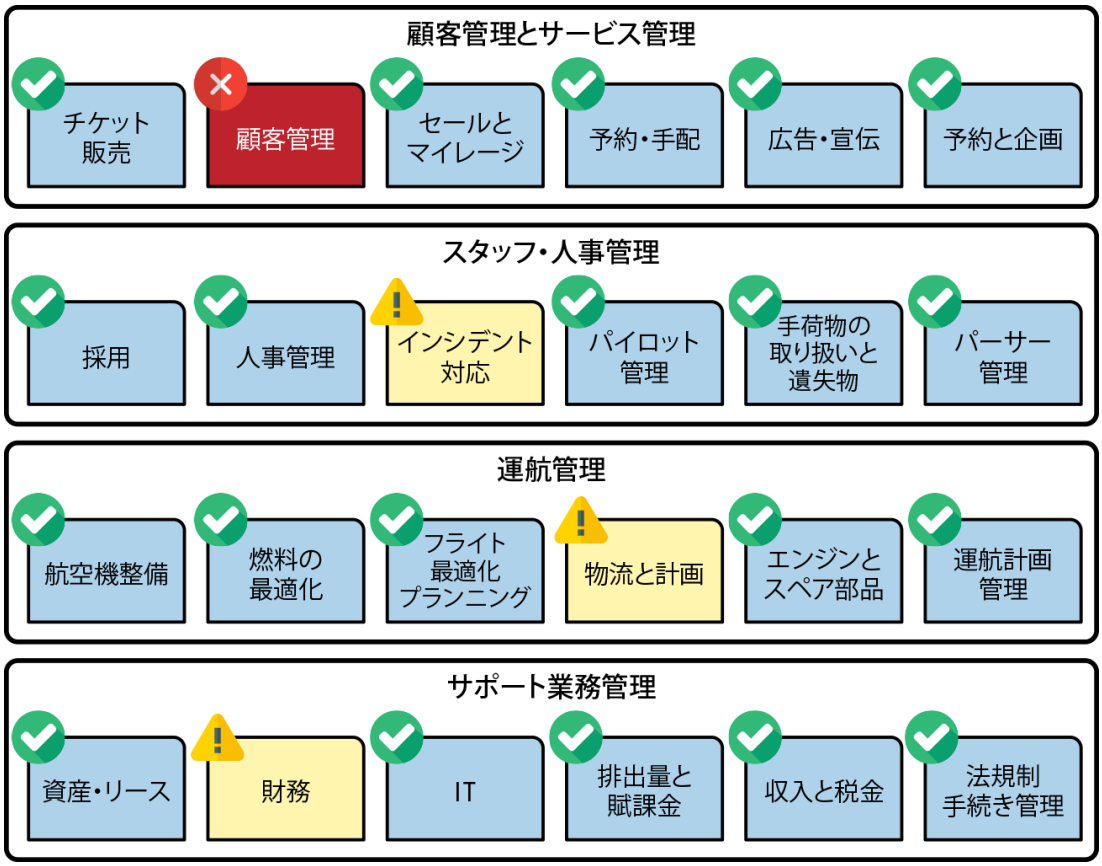

図9-6　データ管理という切り口で各ビジネスケイパビリティの成熟度を示すビジネスケイパビリティモデル

何か問題があれば、ドリルダウンして、データセットの数、データ品質の問題、コンシューマを確認できます。図9-7は、ドメインの健全性に関するレポートの例を示しています。これらの情報は一例です。メタデータが多ければ多いほど、より多くのインサイトを提供できます。このような可視化を行うための情報は、さまざまな場所から取得できます。メタデータは、カタログ、ナレッジグラフ、ほかのメタデータリポジトリ、またはこれらの組み合わせから取得できます。

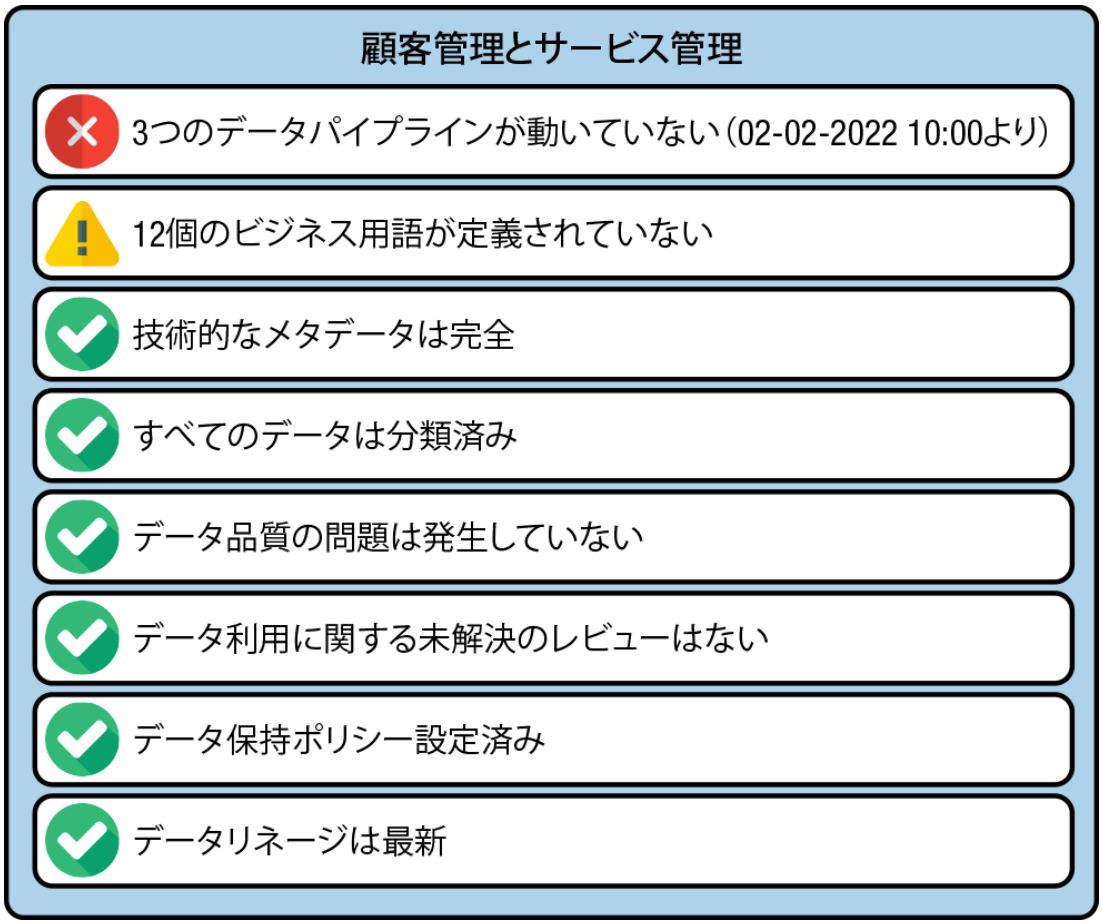

図9-7　データ管理の特性を示したビジネスケイパビリティレポート

ナレッジグラフは、アーキテクチャに対するインサイトを提供するという、すばらしい可能性を秘めていますが、それで終わりではありません。ナレッジグラフは、データマーケットプレイスを構築するための強力なソリューションです。図9-5の上部にあるマーケットプレイスは、ルック&フィールが洗練されたオーケストレーションレイヤーです。マーケットプレイスは、データ利用のためのワンストップショップとして、また組織内のデータガバナンスのための中心的なハブとして機能します。マーケットプレイスは、メタデータが保存されているストアを使用します。カタログ、ナレッジグラフ、そのほか関連するメタデータリポジトリなどです。例えば、カタログやナレッジグラフにAPI呼び出しを行うことで、このメタデータを収集します。

ナレッジグラフをより賢くしたいのであれば、分析機能やプロビジョニング機能を追加することもできます。筆者がいくつかの大企業で経験した例を紹介しましょう。

- マーケットプレイスは、測定可能なKPIに基づいてデータプロダクトを評価しても良いでしょう。例えば、評価、データ品質、データパイプライン成功率、データ鮮度、使用統計に関連するKPIをまとめたものは、データコン

シューマがデータ分析の入力として使う場合に、どのデータプロダクトが適切なのかのヒントになるでしょう。

- マーケットプレイスは、データプロダクトのインシデント分析を自動的に行います。影響を受ける可能性がある場合には、データコンシューマに事前に通知することができます。
- マーケットプレイスには、自営のキャリアチャネルを使って、顧客向けのデータ契約を自動的に作成し発行する機能が含まれている場合があります。
- マーケットプレイスは、データ探索を改善するために、レポートや開発環境（Jupyter Notebookなど）と統合している場合があります。
- マーケットプレイスは、機械学習を使ってデータ品質ルールやスキーマメタデータを提案し、データプロダクトに組み込む場合もあります。
- マーケットプレイスに直感的なクエリを行った場合に、複数のデータソースを統合して解決してくれる場合があります。また、データの仮想化や変換エンジンを呼び出して、データの変換や集約を行う場合もあります。
- マーケットプレイスに、検索エンジンが組み込まれ全文検索が行える場合があります。
- 特定のメタデータが欠落している場合、マーケットプレイスはデータを共有しないよう制限する場合があります。例えば、ビジネス用語と技術的属性がリンクされていない場合、データが外部のコンシューマから見えなくなります。
- マーケットプレイスが報酬システムとなり、ドメインやユーザーが積極的に参加する動機付けとなることがあります。
- マーケットプレイスには、例えばデータセットの上位100レコードを表示するなど、データを発見するための機能が含まれている場合があります。

将来のデータマーケットプレイスは、多くの製品を組み合わせたものになるでしょう。当初はデータプロダクトのカタログとして始まるかもしれませんが、次第に、多くのツールやサービスによって拡張されていくことが予想されます。また、データマーケットプレイスは成長するにつれて、さまざまな成熟サイクルを経ることになるでしょう。この点に関して、どのようなベストプラクティスが考えられるでしょうか。以下に、いくつか提案しておきます。

- 少しずつ進めていきます。まず、少数のユースケースとメタデータソースから始め、徐々にほかのデータドメインメタデータ領域に拡張していきます。

- データマーケットプレイス、ナレッジグラフ、データカタログを双方向に統合します。例えば、データカタログを使用してデータ契約を作成し、一方で、データアクセス許諾管理はデータプロダクトアーキテクチャで行うとします。この場合、いくつかのメタデータコンポーネントを密に統合する必要があります。
- すべての関係者に対してメタデータを充実させるよう促しましょう。チームに特別予算を与えることを検討ください。
- ステークホルダー全員の責任と権限を明確にし、役割とデータドメインに基づく共同ガバナンスモデルを定義します。
- メタモデルを定義し、組織のデータに関するすべての知識とコンテキストを管理します。このメタデータは、カタログで使用されているモデルと整合している必要があります。
- メタデータの品質を監視するためのダッシュボード、メトリクス、アラートを作成します。ソース側でメタデータの品質を改善できるように、フィードバックの仕組みを構築します。

このように、データマーケットプレイスの構築を成功させることは、プラットフォームの構築、組織、プロセスの面で大きな挑戦となります。しかし、データ戦略で定義した目標を達成することにおいて、多くのメリットをもたらします。

9.4　まとめ

データがビジネスユーザーにとっての燃料であるとすれば、メタデータは最高データ責任者（CDO）が必要とするデータです。CDOはメタデータを使うことで、組織全体のデータ管理能力の健全性と状態を監督し、インサイトを得ることができます。そして、このインサイトを活用して効率を高めます。

これまで見てきたように、メタデータはすべてを結び付けてくれます。データの完全性と品質の検証、新しい場所へのルーティングや複製、データの変換、データの意味の把握には、すべてメタデータが必要です。メタデータ管理は、ビッグデータ、ビジネスインテリジェンス、分析だけに関係するものではありません。アプリケーション統合、サービス指向、マイクロサービス、そして継続的な統合と配備を行うDevOpsとも関連しています。

また、データ管理能力を継続的に向上させるためには、メタデータを分析と組み合わせる必要があることもお分かりいただけたと思います。ナレッジグラフ

と機械学習を使用することで、データ間の新しいパターンや関係を見つけることができます。適切なサービス群を利用することで新しい提案を行い、データをモデル化し、データ品質を向上させ、データを自動的に分類することができます。このインテリジェンスこそが、データメッシュに欠けている部分なのです。つまり、次世代アーキテクチャは、データメッシュとデータファブリックのハイブリッドなのです。

メタデータは、セルフサービスポータルを通じてデータを民主化するためにも不可欠です。消費を促すには、データマーケットプレイスを導入し、アクセス可能なデータをユーザーが直感的に探し出せるようにすべきです。まずは、数種類のデータプロダクトのみを提供するデータマーケットプレイスを立ち上げ、アーキテクチャが成長するにつれて、データマーケットプレイスを拡張して、より多くのドメインに対応できるようにします。データプロダクトを直接クエリしたり処理したりするために、データマーケットプレイスのアーキテクチャを仮想化などのサービスで強化することも検討してください。これにより、より豊かな体験が得られ、より多くのユーザーを惹きつけることができます。最終的には、データマーケットプレイスもつながります。データマーケットプレイスはデータの価値を高めるだけでなく、企業全体を見渡す役割も果たします。

データマーケットプレイスの構築はメタデータだけの問題ではありません。組織、カルチャー、人材も重要です。ユーザーを信頼させ、トレーニングを提供し、意識向上に取り組む必要があります。これらのカルチャー面は、それほど厳格なガバナンスを必要としませんが、これらの活動を過小評価すべきではありません。ユーザーを正しく訓練すれば、ユーザーが貴重なリソースになります。ユーザーはそれぞれデータの特定の部分を所有または使用し、それを注意深く保守・最適化してくれるようになります。そして、ユーザーは互いに助け合い効率を高めます。

次の章では、マスターデータ管理について説明します。データのマスター管理、キュレーション、再発行を行うことで、企業の一貫性がアーキテクチャに反映されていくことを学びます。