10章
最新のマスターデータ管理

本書の初版で、データとマスターデータ管理（MDM）について、「データのスピードが速く流動性が高い場合は、データを細かく分割し、それぞれのドメインに任せるようにします。もしも、データが安定しており、本当に必要なものであれば、MDMの利用を検討してください」と助言しました。3年経った今でも、同じ助言を送ります。なぜでしょうか。大規模な分散環境では、アプリケーションは複雑に絡み合っていることが多いからです。これまでの章では、企業がデータを管理・流通させる規模について考察しました。大規模な組織では通常、多数のドメインが存在し、それぞれがデータ資産のオーナーシップを持ち、再利用可能なデータプロダクトをデータコンシューマと共有する責任を担っています。このような連合型の仕組みはスピードを向上させますが、いくつか難しい問題があります。

- 多くの場合、ドメインは自分たちのデータプロダクトだけを管理し、ほかのプロダクトとの連携については考慮しません。このためコンシューマが複数のドメインのデータを組み合わせることが難しくなる場合があります。
- それぞれのドメインが独自にデータ変換プログラムを開発する場合、作業の重複が多く、アーキテクチャのコストが高くなり非効率になります。
- 性能上の理由から、ほかのドメインからのデータを集約・コピーするようなドメインを複数持つことは、データが重複し複雑さが増すことにつながります。
- ドメイン間でコンテキストに整合性がない場合もあり、そのためデータの品質レベルにもばらつきがあります。

データの再利用性と一貫性の課題に対処するためには、MDMをアーキテクチャに追加し、データ品質と不整合の問題をソースシステムにおいて修正する必要があります。1章で説明したように、MDMとは、一貫性、品質、信頼性を確保するために、重要なデータを管理・流通させるためのものです。一貫性のな

いデータや不正確なデータは、信頼性を損ない、売上や利益を減少させる結果につながるため、マスターデータ管理は非常に重要です。また、セキュリティ、不正行為の検知、GDPRやCCPAなどの法規制も、マスターデータ管理の必要性を高めています。マスターデータ管理が不十分だと、不正の検出ができなかったり、規制当局から罰則を受けたりする可能性があります。

> エンタープライズデータ統合の罠にはまりやすくなります。スコープを広げ、マスター管理するデータが多すぎると、データを統合し、管理し、調整するために、多大な労力が必要になります。メタデータを使って、マスター管理に含めるものを決めてください。リネージ、データモデル、データ契約を分析することで、ドメイン間の重複や共通の関心領域を明らかにし、MDMの対象とすべきデータを決めることができます。一般的に、単一のドメインのみで使用されるデータ要素はMDMの対象にはなりません。一方、多数のドメインで共有されるデータ要素は、MDMでの管理対象候補となります。

MDMを大規模なエコシステムの中で活用する方法を説明する前に、MDMはデータ統合（ETL）に主眼を置いたテクノロジーでは解決できない、あるいは解決すべきではない、ということを理解しておいてください。MDMはETLよりはるかに複雑です。最新のMDMスタックは、以下に示すような多くの要素で構成されています。

- 検出処理、修正処理、フォローアップ管理などのデータ品質管理
- データの重複を処理するための自動化された照合・結合ルール管理
- 地理的な制限や影響を管理するためのロケーション処理／ローカライゼーション処理
- 欠落データや不完全なデータを補完するためのデータエンリッチメント管理
- データ保護法や利用管理などの同意管理
- データ品質、ルール、ローカライズ、データアクセスなどに関する承認プロセスや意思決定のためのワークフローやライフサイクル管理などのデータガバナンス管理

- 新たに作成されたMDMレコードでソースシステムのデータを更新するなど、データソース管理との統合機能

マスターデータ管理について

ほとんどの組織では、共通点のあるデータ要素を共有するシステムを持っています。例えば、「顧客」と「製品」などです[†1]。同じマスターデータの複数のバージョンが、組織内のさまざまな場所、多くのアプリケーション・システムに保存されていることでしょう。このような重複は、非効率なだけでなく、不整合を引き起こす可能性があります。顧客名のスペルが違ったり、住所が異なっていたり、同じ顧客がそれぞれのシステムで固有のIDを持っていたりする場合もあります。データのコピーが、それぞれ別の部門やドメインに属している場合もあります。顧客のデータが変更されたり、結合されなければならない場合、このような違いがあるのに、どうやって同じ顧客と認識すれば良いのでしょうか。ここで、MDMが登場します。MDMは、アプリケーションやシステム全体に対して、マスター管理しているバージョンのデータを流通させることで、データの不整合を検出し解決します。

[†1] 実際には、多数のデータ要素（例えば「顧客」）が、一意で一貫性のある識別子さえ持っておらず、簡単につなぎ合わせられないことに気づくでしょう。MDMはこの問題の解決策にもなります。

MDMは、さまざまな方法やスコープを使って実装することができます。以下の節では、いくつかの実装スタイルとデータ統合オプションについて説明し、MDMソリューションの設計へと進みます。

10.1　マスターデータ管理のスタイル

マスターデータと参照データをうまく管理するためには、MDMソリューションを設計し実装する必要があります。Lyn Robison氏は、ガートナーに寄稿したドキュメントの中で、コンソリデーション、レジストリ、中央集権、共存という4つのMDM管理スタイルを挙げています（**図10-1**参照）。

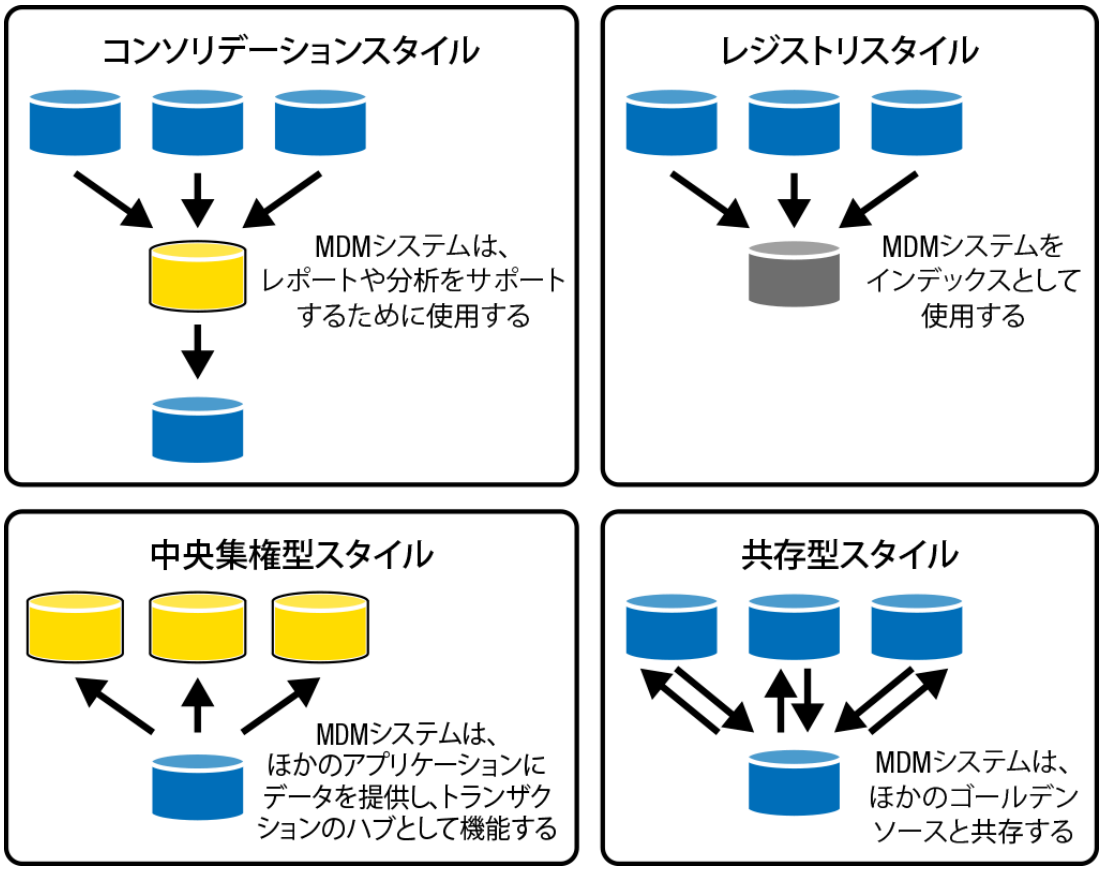

図10-1　ガートナーによる、マスターデータ管理実装スタイル4種類の比較

それぞれを詳しく見てみましょう。

コンソリデーションスタイル

コンソリデーションスタイルは、データウェアハウスと類似した部分が多くあります。マスターデータとそのほかのデータを、**マスターデータストア**や**MDMハブ**と呼ばれる単一のリポジトリやハブにまとめます。 MDMハブは、データ統合パターンを使用して、運用システムからマスターデータを継続的に取り出し、品質の向上、ガバナンス管理を行います。この統合リポジトリのデータは、下流のアプリケーションで利用できます。このスタイルは通常、分析、ビジネスインテリジェンス（BI）、レポート作成で使われます。ゴールデンソースシステムのデータをクレンジングしたり、改善したりするような作業は行われません。データの改善はハブにしか反映されないため、消費アプリケーションだけが恩恵を受けることになります。

レジストリスタイル

MDMのスタイルで最も導入しやすいのは、**レジストリスタイル**（**リポジトリスタイル**）です。レジストリは単純な相互参照テーブルです。重複を排除したオブジェクトと、それらの間にどのような関係があるかを直接確認することができます。レジストリは、内部参照の仕組みとローカル識別子（顧客識別子など）を使って、元のデータソースにリンクします。

このスタイルは、ゴールデンソースアプリケーションに何ら影響を与えません。それぞれのソースシステムは自分自身のデータをコントロールし、

ゴールデンソースであることに変わりはありません。レジストリからソースシステムにデータを戻すことがないため、データ品質への直接的な影響もありません。

中央集権型スタイル

中央集権型スタイルでは、マスターデータストアが中央リポジトリになり、すべての運用システムと分析システムのマスターデータを管理します。データの収集、リンク、クレンジング、マッチング、リッチ化を行い、リッチ化されたデータを即座にそれぞれの（トランザクション）ソースシステムに戻します。

このスタイルの最大の問題は、双方向の同期を行うために、ゴールデンソースシステムに対して操作が必要になることです。アプリケーションは、マスターデータリポジトリをバックエンドとして使用できるようにする必要があります。アプリケーションの設計を変更できるとは限らないため、実現が難しい場合があります。例えば、一般的に、既製品は変更することができません。また、別の問題として、密結合してしまうという問題もあります。何らかの理由で中央リポジトリを変更しようとすると、ほかのすべてのシステムも変更せざるを得なくなります。商用MDMベンダーは、この方法がマスターデータを適切に管理し統制するための最良の方法である、と説明するのですが、ほかの方法も含めて真剣に検討することをお勧めします。

共存型スタイル

共存型スタイルは、マスターデータを中央で使用できず、企業内の複数拠点に分散させる必要がある場合に使われます。このスタイルでは、改良されたデータが元のシステムに戻ってくるため、更新はゴールデンソースシステム内で行われます。共存型は非常に複雑な実装スタイルです。複雑なデータ統合パターンを実装し、ゴールデンソースシステムとマスターデータストア間のデータの一貫性を保証しなければならないからです。

これら4つの実装スタイルは互いに排他的なものではありません。例えば、レジストリスタイルから始めて、後に共存型スタイルに移行することもできます。また、データセットごとにスタイルを変更することもできます。例えば、レポート機能はコンソリデーションスタイルで実装し、顧客データは共存型で実装するといったこともできます。スタイルを実装する際に、さまざまな製品を組み合わせて実装することも可能です。なお、どのスタイルを実装するかを決めるのはテクノロジーではありません。組織とデータのニーズこそが、どのスタイルを選択するかの要因になるのです。

10.2　データ統合

データ統合は、MDMを実現するための基礎となる部分です。多くのMDM実装では、バッチ処理とリアルタイム処理の両方をサポートする必要があります。

トランザクションシステムではリアルタイムで処理が行われ、分析システムでは大量のデータに対してバッチ処理を行うからです。すべてのデータを流通・統合するために、MDMは、これまで使ってきたのと同じ基盤上に構築される必要があります。このモデルでは、MDMは、データコンシューマであり、また同時にデータプロバイダーでもあります。

MDMデータを流通させる場合、データの一貫性と遅延のバランスを取る必要があります。状況に応じて、さまざまな実装と統合設計が考えられます。

運用ユースケースや低遅延が必要なユースケースの場合は、APIやイベントを使います。マイクロサービスを使うアプローチとして、状態ストアを使用する方法があります。数百万件のレコードを同時に移動する代わりに、イベント駆動型アーキテクチャを使用して、MDMレコードをストリーミングデータベースとして消費アプリケーションに公開します。このように、ドメインのマイクロサービスは、ドメインが開発したサービスと、MDMデータを管理する読み出し指向のマイクロサービスを組み合わせた構成になります。

重要で時間的制約のある運用プロセスに対して、MDMを使用するのは難しい場合があります。例えば、受注管理システムが注文を受け取り、MDMシステムで顧客を検索する場合、照合と結合処理をミリ秒以内に確実に実行する必要があります。

MDM状態ストアを実装する選択肢として、NoSQLデータベースを使用する方法があります。データベース内で、状態ストアは、新たに作成されたデータがどのグローバル識別番号にリンクできるかを管理します。このプロセスを効率化し、品質を向上させるために、状態ストアを機械学習機能で強化することができます。MDMストアを用意し、すべてのイベント（例えば、作成、更新、削除など）のトランザクションログをすべて保持することで、データのバックログ全体を再現する機能を提供できます。必要に応じて、ソースシステムを使うことなくすべてのデータを再現できる環境で作業しているため、データモデルの変更を簡単に管理できます。とはいえ、役割と責任を混在させないことが重要であり、トランザクションログをMDMソリューションから分離しておく方が良い場合もあります（この場合、MDMプラットフォームがイベントストリーミング形式で動作するようにしなければなりません）。

遅延が大きくても許容できるユースケースの場合は、データプロダクトアーキテクチャを使用してマスターデータを流通させることができます。ただし、MDMハブと提供・消費アプリケーションの間をポイントツーポイントで接続しないことが重要です。ポイントツーポイントで接続すると、データの不整合が発生するリスクがあるからです。例えば、データコンシューマはMDMハブから配信される新しいレコードを直接取得しているのに、データプロダクトに対してはMDMハブ内のデータがまだ反映されていないかもしれません。MDMハブが常にデータプロダクトを使用していれば、このような不整合が発生することはありません。原則としては、コンシューマが分析作業で使用しているのと同じデータプロダクトをMDM環境に提供するようにします。

10.3　マスターデータ管理ソリューションの設計

MDMの実装プロセスは、どのようなアプリケーションやシステムの中で、どのような一意の信頼できるデータが作成・管理されているかを特定することから始まります。ゴールデンソースシステムから提供されているゴールデンデータセットが基本となります。データは、アプリケーションごとにさまざまな形で保存されるため、それぞれのコンテキストを理解し、そこでどのようなビジネスルール、形式、参照範囲などがマスターデータに影響を与えるかを把握することが重要です。

次のステップは、データを調和させ、一貫性を実現するMDMソリューションを設計することです。ベンダーが提供するソリューションを利用しても、自分で設計してもかまいません。MDMの分野でよく使われているベンダーには、CluedIn（https://www.cluedin.com）、Profisee（https://profisee.com）、Informatica（https://oreil.ly/yA4qx）、Tamr（https://www.tamr.com）などがあります。

MDMの設計と実装は、データモデリングやデータ統合と強い関係があります。なぜなら、重複するデータ属性を特定し、ETLプロセスを通じて調和させ、これらを適切なデータモデルにすることは、MDMソリューションの全体設計になくてはならない部分だからです。選択するスタイルとソリューションによって、データモデリングとデータ統合に要する作業量は変わり、統合パターンとアーキテクチャも変わってきます。例えば、共存型スタイルでは、リアルタイム処理を重視してAPIベースやイベント駆動型アーキテクチャを使用します。一方、コンソリデーションスタイルでは、データプロダクトアーキテクチャのバッチデータのみを用いて設計することができます。

データオーナーとアプリケーションオーナーが以下の項目について合意していることを確かめ、ガバナンスを確立する必要があります。

- どのような法規制を適用しなければならないか（例えば、法律によっては、異なる顧客データセットを組み合わせることが認められていません）。
- マスター管理されるデータの範囲。
- クレンジング、マッチング、マージ、リンク、コンソリデーションのルール†2。
- どのようなデータ利用分類（「8.2.4　データ利用分類」を参照）であれば、中央マスターデータストアを権威あるソースとして使用できるのか、またどのような状況においてデータコンシューマがローカル（元の）ソースシステムを参照するようにしなければならないか。
- どのようなデータ品質ルールやプロセスを導入するか。
- 修正したデータを元のソースシステムに戻すべきかどうか、戻すとしたらどのぐらいの速度で、どのようなデータ統合技術（バッチ、API、ストリーミングのさまざまなバリエーションと組み合わせを想定）で行うべきか。
- 新たに作成されたデータのオーナー（ドメインチームまたは中央チーム）。
- 提案された変更を承認・拒否する権限を持つユーザー。
- マスターデータの定義。この定義は、データカタログなどの中央メタデータリポジトリに格納されるものです。

[†2] 企業が、マッチングやマージのルールを最初から正しく設定できることはほとんどありません。また、マージやリンクについても、正しい粒度でできない場合が多いです。アジャイルなMDMシステムを用意して、ルールを見直せるようにすることが重要です。

これらの手順が完了したら、元のソースシステムやほかのアプリケーションに、データを流通させる方法を検討できるようになります

10.4　ドメイン指向マスターデータ管理

多くのMDMソリューションでは、参照データとマスターデータの両方を管理できますが、この2つの管理方法を明確に区別することをお勧めします。**参照データ**とは、ほかのデータ（または製品間の関係や地理的な階層などの価値階層）を定義、分類、整理、グループ化、カテゴリ化するために使用されるデー

タのことです。対照的に、**マスターデータ**は企業にとって絶対不可欠なコアデータのことです。それぞれ異なる方法で管理され、データ流通方法も異なります。

10.4.1　参照データ

ドメイン間でデータの一貫性を実現するための方法として、ドメインがデータプロダクトを流通させる際に、中央管理された参照データに準拠させる、という方法があります。一般的に、通貨コード、国コード、製品コードは、参照データとして提供されるべきデータの例です。例えば、このようなデータは、マスターデータストアや中央リポジトリで公開することができます。あるドメインがほかのドメインにデータプロダクトを流通させる場合、そのドメインはエンタープライズ参照データから得られた識別子を用いてデータを分類する必要があります。ローカルデータをエンタープライズデータにマッピングすることで、ほかのドメインはデータプロダクト内のマスターデータを速やかに識別することができます。

> ドメインに対して、自ドメインの提供するデータプロダクトをエンタープライズ参照データに準拠するよう求めるのは、データメッシュのアプローチと矛盾しているように思えます。確かにそうかもしれませんが、もし法規制によって特定のデータ次元で一貫性が求められるのであれば、これを適切に実現する方法はマスターデータ管理しかありません。

もちろん、ドメインがローカルの参照データを中央管理の参照データにマッピングする場合、何が何にマッピングされるべきかを正確に理解しておく必要があります。例えば、国コードのアルファ2コード（例US）と数値（例840）が常に標準のアルファ3コード（例USA）にマッピングされるべきかどうかなどです[†3]。

[†3] これらの参照コードの多くは、たとえフォーマットが異なっていても、外部のサービスを使って自動的に整形することができます。多くのプログラミング言語には、この機能が組み込まれています。

ドメインに対して、データプロダクトをエンタープライズ参照データに準拠させるよう求める場合、さまざまな方法があります。1つの方法は、ドメインがデータプロダクトを構築する際に、エンタープライズ参照値を発見、理解、選択、組み込みができるように、中央サービスを提供することです。例えば、データカタログを用意し、すべての参照データがホストされている中央ストレージアカウントを参照できるようにします。この方法では、データプロダクトを流通させる前に、エンタープライズ参照データのコピーを使用して参照値を検索し、ドメイン自身がマッピング作業を行います。この統合プロセスは、完全に自動化されたものから手作業で行われるものまであります。

ほかの方法としては、中央MDMサービスを提供し、ドメインがMDMソリューション内でローカルからエンタープライズへのマッピングを管理できるようにする方法などがあります。この場合、データプロダクトが発行されるたびに後処理が行われ、データプロダクトの不整合がチェックされ、エンタープライズ参照データでデータプロダクトがリッチ化されます。この方法では、最初の段階で実装する作業が増えるかもしれませんが、それぞれのドメイン内でソリューションを構築する必要がなくなります。また、マッピングが中央で検証されるため、より高い品質が保証されます。

データプロダクトに参照データを追加するには、2つの方法を同時に使用することができます。つまり、あるドメインではマッピングを自分たちで行い、別のドメインでは中央で管理されるサービスに頼るという方法もあります。この場合、標準化、品質、業務効率という目標が達成されるように、中央のガバナンス組織が企業全体の参照データ管理を監視する必要があります。

10.4.2　マスターデータ

マスターデータの場合、データの流通と統合の方法はそれぞれ異なります。なぜなら、データの流れる方向が異なるからです。

10.4.2.1　マスター識別番号

まず、マスターデータの重要な要素として、マスター識別番号[†4]が挙げられます。このマスター識別番号は、どのデータがマスター管理され、何が一緒にまとめられているのかを把握するために重要です。一意のデータを識別し、マスター識別子を割り当てることは、システム内でローカルに行うのではなく、中央でのみ行うことができます。そのためには、さまざまなシステムのマスターデータをMDMソリューションにまとめる必要があります。**図10-2**に、実際にこの仕組みを示します。

[†4] **マスター識別番号**または**マスター識別子**は、MDMが作成する拡張属性の1つです。これは、一意の識別子を割り当てることによって、レコードが一意であることを保証します。そして特に重要なのは、一致したレコード間の関係をドキュメント化することです。

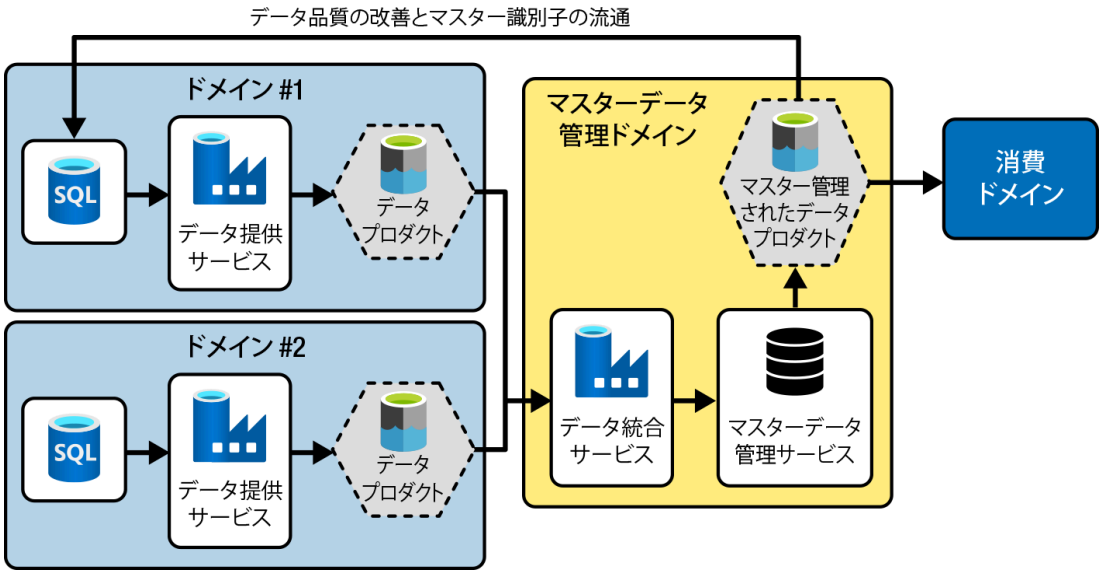

図10-2　MDMによるデータのマスター管理と流通のためのソリューション設計

これらの関係を特定し管理することは、どのデータがマスター管理されているかだけでなく、どのデータがほかデータとリンクされているかを素早く知るためにも重要です。運用システムのローカル（ドメイン）キーが変更された場合、すべてを結び付ける要素はマスター識別子だけとなります。このため、MDMソリューションからローカルドメインへのフィードバックループも構築する必要があります。1つの方法として、ドメインがローカル識別子とマスター識別子の関係を検索テーブルで管理し、それをMDMソリューション自体に

格納する方法があります。ゴールデンソースの場合、マスター識別番号を元のドメインに送り返す原則を導入するとよいでしょう。

アプリケーションキーとサロゲートキー

データエンジニアが利用できる一意な識別子には、2つの選択肢があります。一意な既存のビジネス識別子やアプリケーションキーを使うか、システムが生成する一意なサロゲートキーを使うかです。サロゲートキーは不変で重複することはありません。サロゲートキーを使用する利点は、セマンティック上の意味を持たないということです。MDMは、すべてのマスターレコードにサロゲートキーを割り当てて、マスターデータのグループを認識できるようにします。

アプリケーションキーを使用する場合、ソースシステムではアプリケーションキーは一意であっても、すべてのシステムで一意であるとは限らないということを忘れないようにしてください。例えば、IDのシードキーを1から順に使用するシステムを考えてみましょう。これは良くないやり方だと思っているのではないでしょうか。同じ方法を使用するほかのシステムが組織内にある場合、明らかに、識別子はシステム間で一意でなくなるからです。しかし、実際にこのような方法で動いているシステムはたくさんあります。ランダムなGUIDを使用することで、この問題を解決することができます。このように、複数のシステムからデータをまとめる場合、ビジネス識別子だけではオブジェクトを一意に識別できないことがよくあります。

ここで、次のような状況を想像してみてください。ある運用アプリケーションからMDMシステムにデータをインジェストし、MDMシステムがそのデータに新しいランダムなGUIDを生成します。その後、誰かがMDMシステムからすべてのデータを消去し、再度データをインジェストすることにしました。各レコードに新しいGUIDが生成されます。システムに存在していたデータがすでにビジネスで使用され、参照されていた場合はどうなるでしょうか。MDMは**決定論的な**GUIDを使うことでこの問題に対処できます。決定論的なGUIDの場合、同じ場所からの同じ入力データに対して、毎回同じGUIDが生成されるからです。

マスター識別子を流通させる場合は、MDMマスター識別子をすべてのソースシステムに挿入しないようにしてください。ドメイン間で整合性の問題が発生する可能性があるからです。このため、マスターデータ管理の対象となるアプリケーションやシステムのみが、ハブからマスター識別子を取得するようにし

ます。MDMの対象でないシステムは、独自のローカル（ドメイン）識別子を使用します。

10.4.2.2　MDMドメインとデータプロダクト

データを統合、クレンジング、調和させ、マスターデータストアに格納する場合、一般的にはMDMドメインを新たに作成します。これらのドメインは、特定の対象領域について一連の統一されたデータセットを作成します。一般的な例としては、顧客、製品、地理的位置、財務およびリスクデータ、従業員データなどがあります。これらのMDMドメインからのマスターデータは、ほかのドメインへ戻ることが想定されます。マスターデータはデータプロダクトとして、通常の方法で流通します（4章参照）。通常のデータプロダクトとマスターデータプロダクトを区別することをお勧めします。マスターデータプロダクトは、マスターデータ管理の入力として、通常のデータプロダクトを使用するからです。例えば、データカタログを使用することで実現できます。

マスターデータプロダクトをすべてのドメインに提供する必要はありません。あるスコープ内のドメインに対してはマスターデータを使うようにしなければなりませんが、そのスコープ外のドメインはマスターデータを使用する必要がありません。

10.4.2.3　ドメインレベルMDM

重複しているデータを探していくと、さまざまなレベルの重複が発見されるでしょう。中には、多くのドメインにまたがる汎用的なデータもあれば、2つか3つのドメインにしかまたがっていないデータもあります。**ドメインレベルMDM**を導入することで、データの重複度とその重要性を識別することができます。これを行うには、特定のスコープ内でマスターデータの部分ビューを作成します。重複の重要性と程度を識別するには、以下の分類を使用することをお勧めします。

エンタープライズデータ
企業全体に及ぶスコープと用途のあるデータのことです。複数のドメインにまたがって使用されることもあれば、すべてのドメインで使用されることもあります。また、企業外でも使われることもあります。エンタープライズデータには、マスターデータと参照データの両方が含まれます。その一貫性が重要です。

ドメインデータ

一部のドメイン間で共有されるデータであり、すべてのドメインで共有されるわけではないデータです。データを共有するドメイン群にとっては管理することが重要ですが、企業全体としての重要性はなく、また法規制上の重要性もありません。ドメインデータは、いくつかのドメイン内で管理・保守されますが、グローバルレベルでは管理されません。

ローカルデータ

単一のローカルドメインやシステムの中でのみ使用されます。ほかのドメインと共有されたり、使用されたりすることはありません。

図10-3は、ドメイン境界内でマスターデータを管理する例を示しています。ご覧のように、データプロダクトとの重なる部分が大きくなっています。ETLのみを使用するのではなく、MDMとETLを使用して新しいデータプロダクトを作成します。

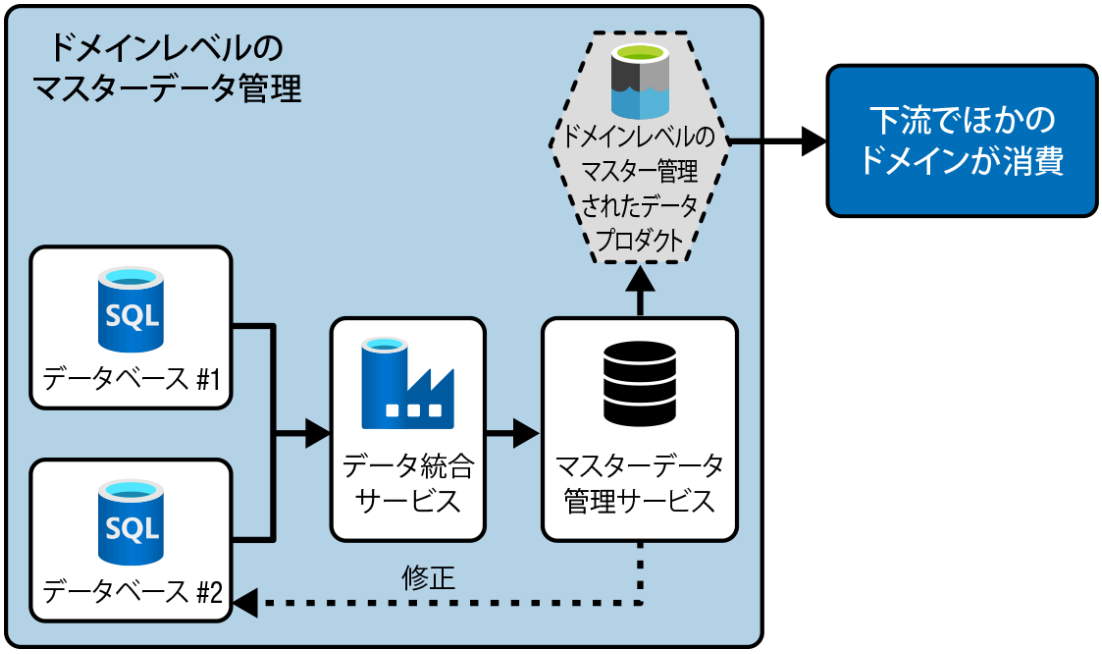

図10-3　ドメイン内のデータのマスター管理と流通（この形式のMDMはドメインデータと整合するが、前に見た例ではエンタープライズデータと整合する）

このような方法を使えば、MDMサービスをas-a-service形式で提供することにより、ドメインをサポートすることができます。これについては次項で説明します。

10.4.3　サービスとしてのMDMとデータ品質

企業やドメインでのMDMの導入を成功させるためには、MDMケイパビリティをドメインにサービスとして（as-a-service）提供することを考えてみてくだ

さい。MDMソリューションは複雑で、導入が難しい場合があります。インフラストラクチャーを抽象化し、MDMをサービスとしてドメインに提供することで、簡単に使えるようになる場合があります。中央のソリューションを使用する場合は、ドメイン（またはドメインのグループ）を互いに分離しておくことをお勧めします。すべてのマスターテーブルと参照テーブルが中央に保存されている場合、例えばカタログやメタデータを使用してそれらを区別し、どのデータセットがエンタープライズデータで、どのデータセットがドメインデータなのかを分類しておきます。

プロファイリング、マッチング、標準化、検証機能など、データ品質サービスについても同様です。サービスとしてデータ品質を扱えば、品質対策とコントロールが透明化され、ドメインはこれらのソリューションを自ら実装する必要がなくなります。ここでお勧めするのは、このモデルをデータパイプラインソリューションの一部にすることです。つまり、標準サービスや標準コンポーネントとして、データプロダクトアーキテクチャに組み込むのです。

マスターデータ管理と参照データ管理は、組織内でより高いレベルの一貫性と再利用を実現する方法ですが、それとは別の方法もあります。次の節では、MDMで見られるように、これらの方法が統合やデータ流通においてどのように重なり合うのかについて説明します。

10.5　MDMとデータキュレーション

マスターデータ管理は、**データキュレーション**と似たところがあります。どちらも、多様なソースからデータを収集し、それを統合することで、個々のデータよりも高い価値を持つようにするプロセスです。新しいデータの作成については、2章でコンストラクタドメインについて説明したときにすでに触れました。コンストラクタドメインはデータを消費するドメインですが、新しいデータプロダクトを作成して流通させることで、プロバイダーとしても機能します。これはデータキュレーションの一形態と見ることができます。

データキュレーションは、ほかのチームが繰り返し行う統合作業を排除するものです。これは、企業にとって重要なことです。大規模な組織では、このプロセスは、一般的に、DataOpsと組み合わせて行われます。DataOpsは、自動化され、統合され、信頼できるデータパイプラインを作成・提供するための方法論です。データキュレーションはMDMと似ていますが、違いを理解した上

で、それぞれに対して強力な原則を策定することが大切です。次の項では、キュレーションされたデータの作成と管理法について紹介します。

DataOpsとMDMには非常に多くの類似点がありますが、対象が異なります（DataOpsはデータエンジニア、MDMはデータスチュワード）。DataOpsのゴールは、コードを使って自動化されたパイプラインを構築し、データ品質の問題を解決することです。MDMは、コードで管理または自動化できない（あるいはすべきでない）問題が明らかになったときに、人間が関与する運用フローを提供します。

MDMとキュレーションデータ作成は、どちらも価値を提供し、データコンシューマの作業を容易にすることを目的としています。両者とも、ETL、データクレンジング、データサイエンス、メタデータ管理（リネージの取得、データモデルの記述など）などの技術を利用します。

これまで学んできたように、MDMのコアとなるのは、（マスター）データの収集、リンク、クレンジング、統合、マッチング、リッチ化、流通に使用されるプロセスです。このプロセスでは、一般的に重複が削除され、データの不整合が修正されます。また、MDMは、エンティティのコンソリデーション（類似または同一の複数のエンティティから1つのエンティティを作成すること）とクラスタの削減（単一のゴールデンレコードの作成）にも重点を置いています。MDMがもたらすものは、マスターデータと参照データの権威あるソースです。一意のデータは通常、中央で検出され、その出力は多くの修正が含まれるため、新たな物理的な場所で永続化されます。何よりも重要なのは、**異なるコンテキストを使って、新しいデータは作成されない**ということです。定量的な情報などの事実は、正確さと一貫性のために修正されますが、そのコンテキストそのものは変わりません。

データウェアハウスやデータレイクハウスと、MDMの関係

前の段落で、「権威あるソース」と述べました。データレイクハウスのゴールドレイヤーや、データウェアハウスの次元テーブルなどに対して、MDMによって生成されたものを権威あるものにするのは何なのかと疑問に思うかもしれません。その答えは、MDMシステムにはゴールデンレコードが格納されているからです。このゴールデンレコードは、そのリネージや、レコードがどのようにしてその場所に存在するようになったかというすべての履歴とともに格納されています。ゴールドレイヤーと次元テーブルには、MDMシステム自体からのゴールデンレコードの出力のみが格納されます。ここでもう1つの疑問が生じます。MDMシステムは次元テーブルやゴールドレイヤーに直接書き込むのでしょうか。答えは「いいえ」です。MDMシステムは、データウェアハウスチームが次元テーブルの入力に使用するソースにフィードする必要があります。最新のレイクハウスの「メダリオン」構成（https://oreil.ly/KEKop）では、シルバーレイヤーとゴールドレイヤーの間の中間的な役割を果たす必要があります。ゴールドレイヤーでは、データは消費可能な「プロジェクト固有」のデータベースに格納される場合が多いです。MDMデータはこのレイヤーの入力になります。

データキュレーションがMDMと異なるのは、既存のデータを修正するのか、新たにデータを作成するのかが明示されない点です。その意味では、コンテキストも変更できます。データキュレーションでは、データを永続化しなければならないのか、それとも必要に応じて作成されるのかについても明確にされていません。例えば、キュレーションデータは、1つまたは複数のデータベーステーブル上で実行されるクエリに基づいてデータベースビューから配信されたり、実行時にコードによって生成されたりします。データキュレーションプロセス全体をメタデータ駆動型にすることも可能です。つまり、メタデータを使用してキュレーションデータを生成することができます。このような作業の大部分にメタデータ（スキーマ、テーブル、カラム情報、クエリ、結合、フィルタなど）の操作が含まれるため、メタデータ管理と強い関係があることになります。

企業全体で一貫性を確保するための方法をいくつか見てみましょう。それぞれに長所と短所があります。

10.5.1　知識の交換

意味的な一貫性を実現するための方法の1つは、知識を交換することです。このアプローチでは、いくつかの手段でドメイン間で知識を共有します。メタデータファイルを追加したり、メタデータをデータにカプセル化したりすること

で、データに関する情報をデータそのものと一緒に提供することができます。また、データカタログなどの中央リポジトリでメタデータを管理することもできます。メタデータには、位置、アノテーション、属性、関係、意味など、ある特定のデータエンティティに関する情報を含めることができます。もし、エンティティが同一であるのであれば、ラベルやアノテーションを使って明記できます。このように情報交換が容易になります。

9章で学んだように、さまざまな方法で知識を増やすことができます。一般的に、データの専門家は、専門分野やドメインの専門家と連携してデータを表現します。また、クラウドソーシングというアプローチもあります。ユーザーや世の中のコミュニティに、コンテキストを提供してもらう方法のことです。スキャナやアノテーションツールも使用することができます。これらのツールはアルゴリズムを使用して重複を検出し、データを分類または格付けし、どのようなデータが一緒になっているのかを推測します。

10.5.2　統合ビュー

統合ビューは、事前に定義されたクエリのことです。実行時に、同じSQL文を使ってデータを再作成します。このような方法でデータの一貫性を確保することは、MDMとEDWの両方のアーキテクチャで一般的です。統合ビューは、テーブルにクエリを実行しているように見えるため、**仮想テーブル**とも呼ばれます。しかし、実際には、統合ビューの背後に存在するのはクエリです。

メタデータを利用して意味的な一貫性を提供する場合と異なるのは、ビューにはビジネスロジックを含めることができる点です。また、新たにデータ要素を生成することもできます。このような変更は、構文的な変換だけではありません。コンテキストの変換も行われる場合があります。また、データを複製できる点も異なります。ビューは実体化（マテアライズド）することもできます。つまり、結果をコピーして永続化することができます。これは、クエリの性能を向上させるのに特に有効です。

ビューは、メタデータと組み合わせることもできます。例えば、メタデータからビューを生成し、メタデータが変更されたときに、自動的にビューを変更することもできます。

10.5.3　再利用可能なコンポーネントと統合ロジック

データによる共同作業と再利用の方法として、**コードの共有**という方法も挙げられます。ここで共有されるのはキュレーションデータではありません。共有されるのは、結果を生成し、アウトプットを生成するために使われるコード（テンプレート、スニペット、スクリプトなど）です。このコードは、バージョン管理機能を備えた中央のオープンリポジトリに保存されます。このため、DevOpsチームが、公開されたコードに対して貢献を行い改善することができます。

このモデルの利点は、ビジネスロジックがドメイン内にのみ適用されるため、チームが必要に応じてロジックを変更したり、最適化したりすることができることです。さらに、コミュニティによる修正が中央のコードリポジトリで公開されれば、すぐにこのコードを使ってデータを再生成できます。このモデルの欠点は、一貫性です。チームがコードを変更できるので、チーム間で結果を比較することが難しくなるためです。

10.5.4　統合ハブによるデータの再発行

いくつかのデータベースベンダーは、元のソースをカプセル化することでデータキュレーションを行うことができると言っています。この方法では、ドメインチームがデータを抽出して統合プラットフォームに読み込み、再発行・流通させます。このプロセスでは、意味的コンテキストを変更することができるため、既存のデータセットに対して変換や改良を施すことができます。新しいデータセットを作成することもできます。

このように、ある特定のドメインを信頼するというモデルは、一見するとエレガントに見えますが、いくつかリスクと課題が存在します。

- データに何が起こったかを知るために、トレーサビリティとバージョン管理は重要です。このような透明性に関するリスクを軽減するために、データキュレーターには、取得したデータだけでなく、データに適用した一連の操作や変換をカタログ化するよう依頼しましょう。このメタデータは中央で公開されるべきです。
- データ品質とガバナンスに問題が発生する可能性があります。データをハブで修正すると、データを改善しても、元のゴールデンソースシステムに戻せないというリスクが生じます。このため、トランザクションプロセスや運用プロセスが、データの改善による恩恵を受けられなくなる可能性があります。また、新しいデータオーナーシップのために、元のデータオー

ナーシップがわかりにくくなるため、オーナーシップに関する懸念が生じる可能性もあります。

- 運用システムはハブを介して新しい機能やアプリケーションコンポーネントで拡張される場合があります。つまり、プロセスとデータの整合性が運用システムとハブの両方にまたがってしまうことを意味します。データは拡散するのと同時に、ほかのユースケースやデータコンシューマのニーズに合わせて最適化されるため、トランザクションの一貫性を保証することがより難しくなります。正しく設計されていない場合、差異が生じて、ハブと運用システムの間に階層的な依存関係が生じるおそれがあります。また、過渡的なシステムとハブの両方から、データをカプセル化したサービスが出現する可能性があります。最終的には、密結合されたアーキテクチャになりかねません。

このようなデータの再発行において、企業側に意味的一貫性をもたらすには、データモデル、リネージ、ドキュメントに関する明確な標準、データクレンジングのルール、データを取得してプラットフォームへ戻すかどうかを決めるデータガバナンスプロセスが必要です。次の項では、集約という別のアプローチについて見ていきます。

10.5.5　集約によるデータの再発行

MDMの活動（データの収集、クレンジング、統合、調和など）は、ほかのドメインと共有するためにキュレーションデータを作成する、集約ドメインの活動と重なります。このような重なりに対処するために、活動をクラスタリングする場合やドメインへの責任分担を行う際には、ドメイン間の連携モデルに気をつけるとよいでしょう。はっきり理解できるように、例を使って説明しましょう。

データ要件が重なる3つのユースケースがあるとします。**図10-4**に示すように、さまざま連携パターンをチーム内やチーム間に適用することができます。

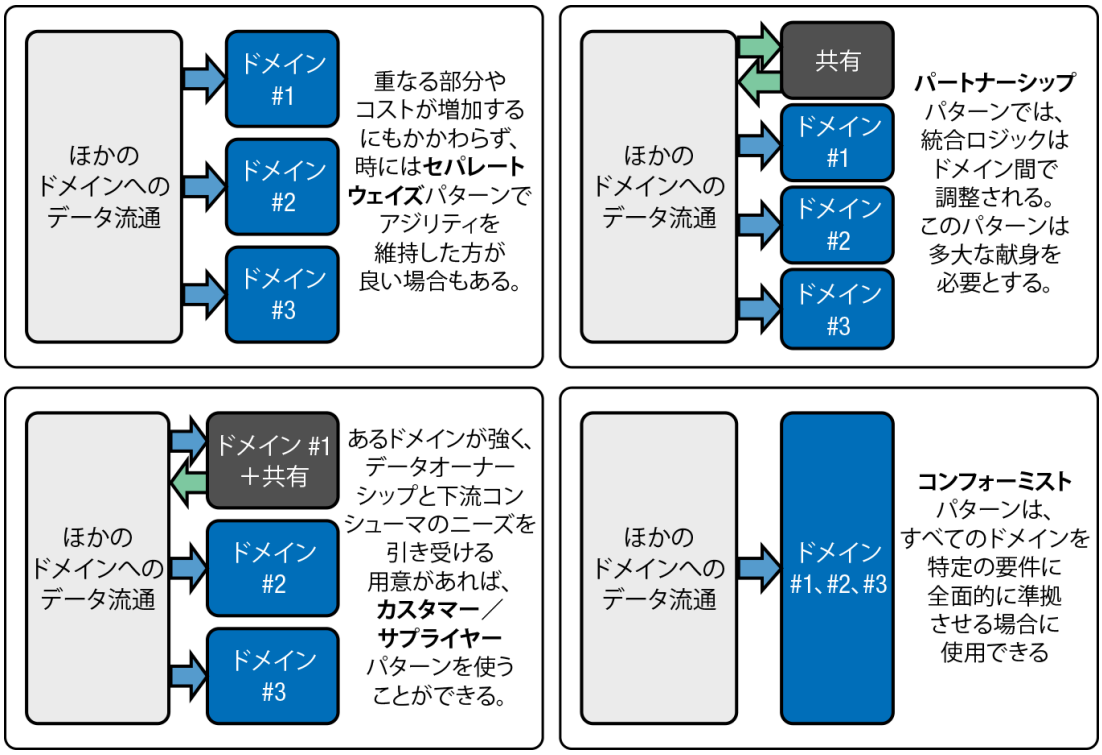

図10-4　データに対するニーズが共通するドメインのさまざまな連携パターン

それぞれの方法について見ていきましょう。

- **セパレートウェイズ**（別々の道、Separate Ways）パターンは、高度な柔軟性とアジリティが必要となる場合に使用できます。また、モデリングの観点からほとんど何も共有されず、再利用性が限定的で、重複のコストが許容できる場合にも有効な選択となります。
- 重複する部分が多い場合、すべてのパーティーに共通するニーズに対応するために、**パートナーシップ**パターンを使用します。すべてのチームが協力し、互いのニーズを尊重する姿勢が必要です。すべてのチームは、共有ロジックを自由に変更することができないため、かなりの献身が求められます。このアプローチでは、データエンジニアリングチームは、データのコンシューマであると同時にプロバイダーでもあります。データを取得し、抽出し、データストアに読み込み、再発行・流通させます。
- あるチームが、データオーナーシップと、下流のコンシューマのニーズを引き受けるつもりがあれば、**カスタマー/サプライヤー**パターンを使用することができます。このパターンの問題点は、利害が対立する可能性があり、下流のチームが成果物やスケジュールの優先順位を協議しなければならないことです。
- すべてのドメインをすべての要件に適合させる場合、**コンフォーミスト**（順応者、conformist）パターンを使用することができます。このパター

ンは、統合作業が非常に複雑な場合、（分散）協調が望めない場合、ベンダーパッケージを使用する場合などに有効な選択肢となります。

この項で説明したパターンは、ドメイン間のデータ統合や調和のニーズが重なる場合に特に重要となります。このような場合、汎用的で繰り返し使用できる統合ロジックを分離し、新たに作成した（集約）データプロダクトとして流通させることが有効です。

10.6　データガバナンスに関する推奨事項

前述したように、MDMとデータキュレーションの間には重なる部分が多くあります。しかし、重要な違いもあるため、ガバナンスの観点からは別々に管理する必要があります。MDMでは、一般的に、データは一貫性の観点から調整されます。MDMは意味を変えて新しいデータを作成するわけではないので、データユーザーと管理部門は、元のデータオーナーやゴールデンソースシステムまでたどることができます。一方、データキュレーションは、既存のデータから新しいデータを作成・導出する場合があるため、新たなデータオーナーシップが生じることがあります。このため、データキュレーションはドメインとより強く整合し、ドメイン内で実行されます。

キュレーションデータを作成するためのさまざまな方法は、9章で説明したデータの民主化とも深い関係があります。連合型のアプローチでは、中央のデータ管理チームから、非中央集権的なチームへと移行します。どのような統合ロジックが適用されたかを透明化し、チームがほかのチームにデータを戻せるようにすることで、データの品質や意味解釈を高め、意思決定の強化につなげます。しかし、権限委譲やスコープの決定については、データ管理全体を監督する中央組織が必要です。

ユーザーは、使用するデータに一貫性と正確性がなければ、正しい意思決定を行うことができません。MDMを使用することで、企業レベルでのデータの一貫性と品質を確保できます。

とはいえ、適切なバランスを見つけることが重要です。マスターデータや参照値の対象領域が多すぎると、ドメイン間の調整が難しくなります。エンタープライズデータがまったくないと、どのような結果も比較できなくなります。そこで、この章の冒頭の文章を思い出してください。もしデータが速く流動的なものであれば、細かく分割してドメインに任せましょう。しかし、データが安定していて重要であれば、MDMの利用を検討しましょう。何が本当に重要か

を把握するためには、データリネージが役立ちます。データリネージは、すでに利用されているデータ資産や、利用する上でクリティカルパスにあるデータ資産を示してくれます。最も重要なのは、これらのデータ資産が多くのドメインにまたがる場合があること、そしてデータ資産自体やそのドメインが時間の経過とともに変化する可能性があることを考えれば、マスターデータに対してアジャイルで取り組む必要があるということです。MDMの情報モデルを正確に定義しようとすると、データ資産が進化するにつれて、多くの見直しが発生することになります。

MDMをバランスよく使い始める現実的な方法は、リポジトリを導入することです。これが組織のマスターデータを管理する最もシンプルな方法です。リポジトリがあれば、どのデータが低品質なのか、あるいは整合させる必要があるのかを知るために、ドメインシステムを調整する必要はありません。リポジトリがその情報を取得するのを助けてくれるので、より迅速に価値を提供することができます。

もう1つのお勧めは、ドメインと合意に達したら、プロセスとガバナンスを整合させることです。MDMに特化したデータ契約書を作成し、関係するすべてのドメインに対して、スケジュールとレビューに関して合意を取り交わすことを検討してください。また、メタデータの作成も忘れないようにしましょう。マスターデータをカタログ化し、どのデータがマスターデータ管理の対象であるのかをドメインが容易に認識できるようにします。また、データがデータパイプラインをどのように流れているかを表すリネージも用意しましょう。

さらに進めて、メタデータの品質が高くなったら、機械学習を使って、重なる部分や企業レベルで管理すべきデータを事前に予見することを検討してください。モデルはどのデータが重要かを学習し、予見することができます。この段階に達している企業はまだ見たことがありませんが、これが最高レベルの成熟度でしょう。

10.7　まとめ

マスターデータ管理が重要であることは明らかです。ユーザーは、データに一貫性と正確性があればこそ、正しい判断を下すことができるからです。MDMは、エンタープライズレベルでの一貫性と品質を保証します。この2つは密に絡み合っているため、多くのソリューションがターゲットにしています。MDMは、次のような方法で使いやすさと効率性の問題に対処します。

マスターデータプロダクトを追加します。
これにより、エンタープライズ全体の一貫性が確保され、複数のドメインが調和とデータ品質のために独自のデータ変換ロジックを構築する必要がなくなります。マスターデータ作成はさまざまなレベルで行えます。エンタープライズレベルでは、データが重要で組織全体にまたがる場合に作成します。ドメインレベルでは、データがいくつかのドメイン間で共有されるが、すべてのドメインでは共有されない場合に作成します。これらのスコープは、時に重なることがあります。例えば、ドメインによっては、ドメインレベルのマスターデータプロダクトと、エンタープライズレベルのマスターデータプロダクトを使用する場合があります。

データプロダクト作成のために参照データを導入します。
ドメインは中央で管理される参照データに準拠しなければなりませんが、ローカルの参照データの解釈や、データの組み合わせに関する問題は解決されます。

ドメインがドメイン集約の役割を担えるようにします。
データキュレーションは、データを新しいコンテキストに変換するために使用できます。しかし、繰り返し可能な統合ロジックを管理するには、これを新しく作成したデータプロダクトとして流通させ共有する方が良いでしょう。

組織でMDMの実装を始めるにあたっては、最もシンプルな実装スタイルである「レジストリ」から始めるのが現実的です。このスタイルでは、運用システムを調整することなく、どのデータを整合させる必要があるのかや、どのデータの品質が悪いのかを知ることによって、迅速に価値を提供することができます。

次のステップは、スコープをはっきりとさせることです。**すべての**データを選択しようとするあまり、エンタープライズレベルのデータ統一という落とし穴にはまらないでください。顧客、契約、組織単位、製品など、組織にとって付加価値の高い対象から始めましょう。マスター管理するフィールドは、特に重要なものだけを選択するようにします。属性の数は数百ではなく、数十程度にすべきです。意見がまとまったら、プロセスやガバナンスを調整します。スケジュールやレビューなどに関する合意事項は、誰にでもわかるようにしておきしましょう。メタデータについても同様です。マスターデータをカタログ化し、どのソースシステムからのどのデータ要素が対象となるのか、これらの要素がどのようにデータパイプラインを流れていくのかを、ユーザーが把握できるようにします。

最後のステップは、最終的な目標である「共存」を実現することです。つまり、改善されたものが元のソースシステムに直接戻ってくるようにすることで

す。このステップは、アーキテクチャに多くの変更を加える必要があるため、非常に大変な作業となります。ソースシステムは、マスターデータストアからのマスターデータの修正や改善を扱えるようにしなければなりません。修正や改善などによりマスターデータが変更された場合は、統合アーキテクチャのパターンを使って適切に流通させる必要があります。

また、キュレーションデータを作成することで、エンタープライズ全体でのデータ一貫性を向上させることについても議論しました。このためには、効率的なコミュニケーションモデルとデータガバナンスが重要です。データの再利用が進めば、組織はより有効に機能するようになります。このため、多くの企業が、コミュニティベースのアプローチ、オープンデータモデル、データマーケットプレイスに注目しています。さて、ここからはヘリコプターに戻り、データを価値に変える際に統合データがどのような役割を果たすかを考察します。次の章では、たくさんの出来事が入れ替わりながら進んでいきます。上へ飛んだり下へ飛んだり、外へ出たり中へ入ったりします。シートベルトを締め、背もたれを元の位置に戻してください。良い旅をお過ごしください。